APACHE kafka®

# UNIT

## Design di un sistema di Messaging

- Nella progettazione e sviluppo di un qualsiasi sistema di integrazione delle applicazioni, ci sono alcuni principi importanti che dovrebbero essere considerati e valutati:
  - Loose coupling (bassa dipendenza)
  - Common Interface Definitions
  - Latency (latenza)
  - Reliability (affidabilità)

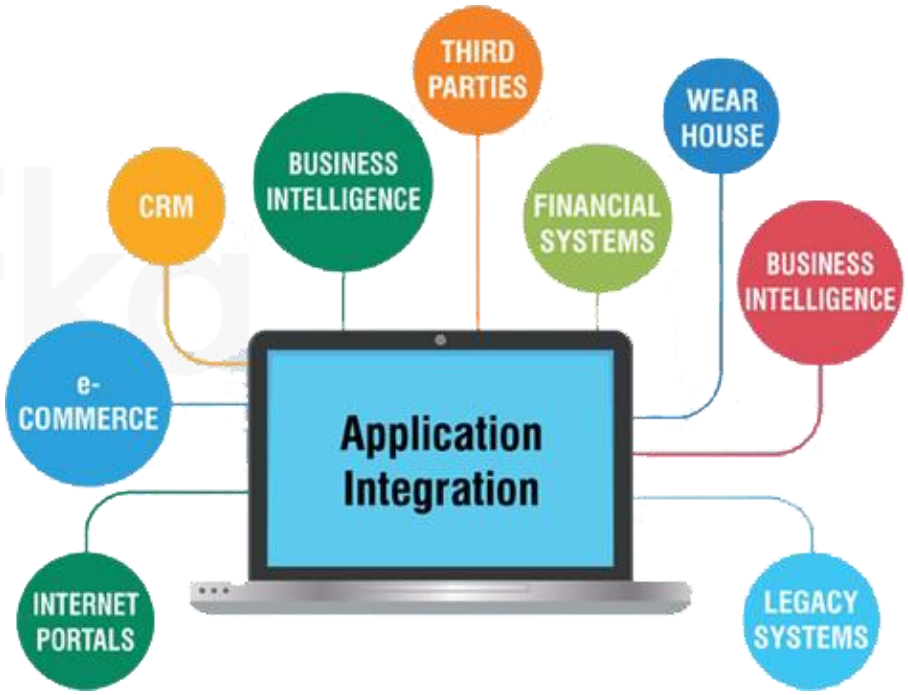


Copyright ETLForma – Tutti i diritti Riservati

# Loose Coupling

- Il «**Loose Coupling**» è un approccio allo sviluppo che ha come fine il ridurre al minimo le dipendenze tra le varie applicazioni coinvolte nello sviluppo per
  - Garantire che eventuali modifiche in un'applicazione non influiscano su altre applicazioni («evitare di sviluppare applicazioni strettamente accoppiate»)
  - Prevenire che qualsiasi cambiamento nelle specifiche possa «rompere o cambiare o in qualche modo influenzare» le funzionalità di altre applicazioni dipendenti (**regression**).

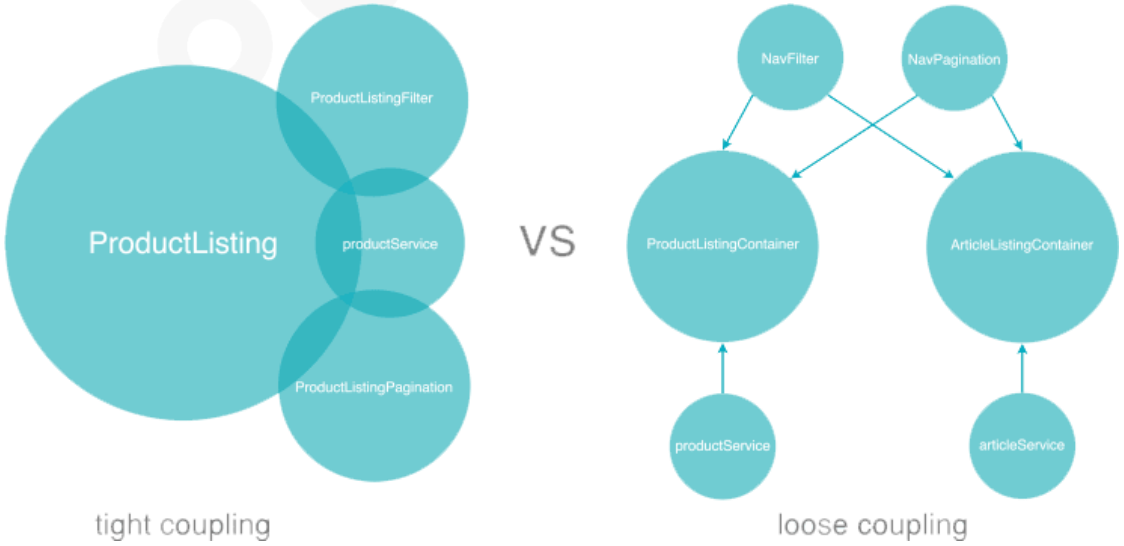


Copyright ETLForma – Tutti i diritti Riservati

# Common Interface Definitions

- Le CID garantiscono un formato di dati concordato comune per lo scambio tra le applicazioni.

- Aiuta a stabilire standard di scambio di messaggi tra le applicazioni.

- Assicura che eventuali migliorie pratiche di scambio di informazioni possano essere applicate facilmente.

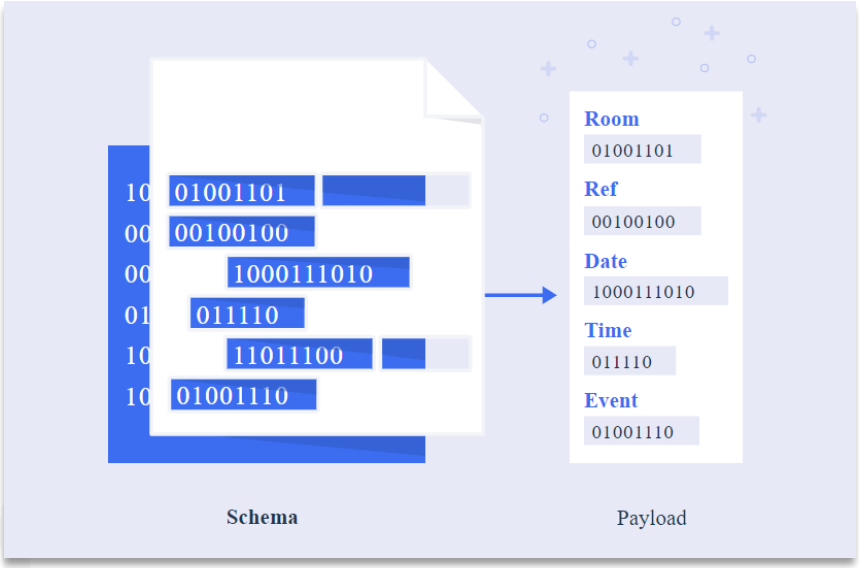


- Esempio: scelta di Avro come formato dati per scambiare messaggi.

  - Avro è una buona scelta per gli scambi di messaggi in quanto serializza i dati in un formato binario compatto e supporta l'evoluzione dello schema.

Copyright ETLForma – Tutti i diritti Riservati

# Latency

- La latenza è il lasso di tempo che intercorre tra l'invio da parte del mittente fino e la relativa consegna al destinatario.

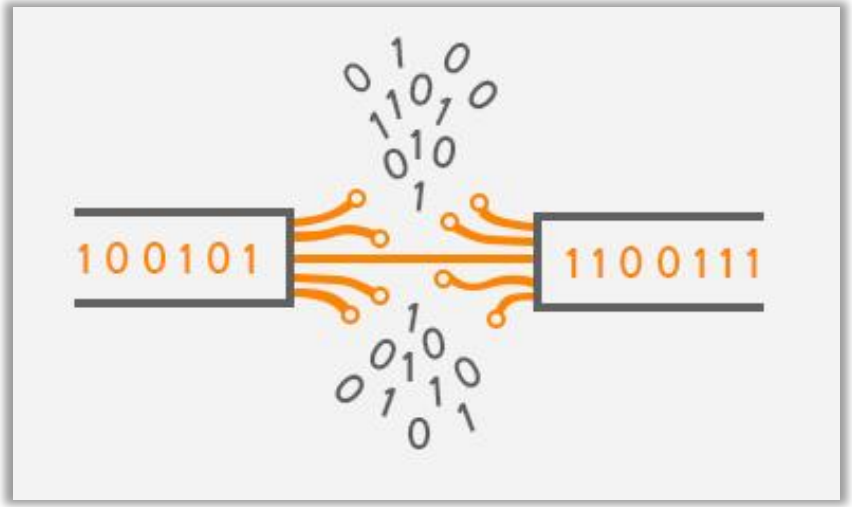


- Per la maggior parte delle applicazioni lo sviluppo è orientato ad ottenere una bassa latenza come requisito critico.

- Anche in una modalità di comunicazione asincrona, non è desiderabile un'elevata latenza poiché un ritardo significativo nella ricezione dei messaggi potrebbe tradursi in perdite significative per un'azienda.

Copyright ETLForma – Tutti i diritti Riservati

# Reliability

- L'affidabilità garantisce che l'indisponibilità temporanea delle applicazioni non influisca sulle applicazioni dipendenti che devono scambiare informazioni.

- In generale, quando l'applicazione di origine invia un messaggio all'applicazione remota, a volte l'applicazione remota potrebbe essere lenta o potrebbe non essere in esecuzione a causa di un errore.

- La comunicazione affidabile e asincrona dei messaggi garantisce che l'applicazione di origine continui a funzionare e sia sicura che l'applicazione remota riprenderà l'attività in un secondo momento.

Copyright ETLForma – Tutti i diritti Riservati

# Comprensione dei sistemi di messaggistica

- Come illustrato nella figura, l'integrazione delle applicazioni basate su messaggi comporta applicazioni aziendali discrete che si colleghino a un sistema di messaggistica comune e inviino o ricevano dati ad esso.

- Un sistema di messaggistica funge da componente di integrazione tra più applicazioni.

- Tale integrazione richiama comportamenti applicativi diversi basati su scambi di informazioni sull'applicazione.

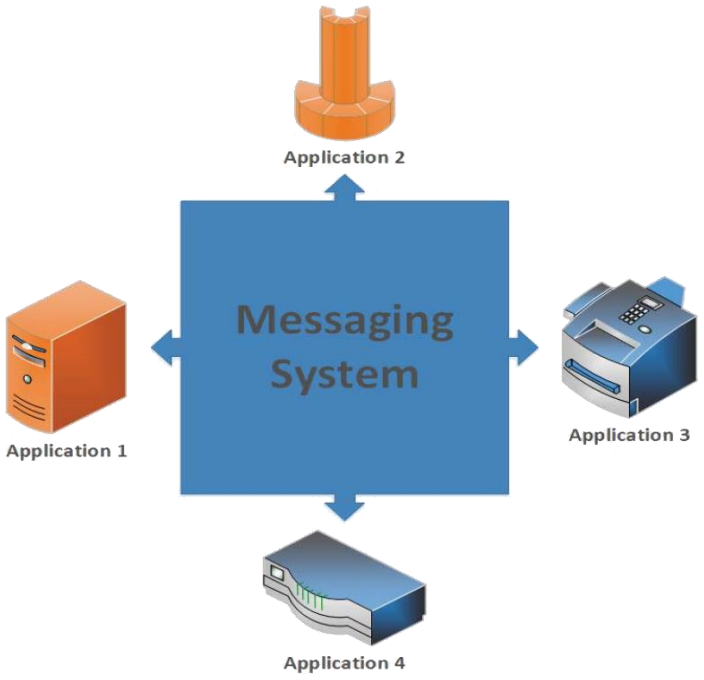


Copyright ETLForma – Tutti i diritti Riservati

- Le aziende hanno iniziato ad adottare architetture a micro-servizi con l'obiettivo di disaccoppiare sempre di più le proprie applicazioni.

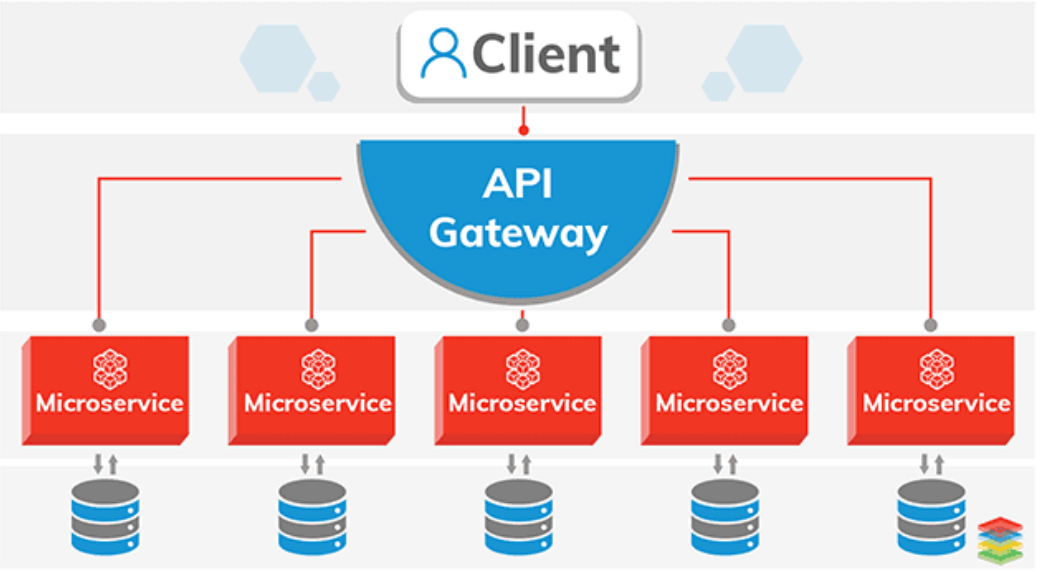


- In tal modo esse comunicano tra loro in modo asincrono al fine di rendere la comunicazione più affidabile dato che le applicazioni non devono essere in esecuzione contemporaneamente.

- Un sistema di messaggistica aiuta a trasferire i dati da un'applicazione all'altra lasciando alle applicazioni la sola logica di gestione di ciò che devono condividere come dati piuttosto che sul come debbano essere condivisi.

Copyright ETLForma – Tutti i diritti Riservati

## «Message Queues»:

- Sono connettori (a volte canali) tra l'invio e la ricezione di apps.
- La loro funzione principale è quella di ricevere pacchetti di messaggi dall'app di origine e inviarli all'app ricevente in modo tempestivo e affidabile.

Copyright ETLForma – Tutti i diritti Riservati

«Messages» (data packets):

- Un messaggio è un pacchetto di dati atomico che viene trasmesso su una rete a una coda di messaggi.
- L'app mittente suddivide i dati in pacchetti di dati più piccoli e li prepara come un messaggio con le informazioni di protocollo e intestazione e lo invia alla coda dei messaggi.
- In modo simile, un'applicazione ricevente riceve un messaggio ed estrae i dati dal wrapper di messaggi per elaborarlo ulteriormente.

Copyright ETLForma – Tutti i diritti Riservati

«Sender» (detto anche Producer):

- E' un'app che funge da fonte per i dati che devono essere inviati a una determinata destinazione.
- I Senders stabiliscono connessioni agli endpoint della coda dei messaggi e inviano i dati in pacchetti di messaggi più piccoli che aderiscono agli standard di interfaccia comuni.
- A seconda del tipo di sistema di messaggistica in uso, le app del mittente possono decidere di inviare i dati uno per uno o in un batch.

Copyright ETLForma – Tutti i diritti Riservati

«Receiver» (detto anche Consumer):

- Sono i destinatari dei messaggi inviati dall'appl mittente.
- Estraggono i dati dalle code dei messaggi o ricevono dati dalle code dei messaggi attraverso una connessione persistente.
- Alla ricezione dei messaggi, estraggono i dati da quei pacchetti di messaggi e li usano per un'ulteriore elaborazione.

Copyright ETLForma – Tutti i diritti Riservati

## «Data transmission protocols»:

- Determinano le regole per governare gli scambi di messaggi tra app.
- Diversi sistemi di accodamento utilizzano protocolli di trasmissione dati diversi; dipende dall'implementazione tecnica degli endpoint di messaggistica.
- Kafka utilizza protocolli binari su TCP: il client avvia una connessione socket con le code Kafka e quindi scrive i messaggi insieme alla lettura del messaggio di riconoscimento.

Copyright ETLForma – Tutti i diritti Riservati

- Alcuni esempi di protocolli di trasmissione dei dati sono
  - AMQP (Advance Message Queuing Protocol)
  - STOMP (Streaming Text Oriented Message Protocol)
  - MQTT (Message Queue Telemetry Protocol)
  - HTTP (Hypertext Transfer Protocol)

Copyright ETLForma – Tutti i diritti Riservati

- Transfer mode:
  - La modalità di trasferimento in un sistema di messaggistica può essere intesa come il modo in cui i dati vengono trasferiti dall'applicazione di origine all'applicazione ricevente.
  - Esempi di modalità di trasferimento sono le modalità sincrone, asincrone e batch.

Copyright ETLForma – Tutti i diritti Riservati

# UNIT

## Messaging Model

- I principali modelli di «**messaging**» sono:
  - Point-To-Point (PTP) Messaging System
  - Publish-Subscribe (Pub/Sub) Messaging System

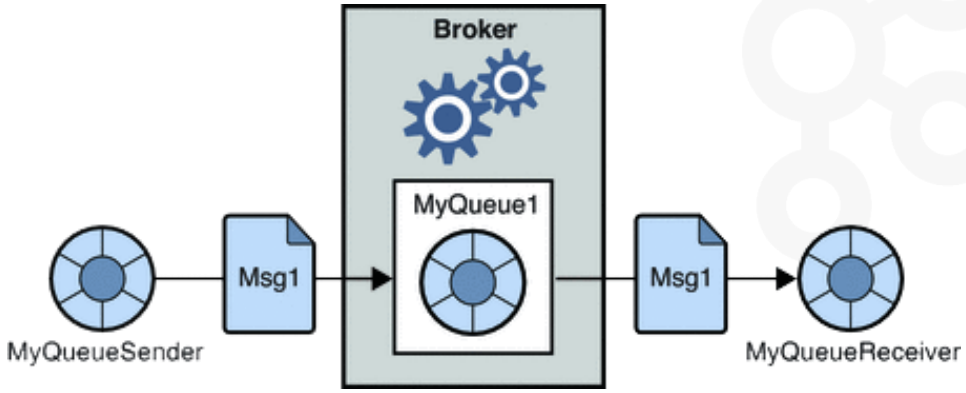


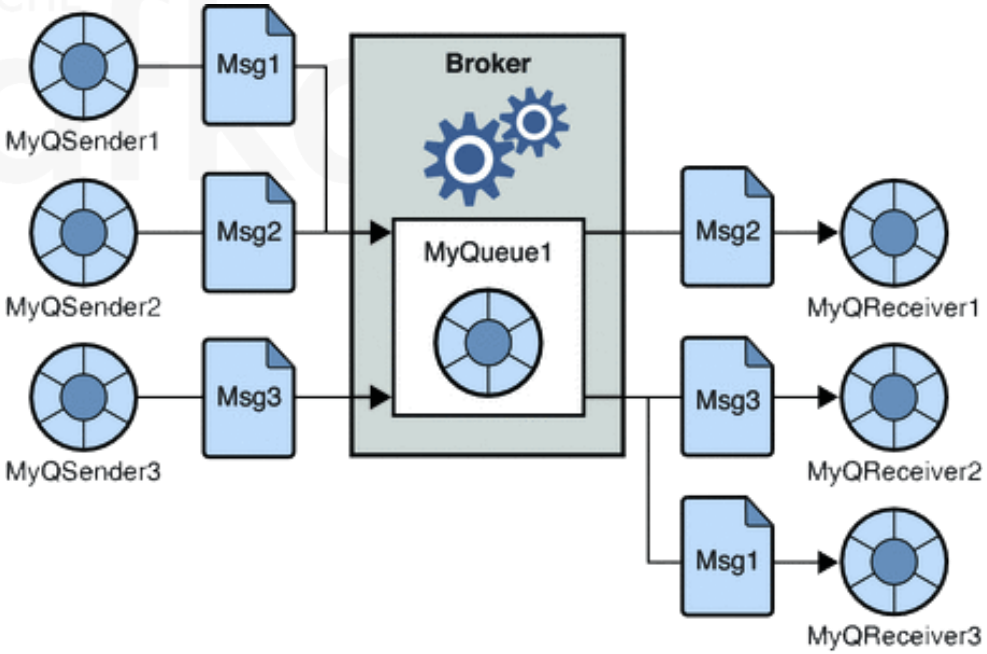


Copyright ETLForma – Tutti i diritti Riservati

# PTP Model

- Il Message Producer è chiamato Sender e il Consumer è chiamato Receiver
- Sender e Receiver scambiano messaggi per mezzo di una destinazione chiamata coda.
- I mittenti producono messaggi in una coda e i destinatari consumano messaggi da questa coda.
- Ciò che distingue la messaggistica PTP è che un messaggio può essere consumato da un solo consumatore.
- È possibile che più Consumer ascoltino in coda per lo stesso messaggio, ma solo uno di loro lo riceverà.

Copyright ETLForma – Tutti i diritti Riservati

# PTP Model

- Un modello PTP si basa sul concetto di invio di un messaggio a una named destination corrispondente all'endpoint della coda messaggi che ascolta i messaggi in arrivo su una porta.

- In genere, nel modello PTP, un destinatario richiede un messaggio che un mittente invia alla coda, piuttosto che iscriversi a un canale e ricevere tutti i messaggi inviati su una determinata coda.

- I modelli di messaggistica PTP gestiscono le code dei messaggi come liste FIFO.

Copyright ETLForma – Tutti i diritti Riservati

# PTP Model

- Nelle code, i messaggi vengono ordinati nell'ordine in cui sono stati ricevuti e, man mano che vengono consumati, vengono rimossi dall'intestazione della coda.

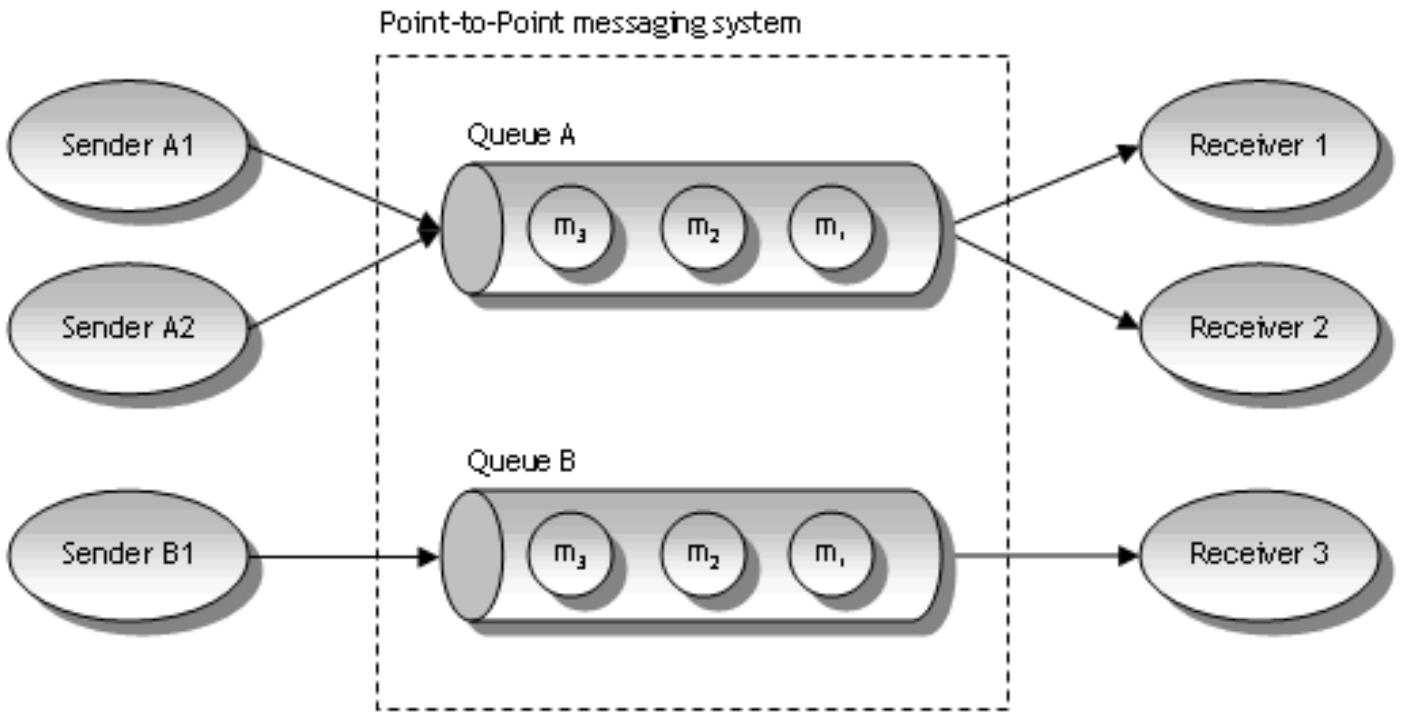


Nota: In Kafka le code mantengono gli offset dei messaggi; invece di eliminare i messaggi, incrementano gli offset per il destinatario. I modelli basati su offset offrono un supporto migliore per la riproduzione dei messaggi.

Copyright ETLForma – Tutti i diritti Riservati

# PTP Model

- Il modello di messaggistica PTP può essere ulteriormente classificato in due tipi:
  - Fire-and-forget model: il produttore si limita ad inviare un messaggio a una coda centralizzata senza attendere alcun tipo di riscontro relativamente alla consegna del messaggio e a chi l'abbia ricevuto; può essere utilizzato in uno scenario in cui si desidera attivare un'azione o inviare un segnale al ricevitore per attivare un'azione che non richiede una risposta.
  - Request/reply model: E' un modello asincrono di richiesta/risposta ove il mittente invia un messaggio su una coda e poi si pone in ascolto su un'altra coda in attesa della risposta dal destinatario. Il modello prevede un elevato grado di disaccoppiamento tra app mittente e app destinataria.

Copyright ETLForma – Tutti i diritti Riservati

# Publish-subscribe (Pub/Sub ) Model

- In questo tipo di modello, un Subscriber (**sottoscrittore**) registra il proprio interesse per un particolare argomento o evento e viene successivamente informato dell'evento in modo asincrono.

- I Subscriber hanno la possibilità di esprimere il loro interesse per un evento o un modello di eventi e vengono successivamente informati di qualsiasi evento generato da un Publisher (Editore) che corrisponda al loro interesse registrato.

Copyright ETLForma – Tutti i diritti Riservati

# Publish-subscribe (Pub/Sub ) Model

- È diverso dal modello di messaggistica PTP in quanto un argomento può avere più destinatari e ogni destinatario riceve una copia di ciascun messaggio.

- In altre parole, un messaggio viene trasmesso a tutti i destinatari senza che debbano eseguire il polling dell'argomento.

- Nel modello PTP, il destinatario esegue il polling della coda per i nuovi messaggi.

Copyright ETLForma – Tutti i diritti Riservati

# Publish-subscribe (Pub/Sub ) Model

- E’ utilizzato quando è necessario trasmettere un evento o un messaggio a molti consumer.

- A differenza del PTP, tutti i consumer (o subscriber) che ascoltano l'argomento riceveranno il messaggio.

- Garantisce un’alta interoperabilità delle piattaforma con i vari sistemi software che interagiscono con essa.

- Inoltre, i messaggi possono essere conservati nell'argomento (Topic) fino a quando non vengono recapitati ai subscriber attivi.

Copyright ETLForma – Tutti i diritti Riservati

# Publish-subscribe (Pub/Sub ) Model

- Il modello prevede opzioni per avere subscription «durable» per consentire al subscriber di disconnettersi, riconnettersi e raccogliere i messaggi consegnati quando non era attivo.

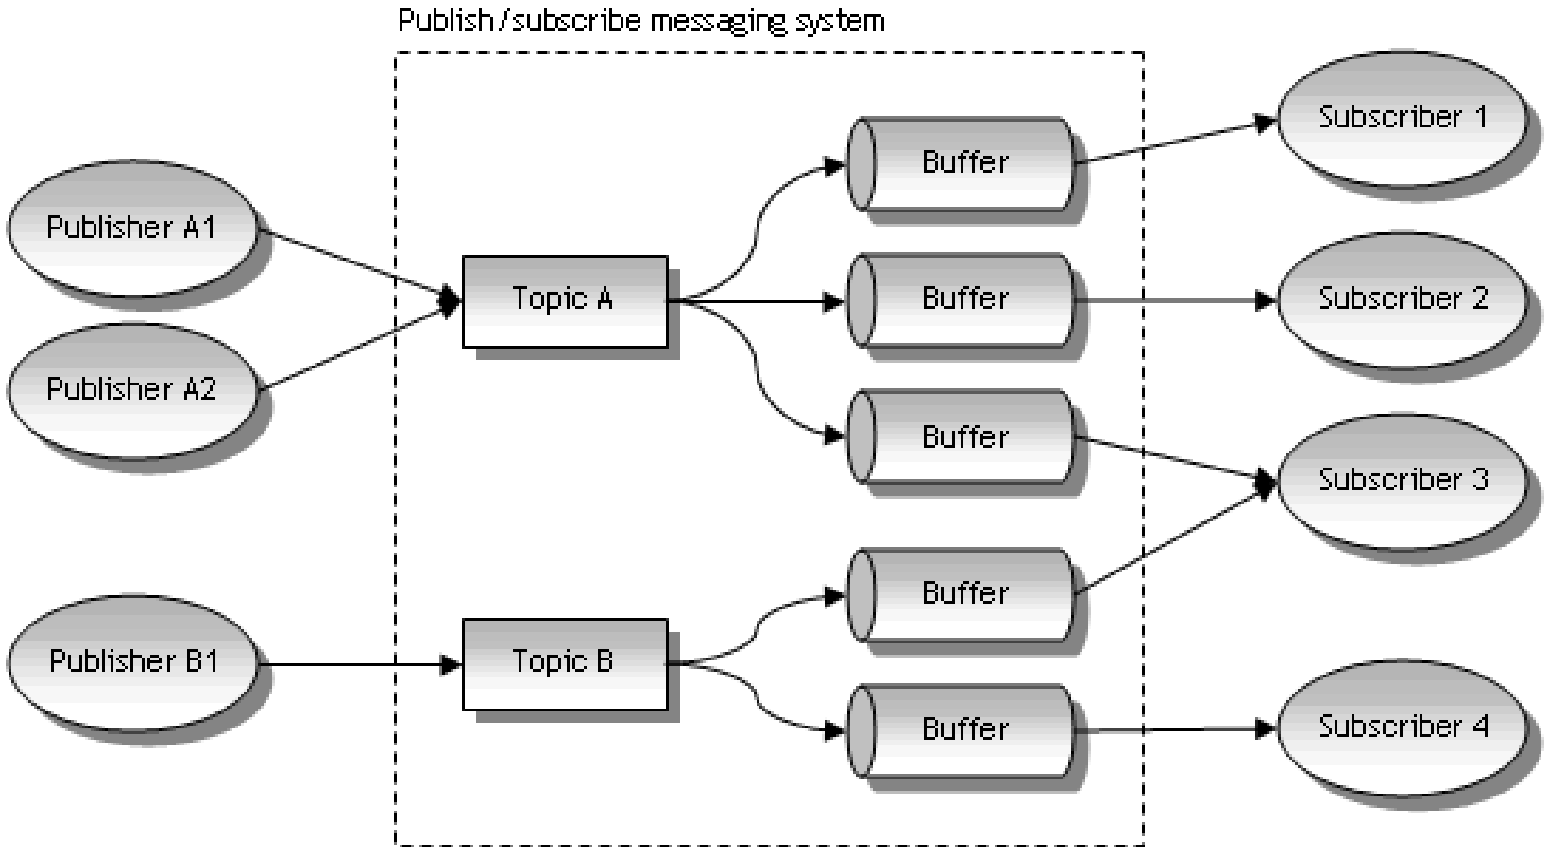


NOTA: Kafka incorpora alcuni di questi importanti principi di progettazione.

Copyright ETLForma – Tutti i diritti Riservati

# UNIT

Protocolli

# Advance Queuing Messaging Protocol (AQMP)

- Esistono diversi protocolli di trasmissione dei dati che utilizzano i messaggi come «oggetto» per lo scambio dati che possono essere trasmessi tra sender, receiver, e message queues.

- E' importante comprendere come funzionino perché influiscono sulle decisioni di progettazione utili per la definizione dell'architettura di integrazione delle applicazioni orientate ai messaggi. AQMP è uno dei protocolli progettato per la messagistica.

- AQMP è un protocollo aperto per l'accodamento dei messaggi asincrono sviluppato e maturato nel corso di diversi anni.

Copyright ETLForma – Tutti i diritti Riservati

# Advance Queuing Messaging Protocol (AQMP)

- AMQP offre set ricchi di funzionalità di messaggistica che possono essere utilizzate per supportare scenari *molto avanzati*.

- Il protocollo prevede tre componenti principali:

  - Publisher(s)
  - Consumer(s)
  - Broker/Server(s)

- Ogni componente può essere replicato e installato su host indipendenti.

- Publishers e Consumers comunicano tra loro attraverso le code dei messaggi destinate agli scambi all'interno dei broker. Il recapito è affidabile, garantito e la consegna è di tipo «in-order».

Copyright ETLForma – Tutti i diritti Riservati

# Advance Queuing Messaging Protocol (AQMP)

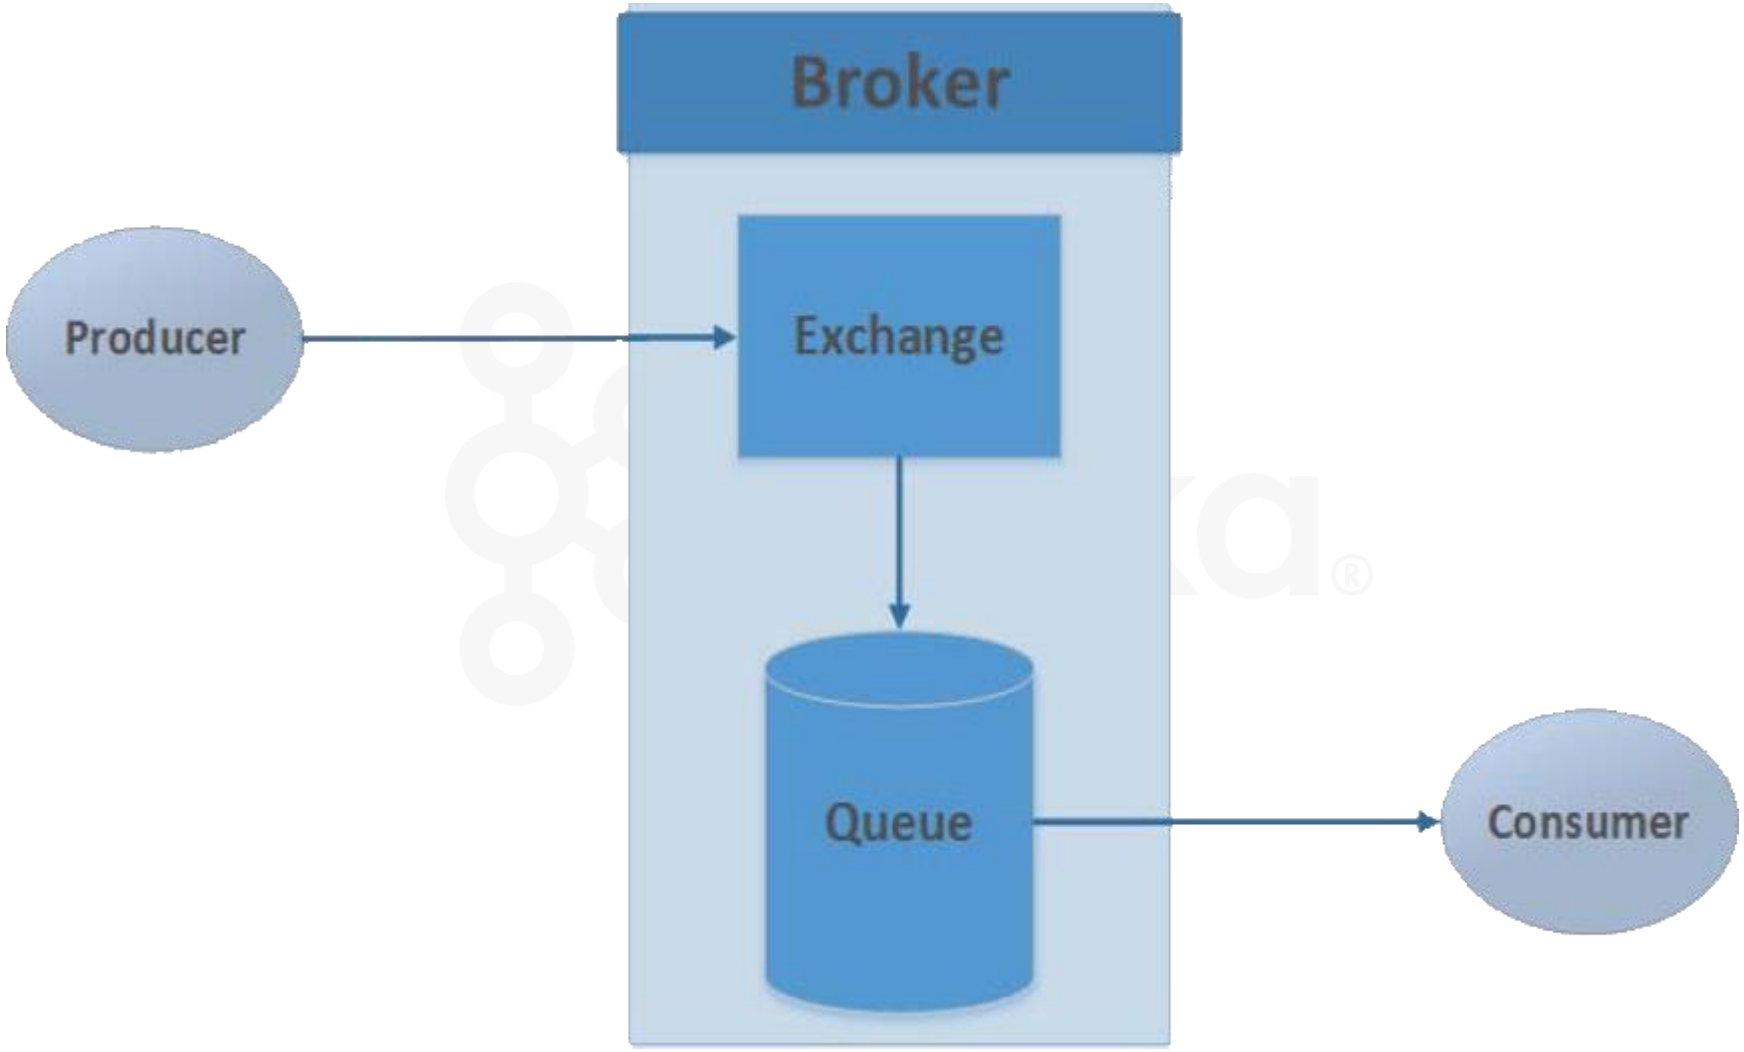


Copyright ETLForma – Tutti i diritti Riservati

- Lo scambio di messaggi può avvenire in diversi modi.

- Direct exchange: è un meccanismo di routing key-based; in pratica un messaggio viene recapitato alla coda ove il suo identificativo è uguale alla chiave di routing del messaggio.

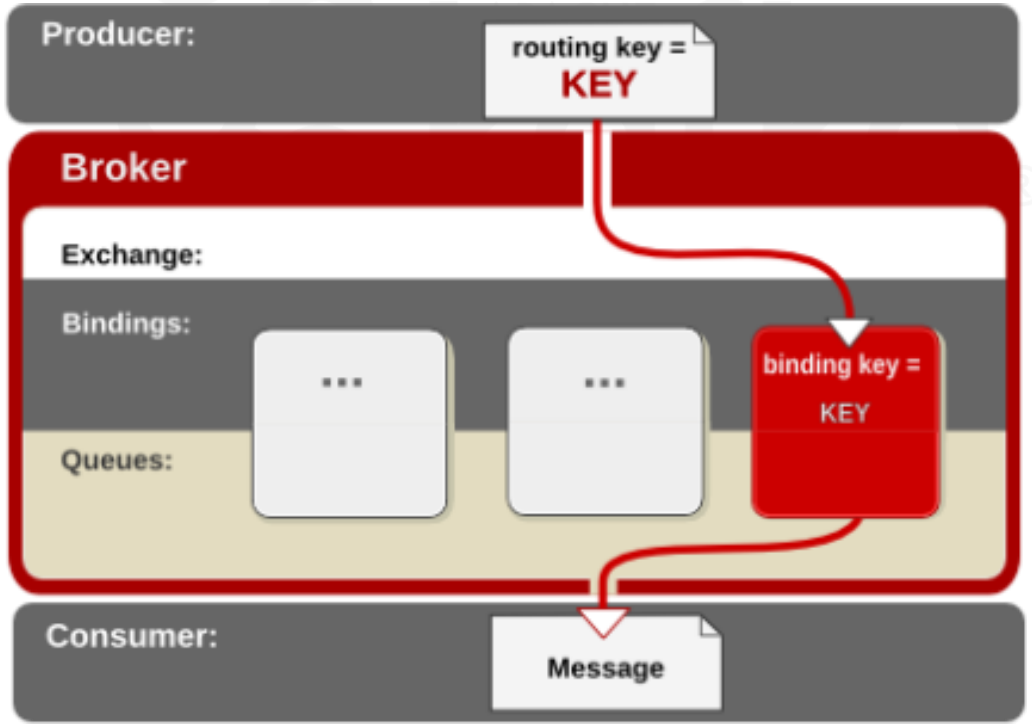


Copyright ETLForma – Tutti i diritti Riservati

- Fan-out exchange: uno scambio di fan-out instrada i messaggi a tutte le code ad esso associate e la chiave di routing viene ignorata.
  - Se N code sono associate a uno scambio di fan-out, quando un nuovo messaggio viene pubblicato, una copia del messaggio viene recapitata a tutte le N code.
  - Gli scambi di fan-out sono ideali per il routing di trasmissione dei messaggi.
  - In altre parole, il messaggio viene clonato e inviato a tutte le code collegate a questo scambio.

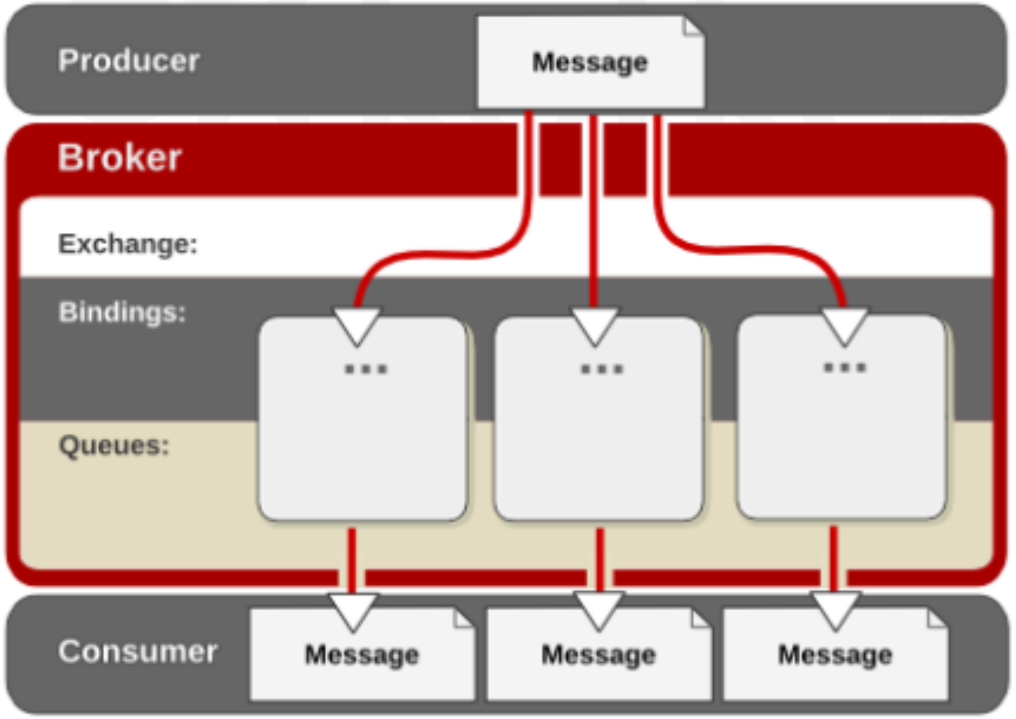


Copyright ETLForma – Tutti i diritti Riservati

- Topic exchange: nello scambio di argomenti, il messaggio può essere instradato ad alcune delle code collegate usando i caratteri jolly (wildcards).
  - Il tipo di scambio di argomenti viene spesso utilizzato per implementare varie varianti del modello di publish/subscribe (pubblicazione/sottoscrizione).
  - Gli scambi di argomenti sono comunemente utilizzati per l'instradamento multicast di messaggi.

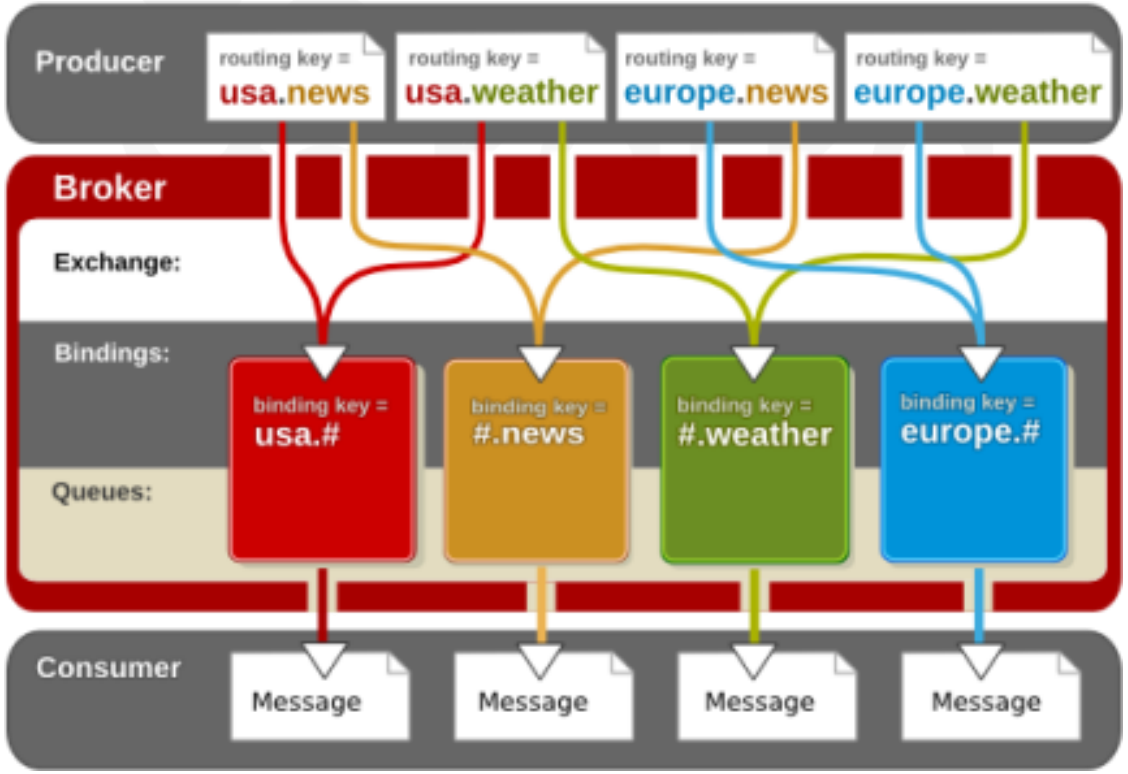


Copyright ETLForma – Tutti i diritti Riservati

# UNIT

Uso di messaging systems in applicazioni di big data streaming

# Layer di un'applicazione per big data

- Si parla di big data quando si ha un insieme talmente grande e complesso di dati che richiede la definizione di nuovi strumenti e metodologie per estrapolare, gestire e processare informazioni entro un tempo ragionevole.

- In ambito Big Data, le evoluzioni architetturali hanno portato alla definizione di architetture complesse (come mostrato nella slide successiva) e di cui discuteremo alcuni aspetti.

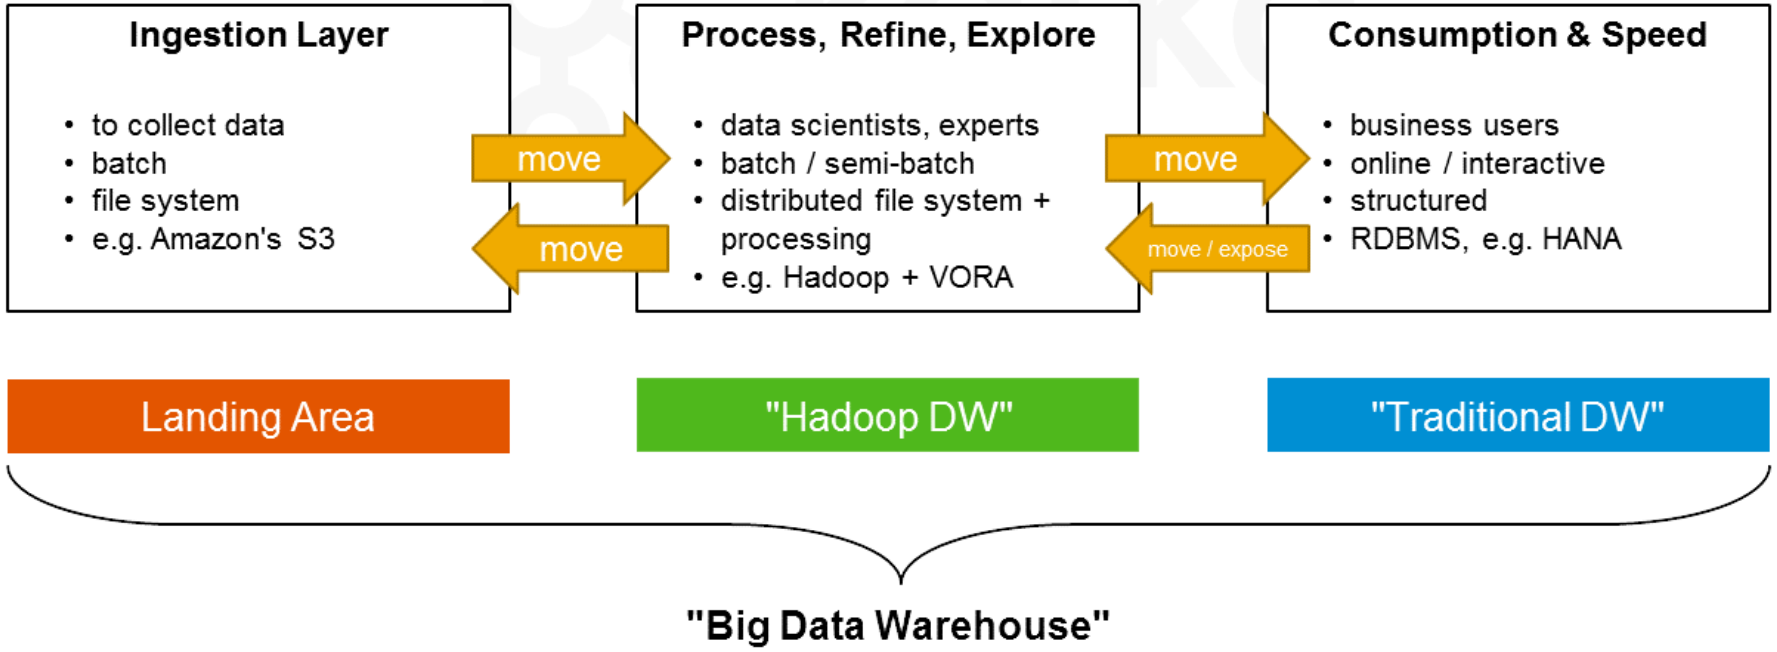


Copyright ETLForma – Tutti i diritti Riservati

# Layer di un'applicazione per big data

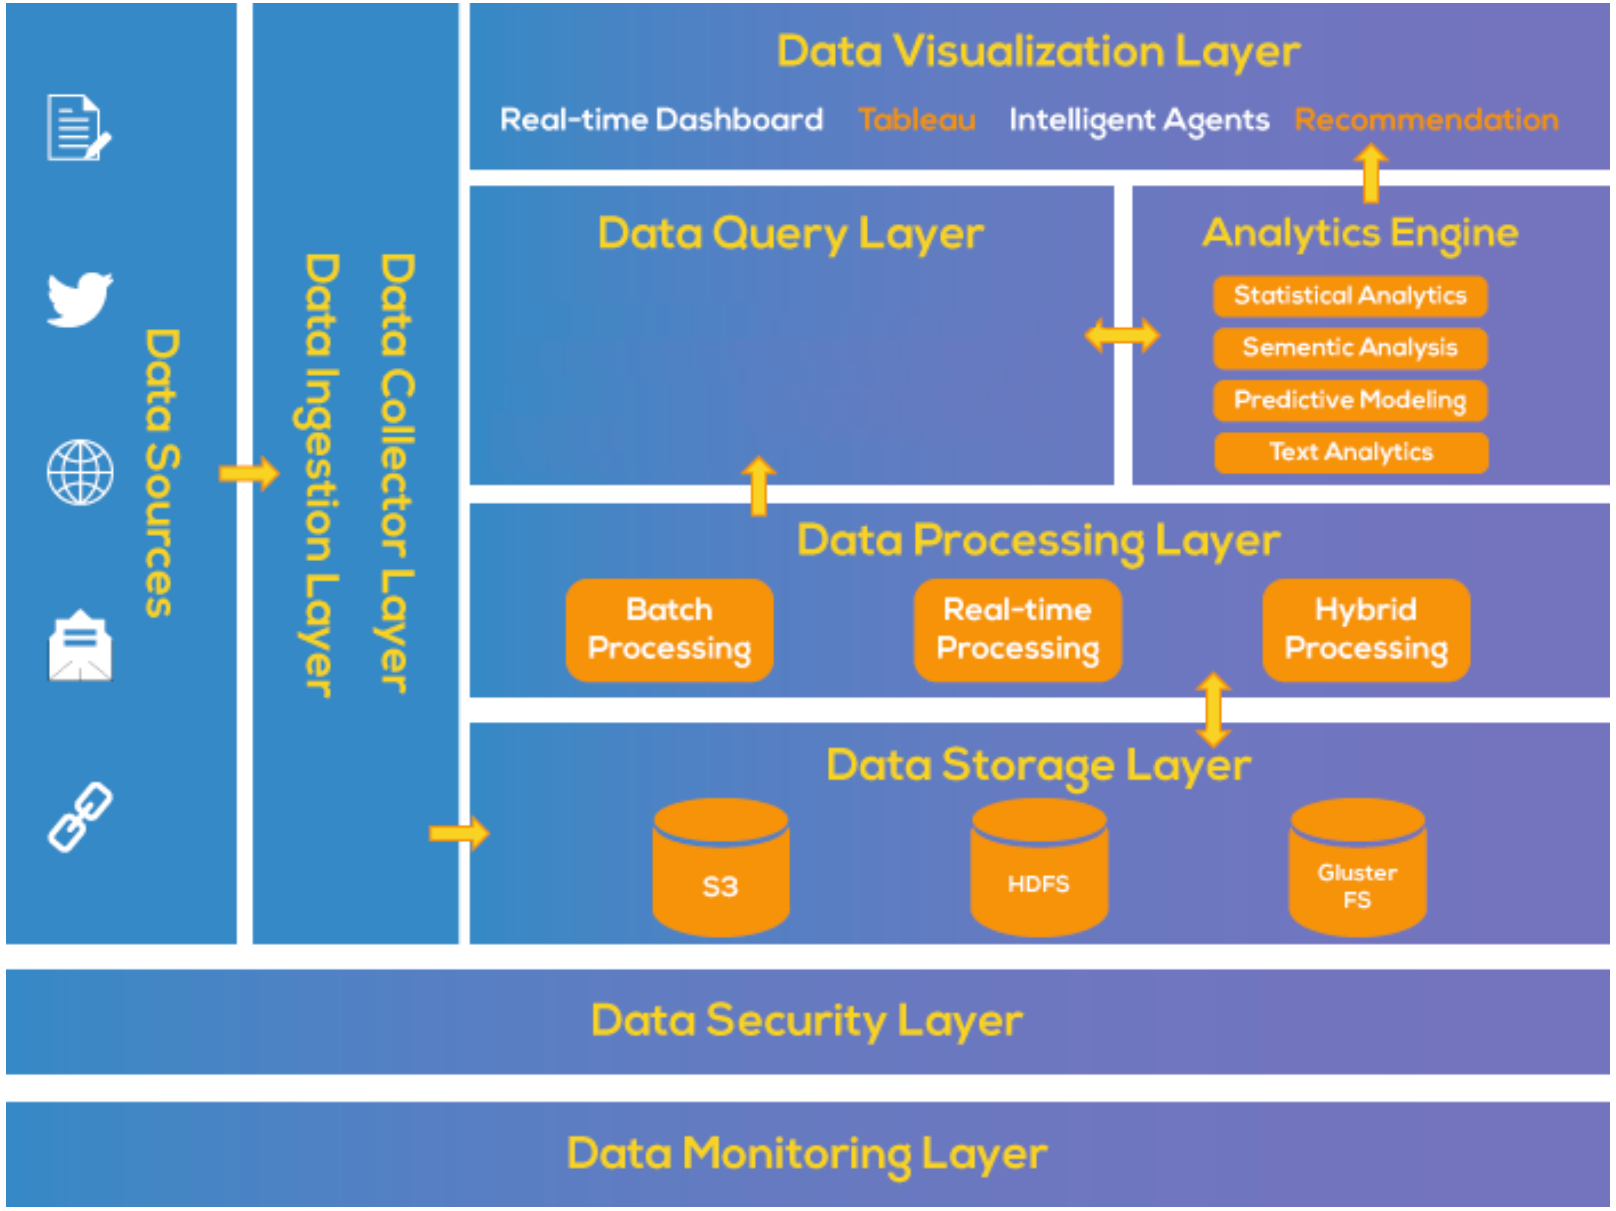


Copyright ETLForma – Tutti i diritti Riservati

# Ingestion layer

- I dati di input richiesti per l'elaborazione vengono «ingeriti» in sistemi di archiviazione; possono esservi molte fonti di dati per le quali è necessario eseguire la stessa o diversa elaborazione.

- Il livello di acquisizione elabora i dati in entrata, dando la priorità alle fonti, convalidando i dati e instradandoli nella posizione migliore per essere memorizzati ed essere pronti per l'accesso immediato.

- L'estrazione dei dati può avvenire in un singolo batch di grandi dimensioni o suddiviso in più piccoli; il livello di inserimento dati sceglierà il metodo in base alla situazione.

- Il layer dà la priorità a un tempo di caricamento più rapido e a ciò che è meglio per il programma.

Copyright ETLForma – Tutti i diritti Riservati

# Ingestion layer

- I dati di input richiesti per l'elaborazione vengono «ingeriti» in sistemi di archiviazione; possono esservi molte fonti di dati per le quali è necessario eseguire la stessa o diversa elaborazione.

- Il livello di acquisizione elabora i dati in entrata, dando la priorità alle fonti, convalidando i dati e instradandoli nella posizione migliore per essere memorizzati ed essere pronti per l'accesso immediato.

- L'estrazione dei dati può avvenire in un singolo batch di grandi dimensioni o suddiviso in più piccoli; il livello di inserimento dati sceglierà il metodo in base alla situazione.

- Il layer dà la priorità a un tempo di caricamento più rapido e a ciò che è meglio per il programma.

Copyright ETLForma – Tutti i diritti Riservati

# Data Collector Layer

- In questo livello, maggiore attenzione è rivolta al trasporto di dati dal livello di importazione al resto della pipeline di dati.

- È lo strato, in cui i componenti sono disaccoppiati in modo che possano inizializzare le capacità analitiche.

Copyright ETLForma – Tutti i diritti Riservati

# Processing layer

- Contiene la business logic che elabora i dati ricevuti nel livello di importazione e applica trasformazioni per portare i dati stessi in una forma utilizzabile.
- Il suo scopo è quindi quello di convertire i dati grezzi in informazioni.
- Possono esistere più applicazioni di elaborazione per dati uguali o diversi.
- Ogni applicazione può avere una logica e capacità di elaborazione diverse.

Copyright ETLForma – Tutti i diritti Riservati

# Consumption layer

- Questo livello contiene i dati elaborati dal livello di elaborazione.
- I dati elaborati sono un unico punto di verità e contengono informazioni importanti per le decisioni aziendali.
- Possono esistere più consumatori che possono utilizzare gli stessi dati per scopi diversi o dati diversi per lo stesso scopo.

Copyright ETLForma – Tutti i diritti Riservati

# Uso di messaging systems in big data streaming applications

- Le applicazioni di streaming probabilmente rientrerebbero nel secondo livello, il livello di elaborazione.

- Gli stessi dati possono essere utilizzati da molte applicazioni contemporaneamente e possono sussistere diversi modi di fornirli alle applicazioni.

- Pertanto, le applicazioni possono essere in streaming, batch o micro-batch.

- Tutte le applicazioni coinvolte consumano i dati in diversi modi:

  - le applicazioni di streaming possono richiedere dati come flusso (stream) continuo
  - le applicazioni batch possono richiedere dati come batch.

Copyright ETLForma – Tutti i diritti Riservati

# Uso di messaging systems in big data streaming applications

- In questo ambito possono esservi molteplici casi d'uso sia per i producer che per i consumer di dati; il contesto favorisce quindi l'adozione di un sistema di messaggistica.

- Lo stesso messaggio può essere utilizzato da più consumer, quindi è necessario conservare il messaggio fino a quando tutti i consumer lo abbiano ricevuto.

- L'esigenza è quella di avere un sistema di messaggistica in grado di

  - Conservare i dati fino a quando non li vogliamo
  - Offrire un alto grado di tolleranza agli errori
  - Fornire un modo diverso di consumare flussi di dati, batch e micro-batch

Copyright ETLForma – Tutti i diritti Riservati

# Punti di forza di un messaging systems - High consuming rate

- Le origini dati in streaming possono avere varia natura e sono inquadrati in un contesto in cui la velocità di produzione dei messaggi è troppo elevata.

- È possibile che le applicazioni di *streaming* possano o meno richiedere un consumo simile.

- È possibile che si desideri disporre di una coda di messaggistica in grado di utilizzare i dati a una velocità maggiore.

Copyright ETLForma – Tutti i diritti Riservati

# Punti di forza di un messaging systems - Guaranteed delivery

- Alcune applicazioni di streaming non possono permettersi di perdere messaggi;
- Abbiamo bisogno di un sistema che garantisca la consegna dei messaggi all'applicazione di streaming ogni volta che è necessario.

Copyright ETLForma – Tutti i diritti Riservati

# Punti di forza di un messaging systems - Persisting capability

- Possono sussistere casi di più applicazioni che consumano dati simili ma a una velocità diversa.

- È possibile che si desideri disporre di un sistema di messaggistica che conservi i dati per un periodo di tempo e li fornisca a un'applicazione diversa in modo asincrono.

- Questo aiuta a disaccoppiare tutte le applicazioni e a progettare un'architettura a micro-servizi.

Copyright ETLForma – Tutti i diritti Riservati

# Punti di forza di un messaging systems - Security

- Alcune applicazioni richiedono sicurezza sui dati che consumano
- Applicazioni potrebbero non voler condividere, come specifica, alcuni dati con altre che utilizzano lo stesso sistema di messaggistica.
- Si desidera un sistema che garantisca la sicurezza in generale.

Copyright ETLForma – Tutti i diritti Riservati

# Punti di forza di un messaging systems - Fault tolerance

- Le applicazioni non possono poggiare su sistemi che non recapitino messaggi o dati ogni qualvolta che li richiedono.

- Un sistema deve garantire la tolleranza agli errori e, in particolare, a fronte del fallimento di un server non vi deve essere perdita di informazioni e quindi i messaggi dovranno e potranno essere consegnati lo stesso.

Copyright ETLForma – Tutti i diritti Riservati

# UNIT 2

## Il Messaging

# Il Messaging

- Parlare di messaging «sembra tanto anni Novanta», eppure molte delle soluzioni e delle architetture «moderne» hanno alla base delle applicazioni frammentate in microservizi dove le soluzioni per far convivere l'IT vecchia e nuova sono basate concettualmente proprio sui paradigmi del messaging (…ovviamente convertiti alla visione del Terzo Millennio…)

- Apache Kafka nasce proprio come soluzione «fatta in casa» per collegare parti diverse dell'IT aziendale in seno a LinkedIn da un'idea di un gruppo di sviluppatori del social network stesso.

- Siamo nel 2008 e l'esigenza da risolvere è combinare la grande quantità di dati che arrivano sulla piattaforma online con le funzioni di analytics.

Copyright ETLForma – Tutti i diritti Riservati

# Il Messaging

- La parte transazionale è veloce e quella analitica anche; il problema da risolvere «è il miglioramento della comunicazione fra le due componenti».

- Gli sviluppatori di Likedin pensano che a collegarle debba essere un sistema di messaging che, nelle intenzioni, dovrebbe supportare le varie applicazioni di LinkedIn.

- Sul mercato non trovano soluzioni adeguate, da qui l'idea di creare un prodotto interno nuovo ovvero Kafka.

- Kafka nasce dalla ricerca di superare i limiti sperimentati in LinkedIn dai Team di Sviluppo.

Copyright ETLForma – Tutti i diritti Riservati

# Il Messaging

- E’ sempre un sistema di messaging ma secondo i suoi creatori è stato progettato col fine di gestire un flusso continuo di messaggi in grandi volumi

- Un’esigenza che le tradizionali piattaforme di messaging non si erano poste e che rende invece il nuovo progetto adatto ad applicazioni come quelle di IoT e tutte quelle in real-time.

- I suoi progettisti lo hanno pensato con natura estremamente distribuita e con lo storage dei messaggi (necessario a garantirne l’arrivo anche in infrastrutture in cui non sempre i nodi riceventi sono attivi).

- Inoltre hanno previsto la possibilità di operare direttamente sui messaggi con funzioni di organizzazione, trasformazione e selezione senza richiedere altri elementi esterni.

Copyright ETLForma – Tutti i diritti Riservati

# Il problema di Linkedin

Copyright ETLForma – Tutti i diritti Riservati

# Il problema di Linkedin

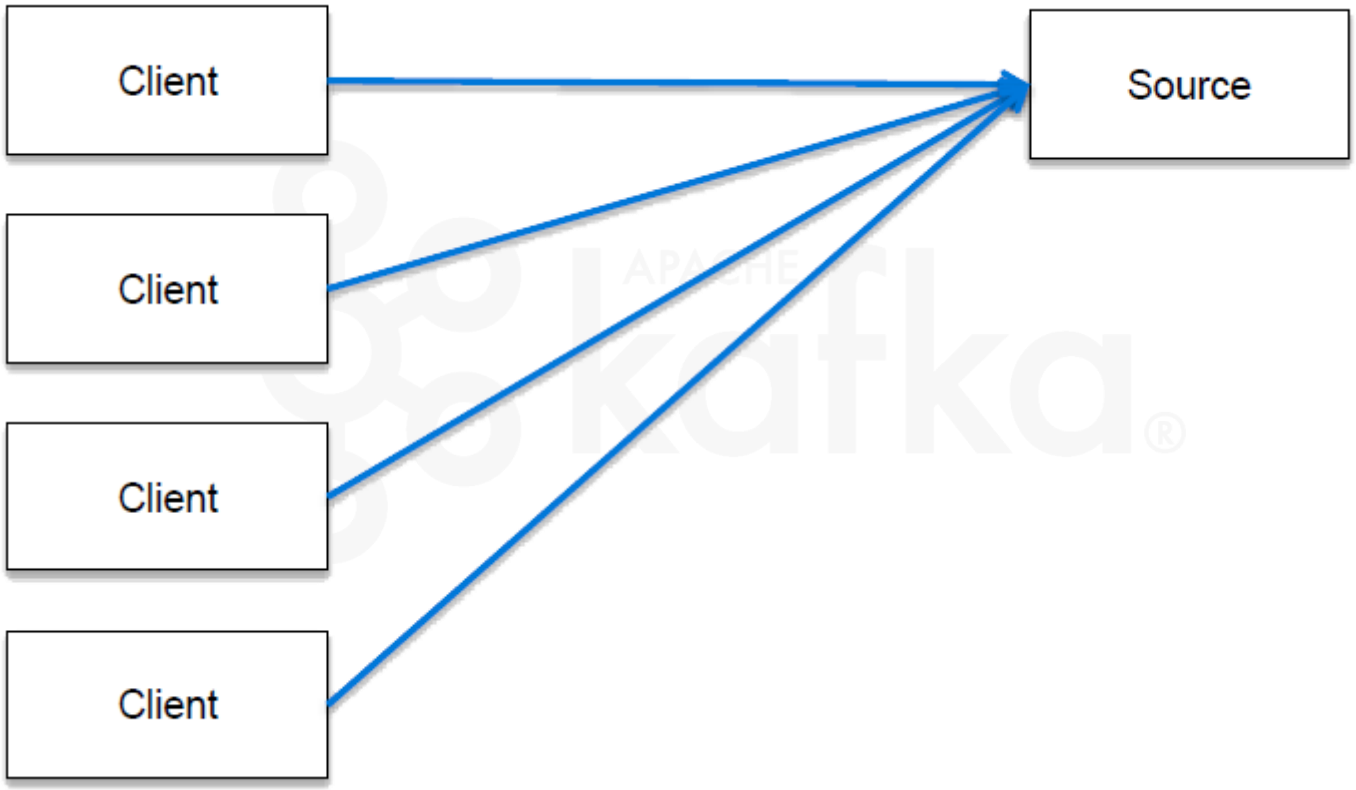


Copyright ETLForma – Tutti i diritti Riservati

# Il problema di Linkedin

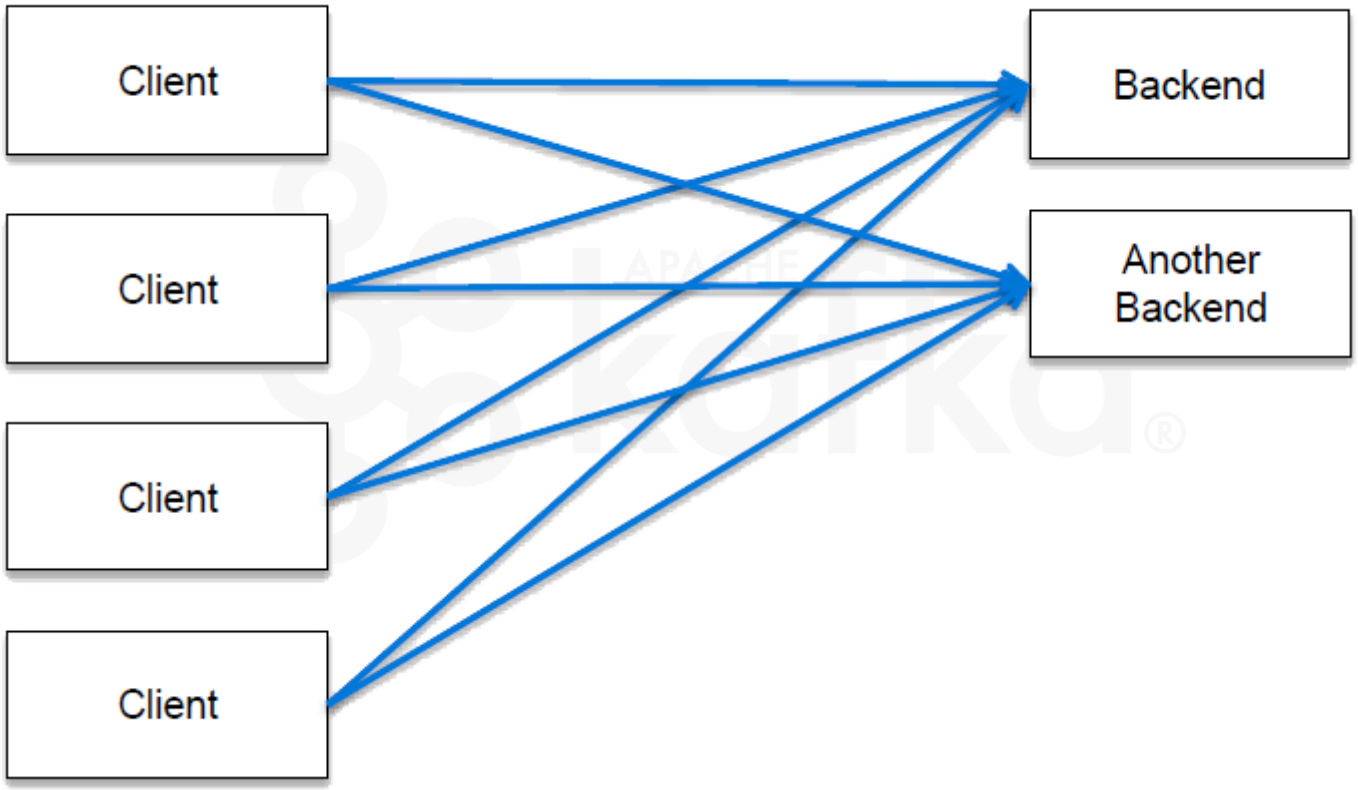


Copyright ETLForma – Tutti i diritti Riservati

# Il problema di Linkedin

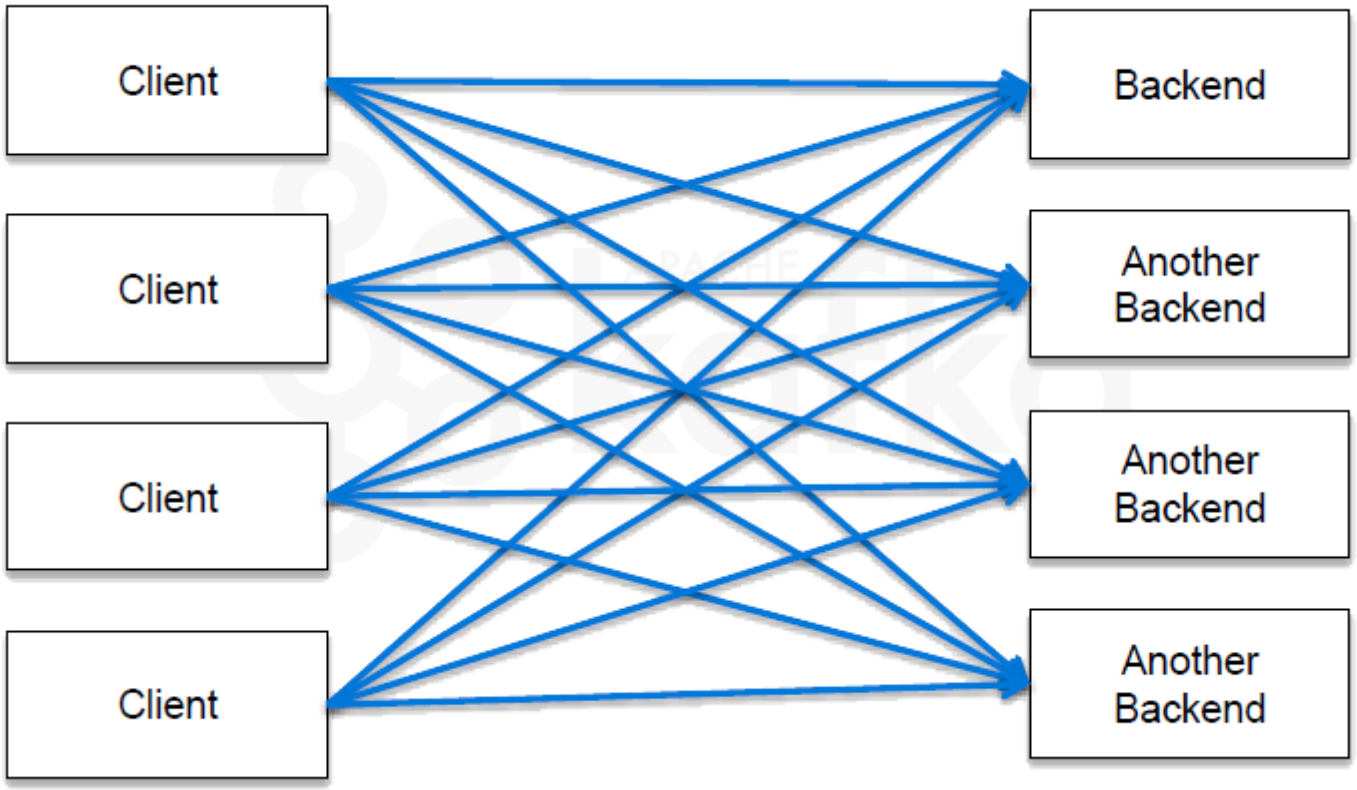


Copyright ETLForma – Tutti i diritti Riservati

# Il problema di Linkedin

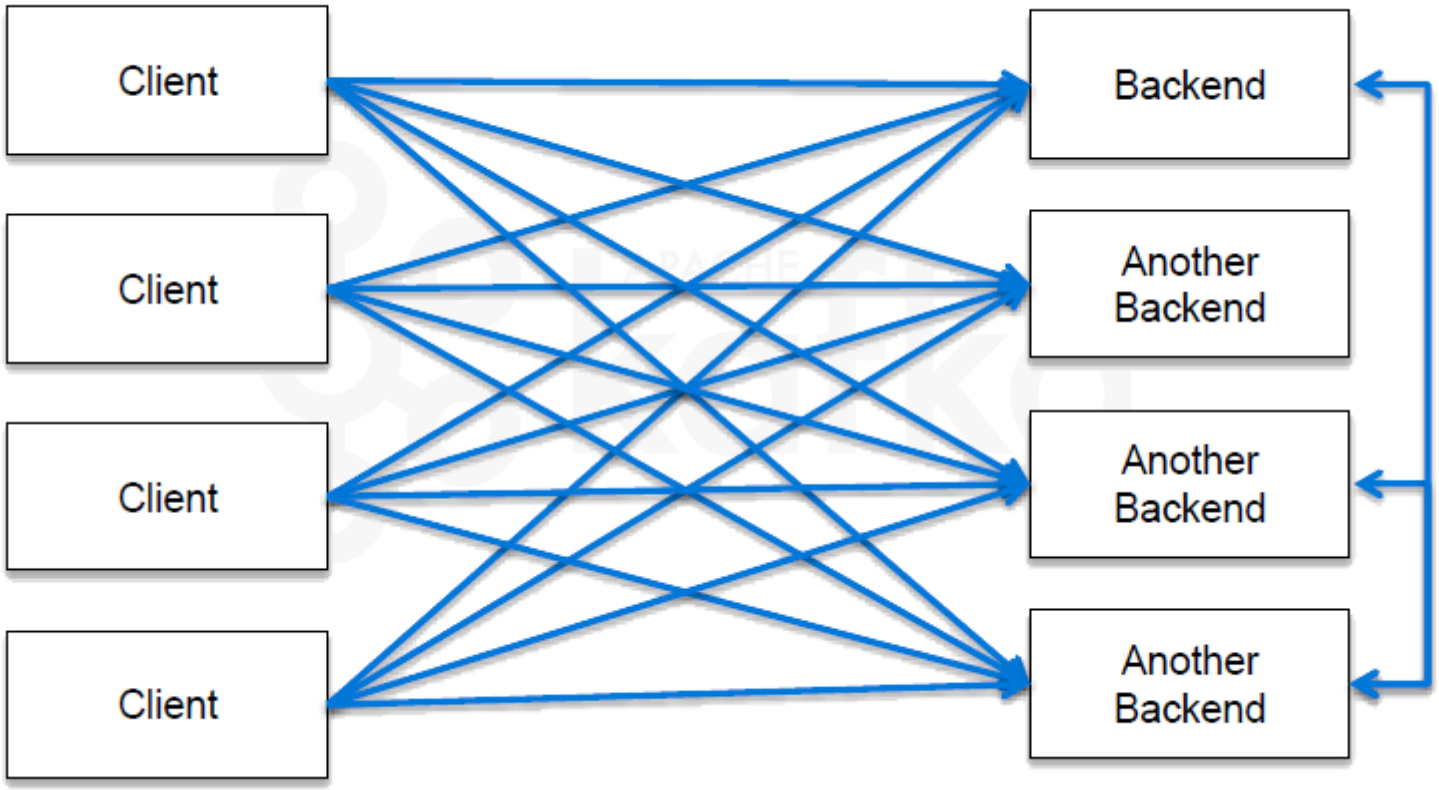


Copyright ETLForma – Tutti i diritti Riservati

# La soluzione di Linkedin

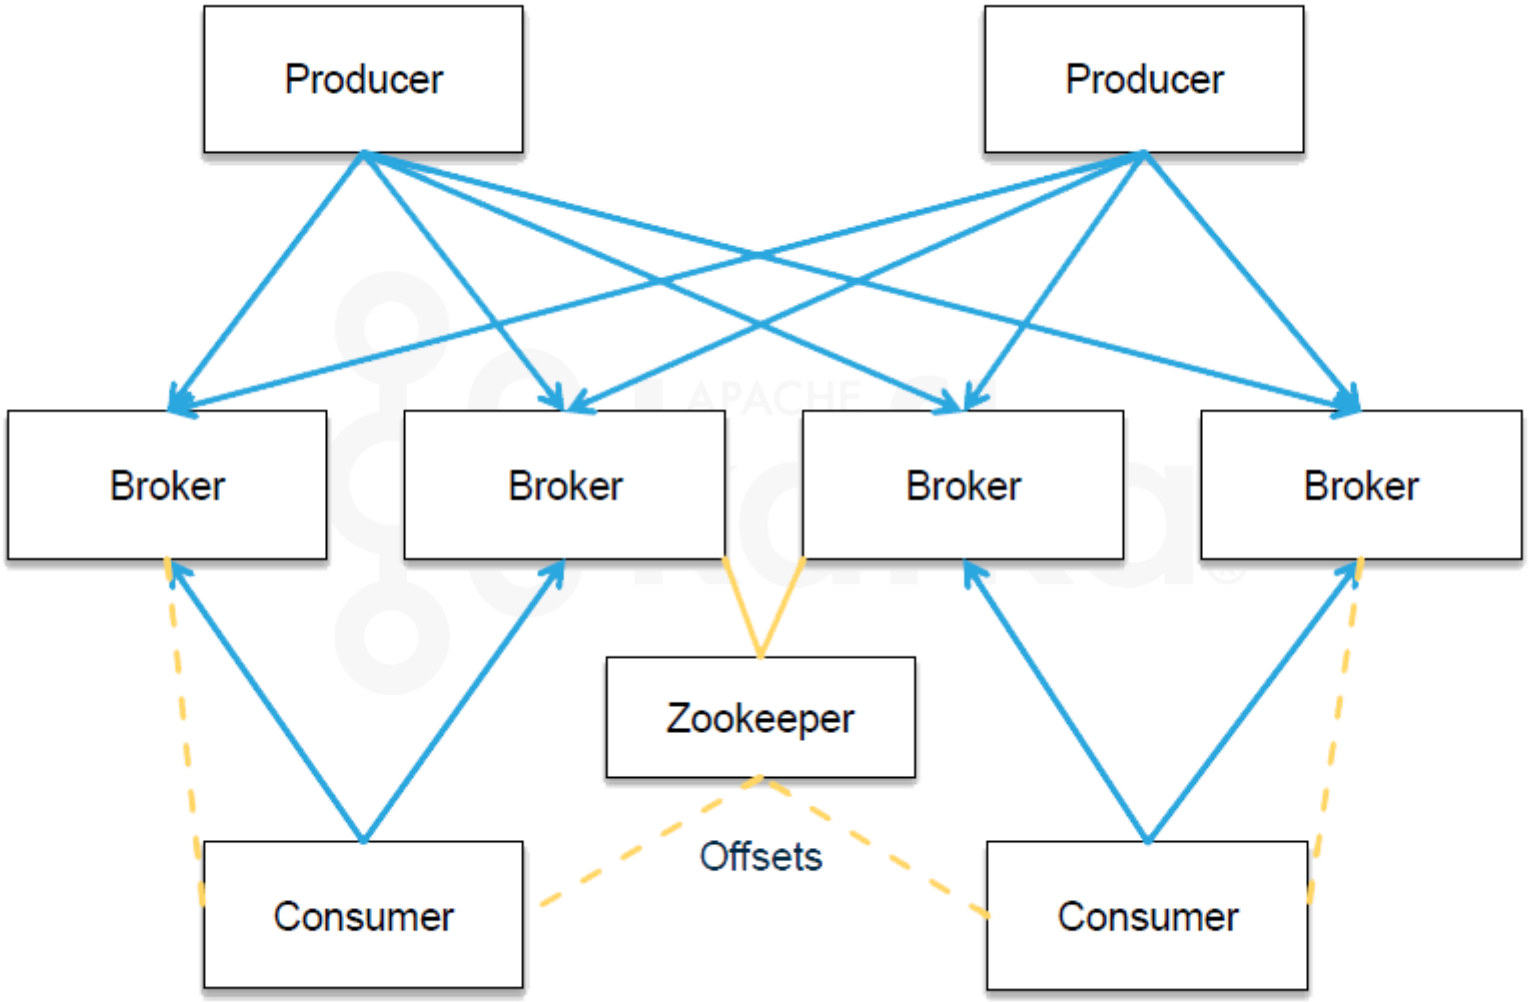


Copyright ETLForma – Tutti i diritti Riservati

# Kafka Enterprise Architecture

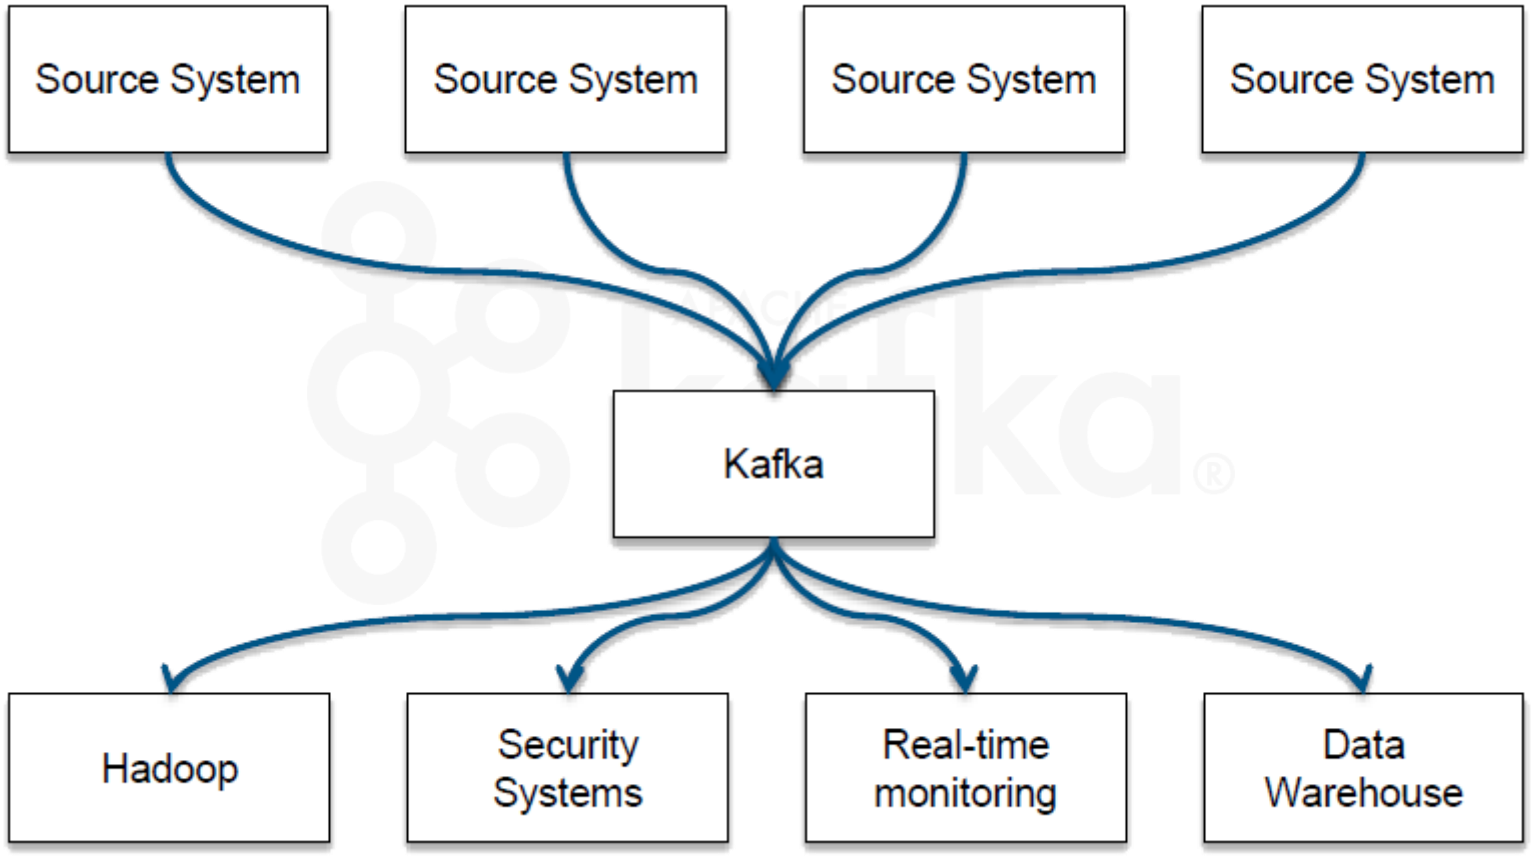


Copyright ETLForma – Tutti i diritti Riservati

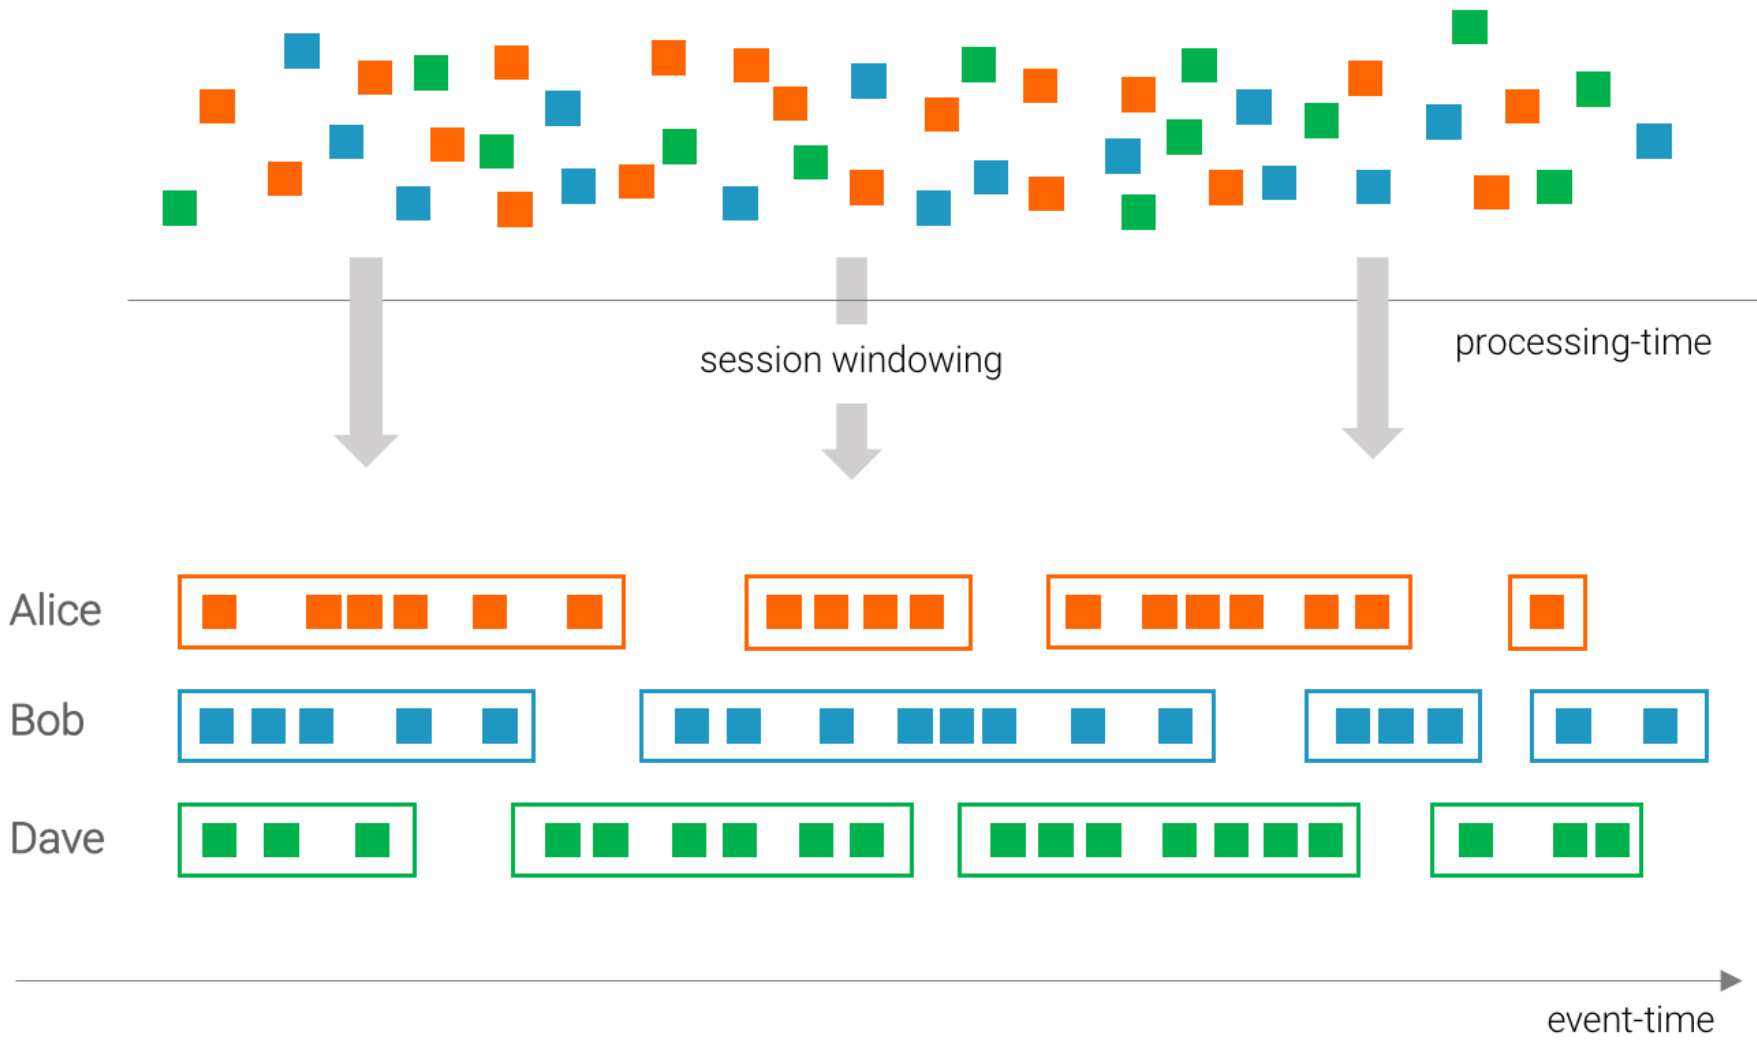


**Input data**

Colors represent different users event

**Results**

User sessions, grouped by event-time session windows

Copyright ETLForma – Tutti i diritti Riservati

# L'importanza dello streaming

- Per i creatori di Kafka (che hanno poi fondato una loro società, Confluent) è la **gestione dello streaming dei dati** il punto chiave per il futuro della piattaforma.

- L'idea è che gran parte delle imprese si stia muovendo verso ambienti con streaming di dati in tempo reale e questo permetta a Kafka, con le sue varie evoluzioni, di diventare un asse portante per tutto lo sviluppo applicativo di queste realtà.

- Anche la transizione ai microservizi viene considerata un fattore di accelerazione per Kafka (non in tutte le realtà, ma laddove i microservizi vengono usati per la gestione di eventi asincroni certamente sì).

Copyright ETLForma – Tutti i diritti Riservati

# L'importanza dello streaming in ecosistemi a microservizi

- Avere servizi asincroni introduce la possibilità che eventi o informazioni si perdano, una piattaforma nata proprio per garantire la certezza della consegna dei messaggi risolve il problema (o perlomeno intende farlo).

- Nell'evoluzione di Kafka, Confluent ha aggiunto il passo in più (in termini di componenti e soluzioni) che ne sta agevolando la diffusione.

- Confluent propone, inoltre, «Kafka as a Service» attraverso un servizio cloud, togliendo alle aziende utenti il peso dell'implementazione e portandole direttamente alla fase di sviluppo.

Copyright ETLForma – Tutti i diritti Riservati

# UNIT

Kafka

# Apache Software Foundation

- L'Apache Software Foundation (**ASF**) è una fondazione no-profit, costituita nel giugno 1999
- La storia di ASF è collegata al suo web server HTTP Apache, il cui sviluppo è iniziato nel 1994
- In pratica un gruppo di otto sviluppatori (in seguito definito Apache Group ) iniziò a lavorare al miglioramento del demone HTTPd dell'NCSA

Copyright ETLForma – Tutti i diritti Riservati

# Apache Software Foundation

- È una community distribuita di sviluppatori che lavorano su progetti software open source.

- I progetti sono caratterizzati da un processo di sviluppo distribuito, collaborativo e basato sul consenso molto simile al progetto wikipedia; ciascun progetto è gestito da un team di volontari che sono i contributori attivi al progetto stesso.

Copyright ETLForma – Tutti i diritti Riservati

# Licenza Apache

- La Licenza Apache (d'ora in poi definita semplicemente con **AL** = Apache License) è una licenza di software libero non copyleft scritta dalla **ASF** che obbliga gli utenti a preservare l'informativa di diritto d'autore e d'esclusione di responsabilità nelle versioni modificate.

- Tutti i software realizzati dalla ASF sono licenziati secondo i termini della LA.

- Qualsiasi azienda può rilasciare software adottando la LA come modello.

Copyright ETLForma – Tutti i diritti Riservati

# Licenza Apache

- Consente agli utenti di:
  - Usare il software per ogni scopo
  - Distribuirlo
  - Modificarlo
  - Distribuire versioni modificate dello stesso

- Non richiede che versioni modificate del software siano distribuite secondo i termini della stessa licenza o come software libero ma solo che si includa un'informativa del fatto che si è utilizzato software licenziato secondo i termini della AL.

Copyright ETLForma – Tutti i diritti Riservati

# Licenza Apache

- E’ una licenza permissiva la cui principale condizione è quella di preservare le note sul copyright e la licenza stessa.

- Ai contributori è fornita una esplicita concessione sui brevetti.

- L'opera, le sue modifiche, o lavori più estesi basati su di essa **possono essere distribuiti con una licenza diversa**, anche proprietaria e anche senza codice sorgente.

| Permissions | Conditions | Limitations |
|---|---|---|
| Brevetti | Cambiamenti | Garanzia |
| Distribuzione | Licenza e Copyright | Responsabilità |
| Modifiche | | Uso Trademark |
| Uso Commerciale | | |
| Uso Privato | | |

Copyright ETLForma – Tutti i diritti Riservati

# Licenza Apache

- Comparazione licenze: https://www.linux.it/scegli-una-licenza/licenses/

- **Nota**: L'Apache Software Foundation e la Free Software Foundation (FSF) hanno concordato che la Licenza Apache 2.0 è una licenza di software libero compatibile con la versione 3 della GNU General Public License (GPL), il che significa che il codice sotto licenza GPL versione 3 e Apache License 2.0 possono essere combinati, ed il codice risultante è sotto licenza GPL versione 3.

Copyright ETLForma – Tutti i diritti Riservati

- **Apache Kafka** è «un sistema di **messaggistica di pubblicazione-sottoscrizione** ad alta produttività (high throughput) implementato come servizio di registro di commit distribuito, partizionato e replicato».

- In altri termini è un sistema open source di **messaggistica istantanea** che consente la gestione di un elevato numero di operazioni in tempo reale da migliaia di client, sia in lettura che in scrittura.

- La piattaforma si dimostra ideale per la progettazione di applicazioni di alta fascia.

- Apache Kafka è una piattaforma di stream-processing distribuita scritta in Scala e in Java, inizialmente sviluppata da LinkedIn e divenuta open source a inizio 2011

Copyright ETLForma – Tutti i diritti Riservati

- Tra i punti di forza di Kafka vi sono l'incremento della produttività e l'affidabilità, fattori che hanno consentito al sistema di sostituire famosi broker di messaggistica come JMS e AMQP.

- Per un rapido apprendimento di Kafka è preferibile possedere una conoscenza approfondita di
  - Java
  - Scala
  - Linux.

Scalable Language

Copyright ETLForma – Tutti i diritti Riservati

# Caratteristiche salienti di Kafka (Tratte dal sito ufficiale)

- **Veloce**: Un singolo broker Kafka può gestire centinaia di megabyte di letture e scritture al secondo da migliaia di client.

- **Scalabile**: Kafka è progettato per consentire a un singolo cluster di fungere da backbone centrale dei dati per una grande organizzazione. Può essere espanso elasticamente e in modo trasparente senza tempi di fermo (alta scalabilità). I flussi di dati sono partizionati e distribuiti su un cluster di macchine per consentire la «trasmissione» di grandi quantità di dati e per consentire cluster di consumer coordinati.

Copyright ETLForma – Tutti i diritti Riservati

# Caratteristiche salienti di Kafka (Tratte dal sito ufficiale)

- **Durevole**: I messaggi sono persistenti su disco e replicati all'interno del cluster per prevenire la perdita di dati. Ogni broker può gestire terabyte di messaggi senza impatto sulle prestazioni.

- **Distribuito**: Kafka ha un design moderno incentrato sul cluster che offre una lunga durata e garanzie di tolleranza agli errori.

Copyright ETLForma – Tutti i diritti Riservati

# Cosa offre Kafka

- La storia di Kafka inizia nel 2010, quando il celebre social LinkedIn sentì l'esigenza di affrontare le problematiche delle basse latenze inerenti alla gestione di grandi quantità di dati sul web.

- Considerando che in quel momento non vi erano soluzioni all'altezza, si decise di dare vita a una nuova piattaforma; in realtà avevano già delle tecnologie per l'elaborazione in batch, **ma non consentivano l'elaborazione dei dati in tempo reale**.

- Nello specifico Kafka è stato creato per risolvere il problema della pipeline di dati su LinkedIn.

- È stato progettato per fornire un sistema di messaggistica ad alte prestazioni in grado di gestire molti tipi di dati e fornire dati chiari e strutturati sull'attività degli utenti e le metriche di sistema in tempo reale.

Copyright ETLForma – Tutti i diritti Riservati

- Tra le sfide più importanti per un software di messaggistica vi è quella relativa all'**elaborazione di grandi volumi di dati**. Un efficiente sistema deve essere in grado di rendere immediatamente disponibili i dati agli utenti: ed è proprio questo che Kafka riesce a fare.

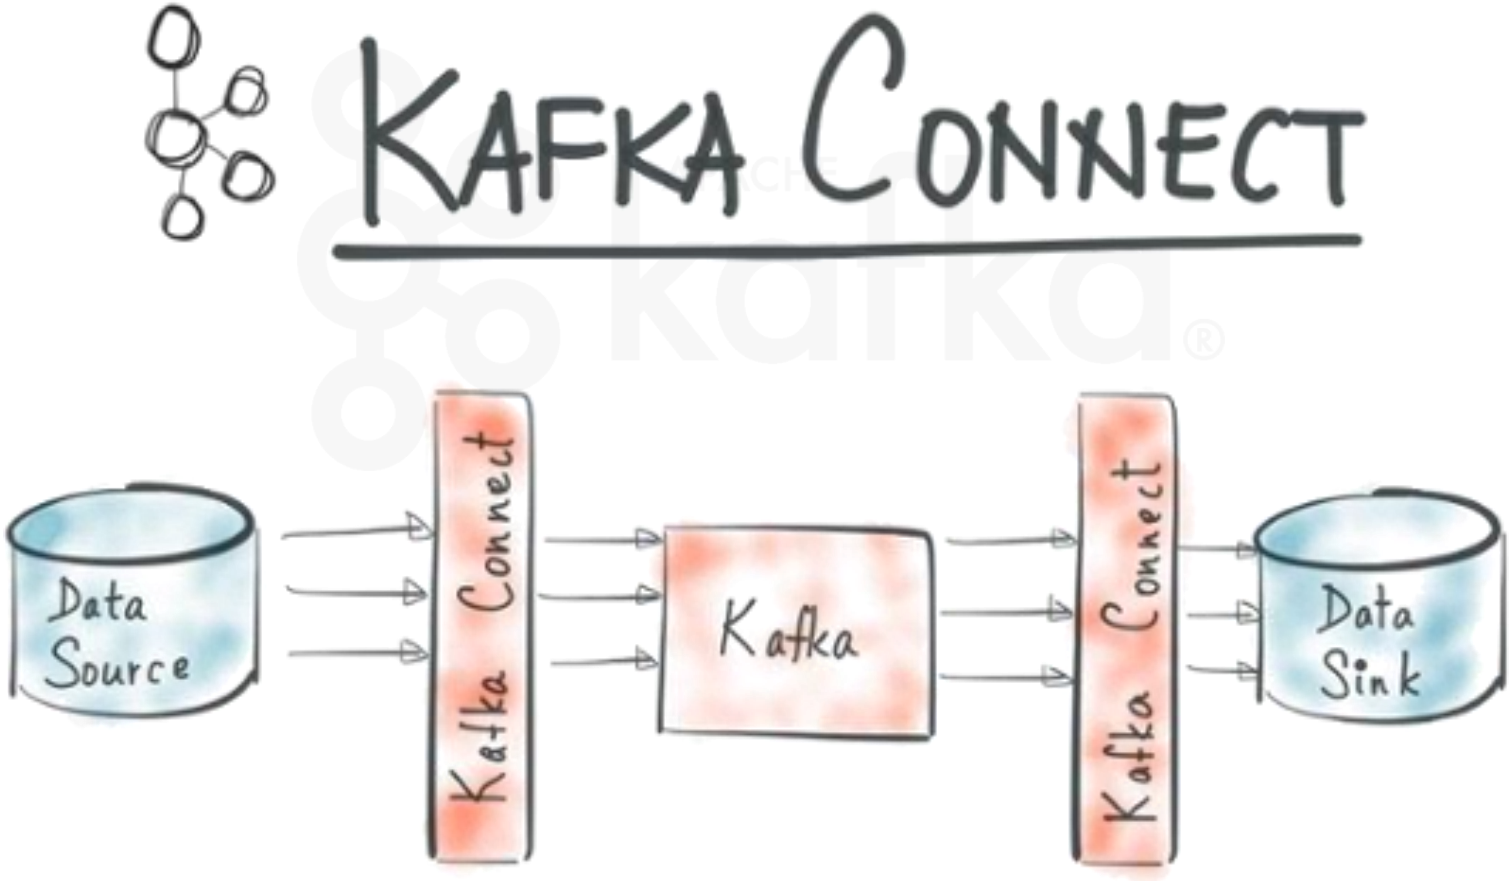


Copyright ETLForma – Tutti i diritti Riservati

# I Vantaggi

- Tra i vantaggi offerti dalla piattaforma vi sono:
  - Il monitoraggio delle attività sul web memorizzando e inviando i flussi di dati in tempo reale
  - La memorizzazione dei messaggi su hard disk per prevenire la perdita dei dati, con la facoltà di stabilire un preciso tempo di conservazione degli stessi
  - Il rilevamento delle minacce

Copyright ETLForma – Tutti i diritti Riservati

# I Vantaggi

- Kafka è generalmente integrato in ecosistemi software di tipo enterprise con Apache Storm, Apache HBase e Apache Spark.

- Il fine ovviamente è quello di **elaborare i dati in tempo reale e in streaming** con supporto ai flussi di messaggi al cluster di Hadoop (a prescindere dalla classe di utilizzo).

Copyright ETLForma – Tutti i diritti Riservati

# Kafka & Hadoop Software Ecosystem

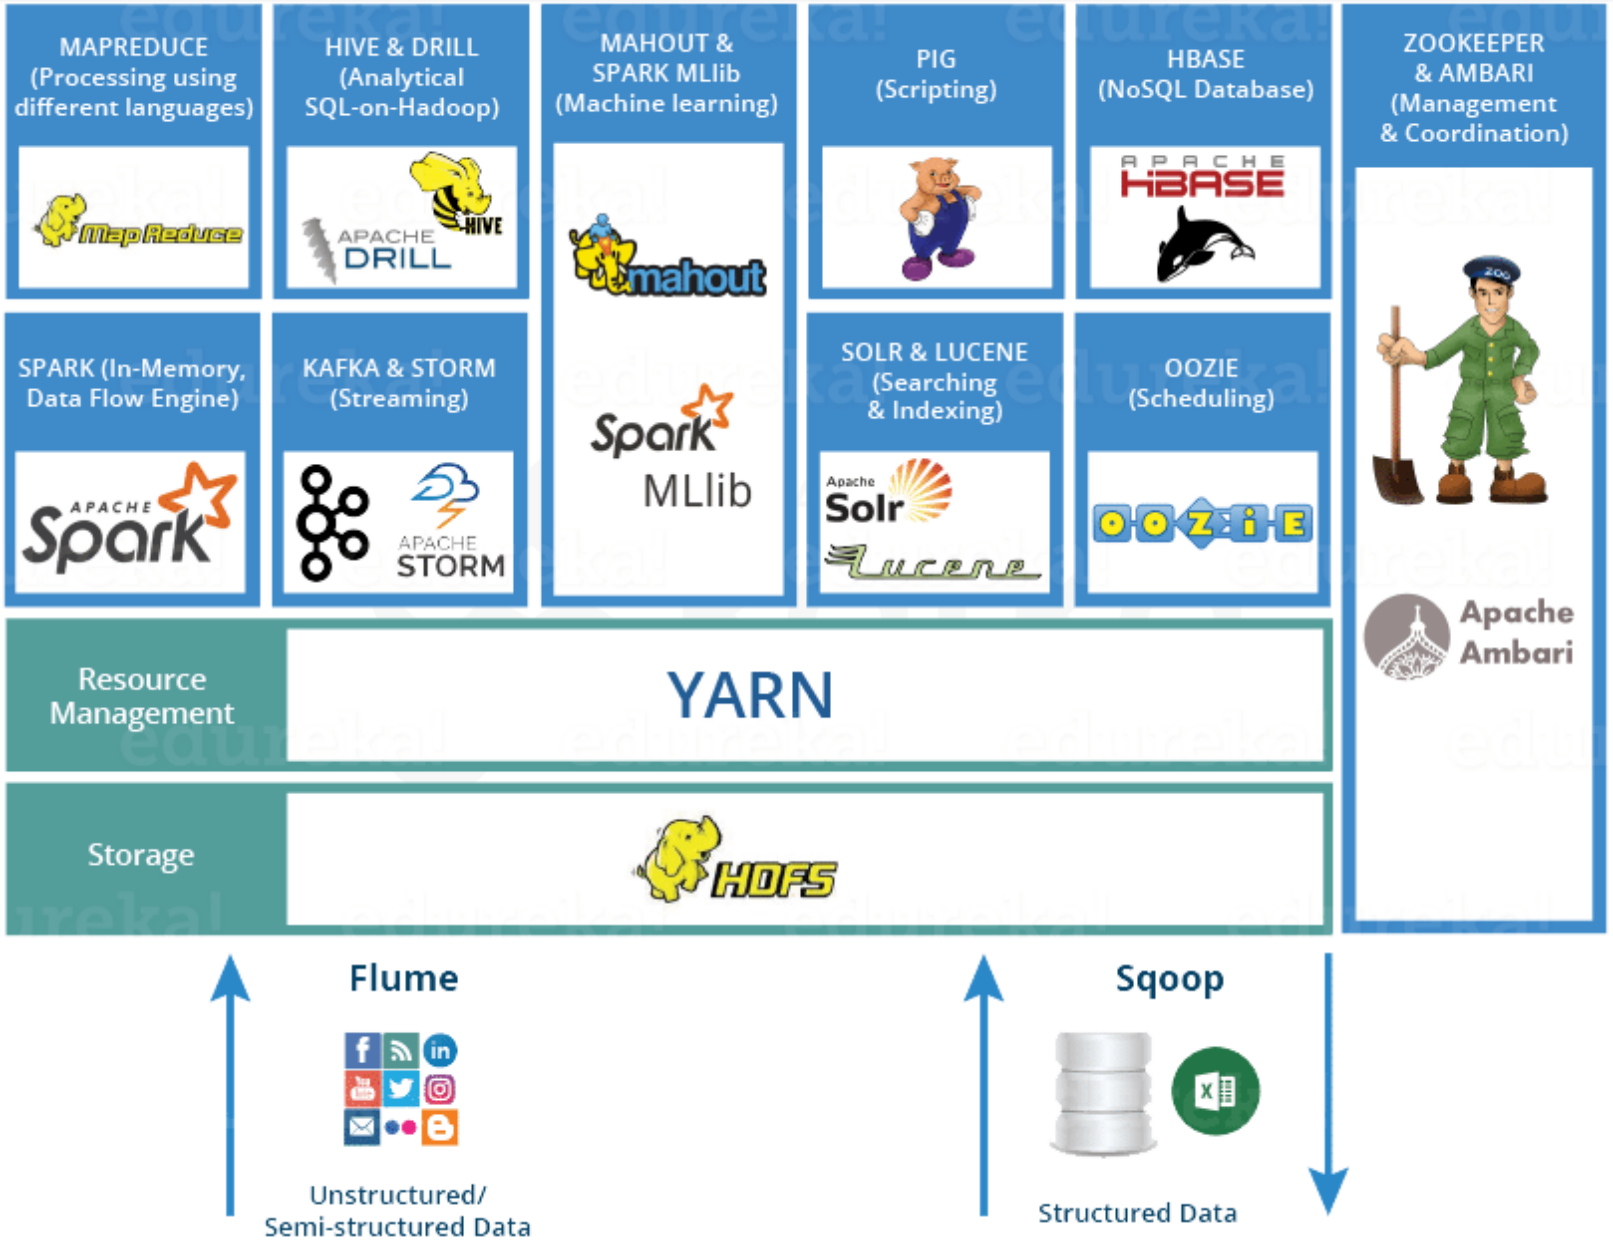


Copyright ETLForma – Tutti i diritti Riservati

# Cluster, Topic e Record

- Per quanto concerne il funzionamento, la piattaforma viene distribuita come **cluster** da installare su uno o più server.

- Il cluster ha la capacità di memorizzare vari topic, ovvero dei flussi di record.

- Ogni record contiene al suo interno tre dettagli:

  - una chiave
  - un valore
  - un timestamp.

Copyright ETLForma – Tutti i diritti Riservati

- L'architettura è basata su quattro API principali:
  - Producer API: permette alle applicazioni di pubblicare flussi in uno o più topic.
  - Consumer API: consente l'elaborazione dei topic e del flusso prodotto dai record.
  - Stream API: riceve un determinato input dai topic e produce degli output, convertendo i flussi.
  - Connector API: gestisce il collegamento tra varie applicazioni.

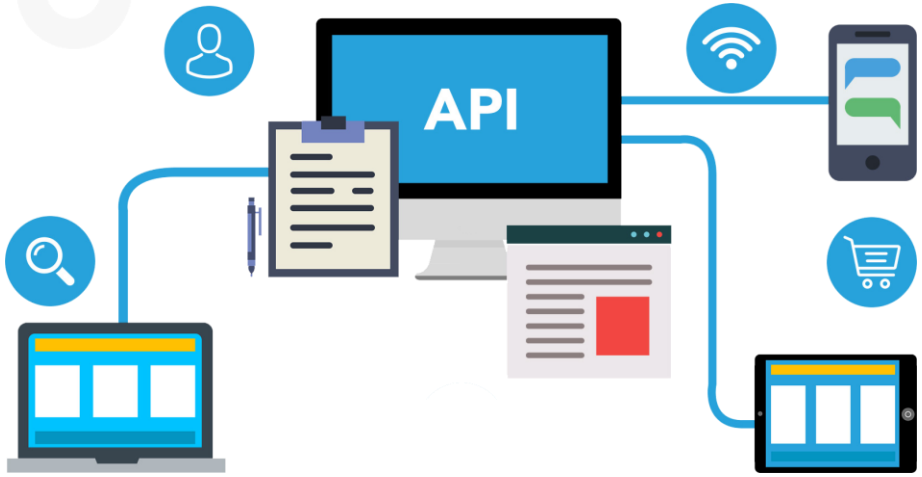


Copyright ETLForma – Tutti i diritti Riservati

# Concetti fondamentali

- TOPIC: è una sorta di categoria utilizzata per raggruppare i messaggi;
- PARTITION: ciascuna delle sottosezioni in cui è diviso un topic;
- RECORD: è il messaggio vero e proprio, costituito da una chiave, un valore e un timestamp;
- OFFSET: indice che identifica univocamente un record all'interno di una partizione;
- PRODUCER: entità che invia i messaggi a Kafka;
- CONSUMER: entità che riceve i messaggi da Kafka;

Copyright ETLForma – Tutti i diritti Riservati

# Concetti fondamentali

- GRUPPO: è un’etichetta utilizzata per distinguere insiemi di consumatori sottoscritti a un topic;

- BROKER: è un processo che si occupa di gestire la ricezione e il salvataggio dei messaggi e i relativi offset;

- CLUSTER: insieme di più broker utile per replicare e distribuire le partizioni.

Copyright ETLForma – Tutti i diritti Riservati

# Esempio di un Topic con tre Partitions

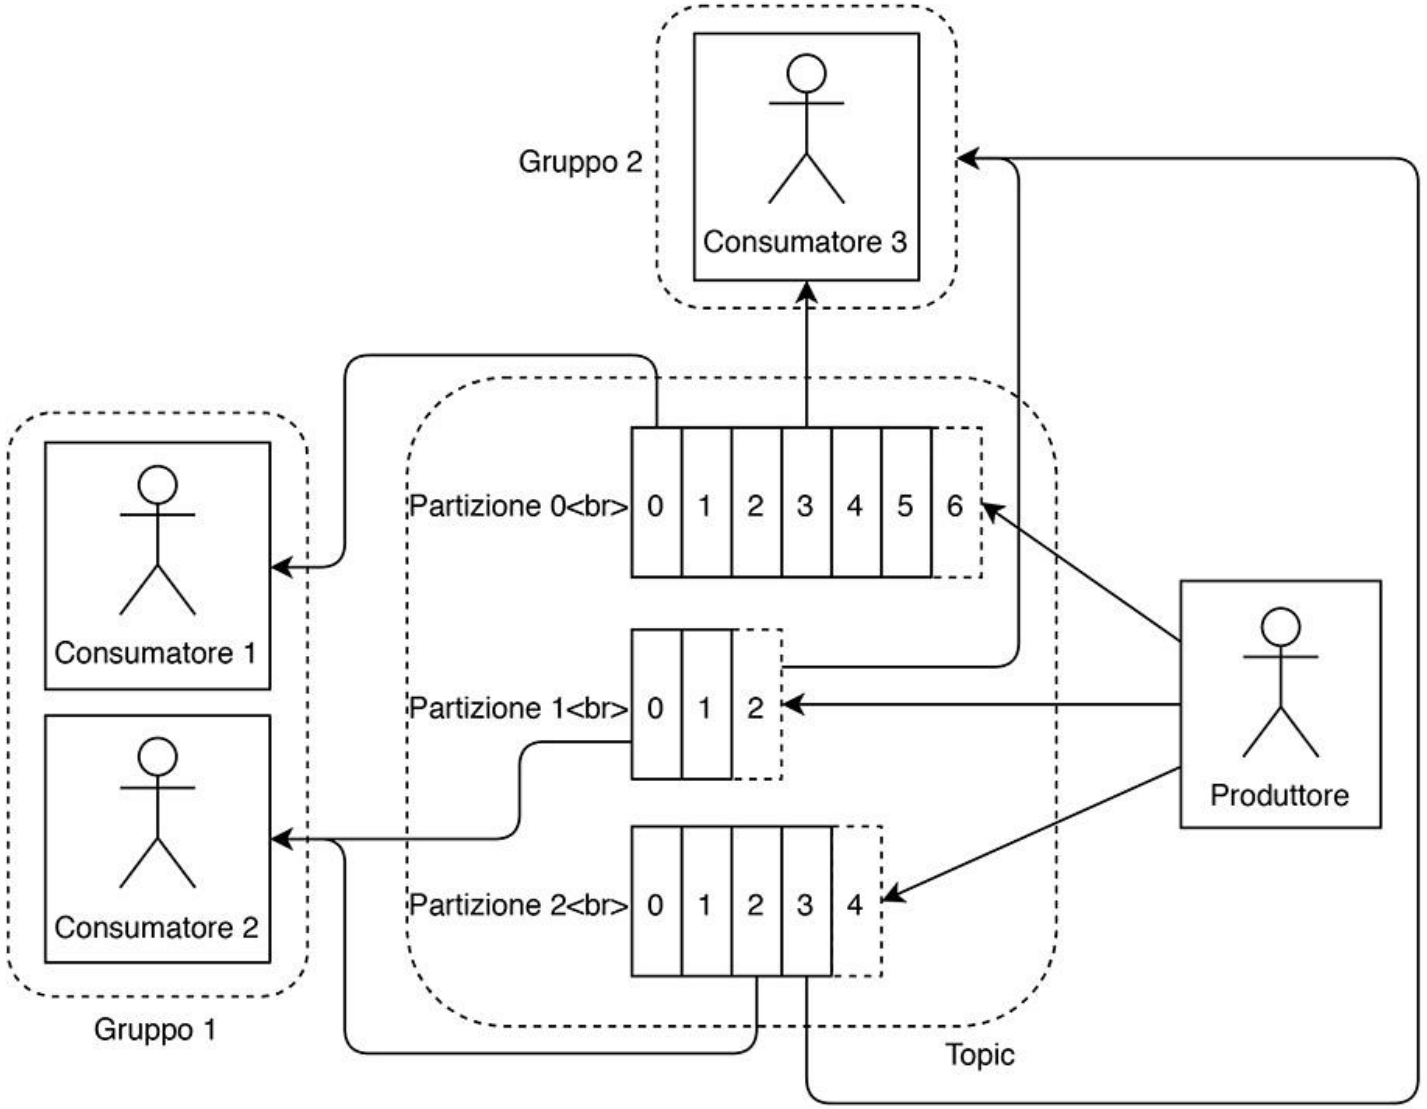


Copyright ETLForma – Tutti i diritti Riservati

# Topic e Partitions

- Ogni partizione contiene un numero variabile di record, ciascuno con il suo offset.
- La partizione a cui viene assegnato un messaggio è:
  - quella scelta dal produttore, se specificata al momento dell'invio;
  - quella ottenuta elaborando l'hash della chiave del record, se presente;
  - una qualsiasi secondo una logica di tipo round-robin, se il produttore non ha indicato né una partizione né una chiave per il messaggio.

Copyright ETLForma – Tutti i diritti Riservati

# Gruppi, Consumers e Partitions

- Se un gruppo è formato da più consumatori, le partizioni di un topic e i relativi record vengono distribuiti tra di essi.

- In particolare, detto C il numero di consumatori di un gruppo e P il numero di partizioni:
  - se C > P allora:
    - a P consumatori verrà assegnata una partizione
    - mentre C – P consumatori resteranno senza partizioni;
  - se C = P ciascun consumatore avrà una e una sola partizione;
  - se C < P le varie partizioni saranno distribuite in maniera uniforme tra i vari consumatori.

Copyright ETLForma – Tutti i diritti Riservati

# Gruppi, Consumers e Partitions

- Il bilanciamento delle partizioni è dinamico, ossia esse vengono redistribuite al momento della connessione o disconnessione dei consumatori.

- Come si può facilmente intuire le partizioni e i gruppi di consumatori sono gli elementi che permettono di scalare orizzontalmente un sistema.

- Nell'esempio mostrato precedentemente possiamo notare che:

  - il consumatore 1 riceve messaggi solo dalla partizione 0;
  - il consumatore 2 riceve messaggi dalle partizioni 1 e 2;
  - il consumatore 3 riceve messaggi da tutte le partizioni essendo l'unico membro del suo gruppo.

- È importante sottolineare che un consumatore non riceve mai automaticamente i messaggi, bensì deve richiederli esplicitamente quando è pronto a elaborarli.

Copyright ETLForma – Tutti i diritti Riservati

# UNIT

Casi D’Uso

# Casi D'Uso - IoT, sensor data analysis

- l'utilizzo di Kafka si colloca in un contesto in cui l'uso di sensori applicati a macchine industriali, autovetture e oggetti di uso comune sta crescendo enormemente.

- Offre infatti la possibilità di gestire le enormi quantità di dati generate dai sensori, con bassissima latenza.

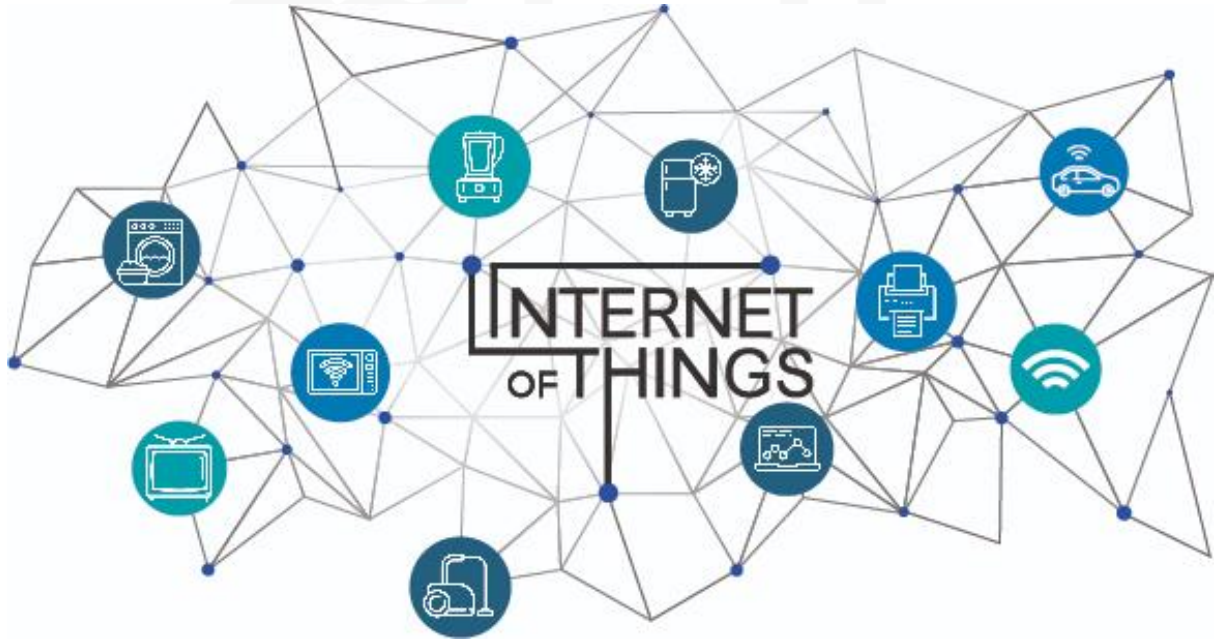


Copyright ETLForma – Tutti i diritti Riservati

# Casi D'Uso - Batch Processing —> Real time processing (BP Vs RP)

- Attraverso lo stream processing è possibile operare modifiche o trasformazioni dei dati durante il flusso.

- Non è quindi necessario affidarsi a un servizio esterno per gestire attività di storage e processing.

| Batch Processing | Real-Time Processing |
|---|---|
| The collection and storage of data, for processing at a scheduled time when a sufficient amount of data has been accumulated | The immediate processing of data after the transaction occurs, with the database being updated at the time of the event |
| Transactions Collected and Organised into Batches → Transaction File created → Transaction File stored → Master File updated at scheduled time periods | Transaction event occurring ⇄ Online computer database updating |
| **Examples:**<br>• Cheque Clearing<br>• Generation of Bills<br>• Credit Card Transactions | **Examples:**<br>• Reservation Systems<br>• Point of Sales Terminals (POS) |
| **Advantages / Disadvantages:**<br>• Many transactions are completed at one time in a single process<br>• Data takes time to be processed | **Advantages / Disadvantages :**<br>• Data is processed immediately<br>• The act of processing data is repetitive |

Copyright ETLForma – Tutti i diritti Riservati

# Casi D'Uso - Scalabilità e Fault-tolerance

- La velocità di elaborazione e il volume dei dati in entrata possono essere variabili, quindi è necessario poter manipolare la capacità di uno strumento di messaging per modulare le variabili di precisione o performance.

- Kafka è in grado di gestire tutto questo, e grazie alla persistenza dei dati all'interno dei cluster (anche questa gestibile dall'utente) garantisce anche un alto livello di fault tolerance.

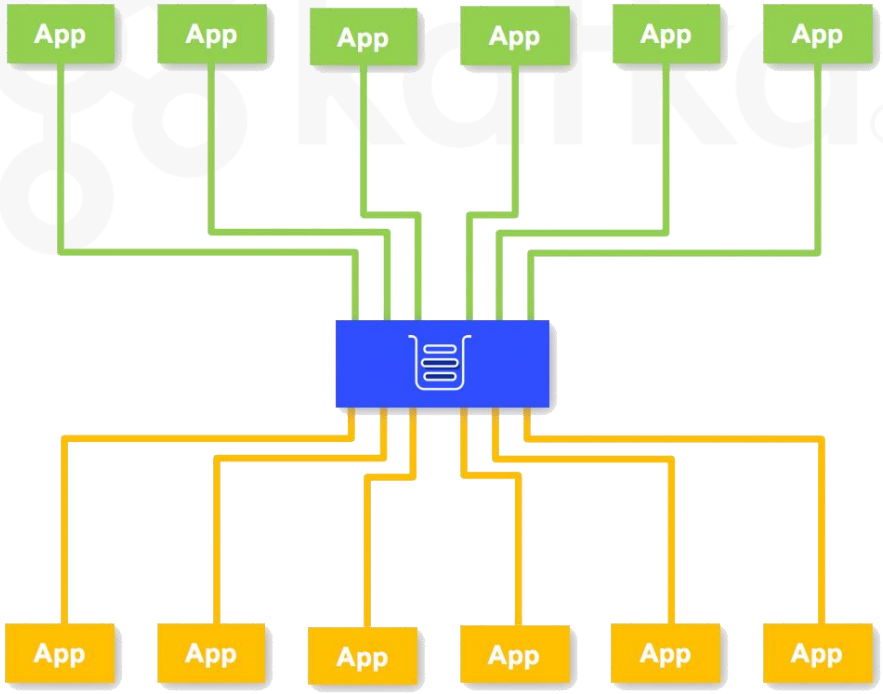


Copyright ETLForma – Tutti i diritti Riservati

# Casi D'Uso - Microservizi e comunicazione asincrona

- Kafka può essere utilizzato come strumento per lo scambio di messaggi asincroni in un ecosistema di microservizi.

- Velocizza le comunicazioni tra le applicazioni e riduce al minimo il rischio di perdita di informazioni

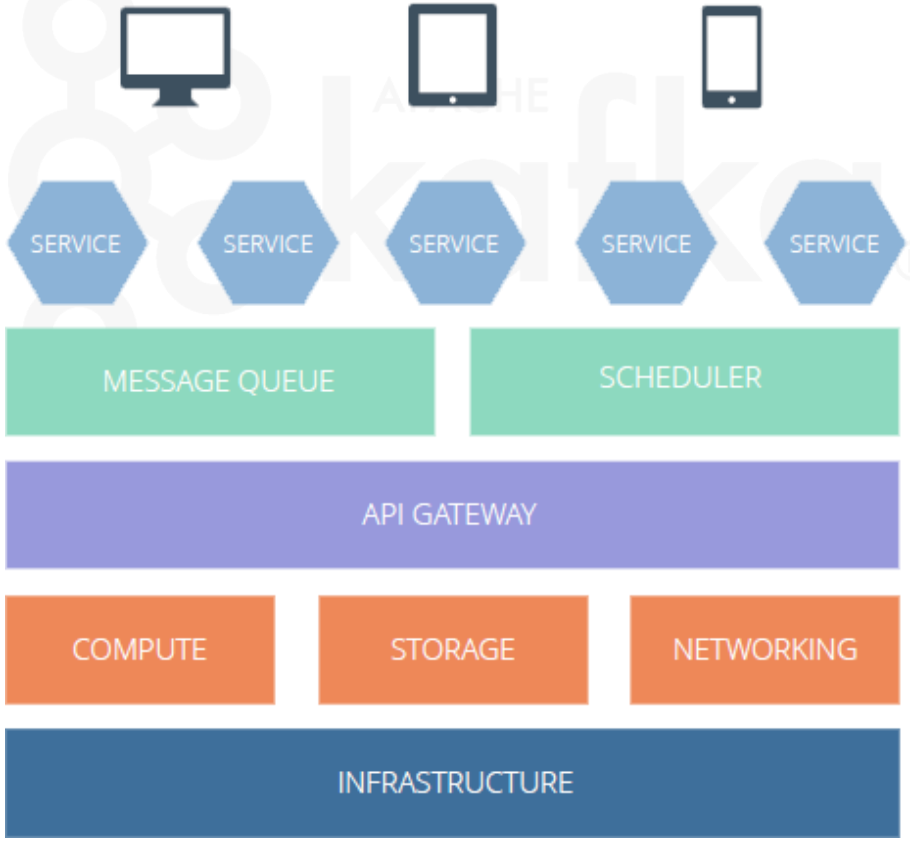


Copyright ETLForma – Tutti i diritti Riservati

# UNIT

Confluent

# Confluent

- Confluent è la soluzione opensource basata su Apache Kafka™, per costruire funzioni avanzate di Stream Data Processing.

- Ideata dai creatori di Kafka, la piattaforma migliora l'applicazione permettendogli di espandere le sue capacità di integrazione, in modo da aggiungere strumenti per ottimizzare, gestire i cluster e garantire la sicurezza dei flussi di dati.

- Confluent rende Kafka più facile da configurare e più facile da usare, ed è disponibile in licenza Open Source ed Enterprise, tramite un abbonamento dedicato.

Copyright ETLForma – Tutti i diritti Riservati

# Confluent Platform

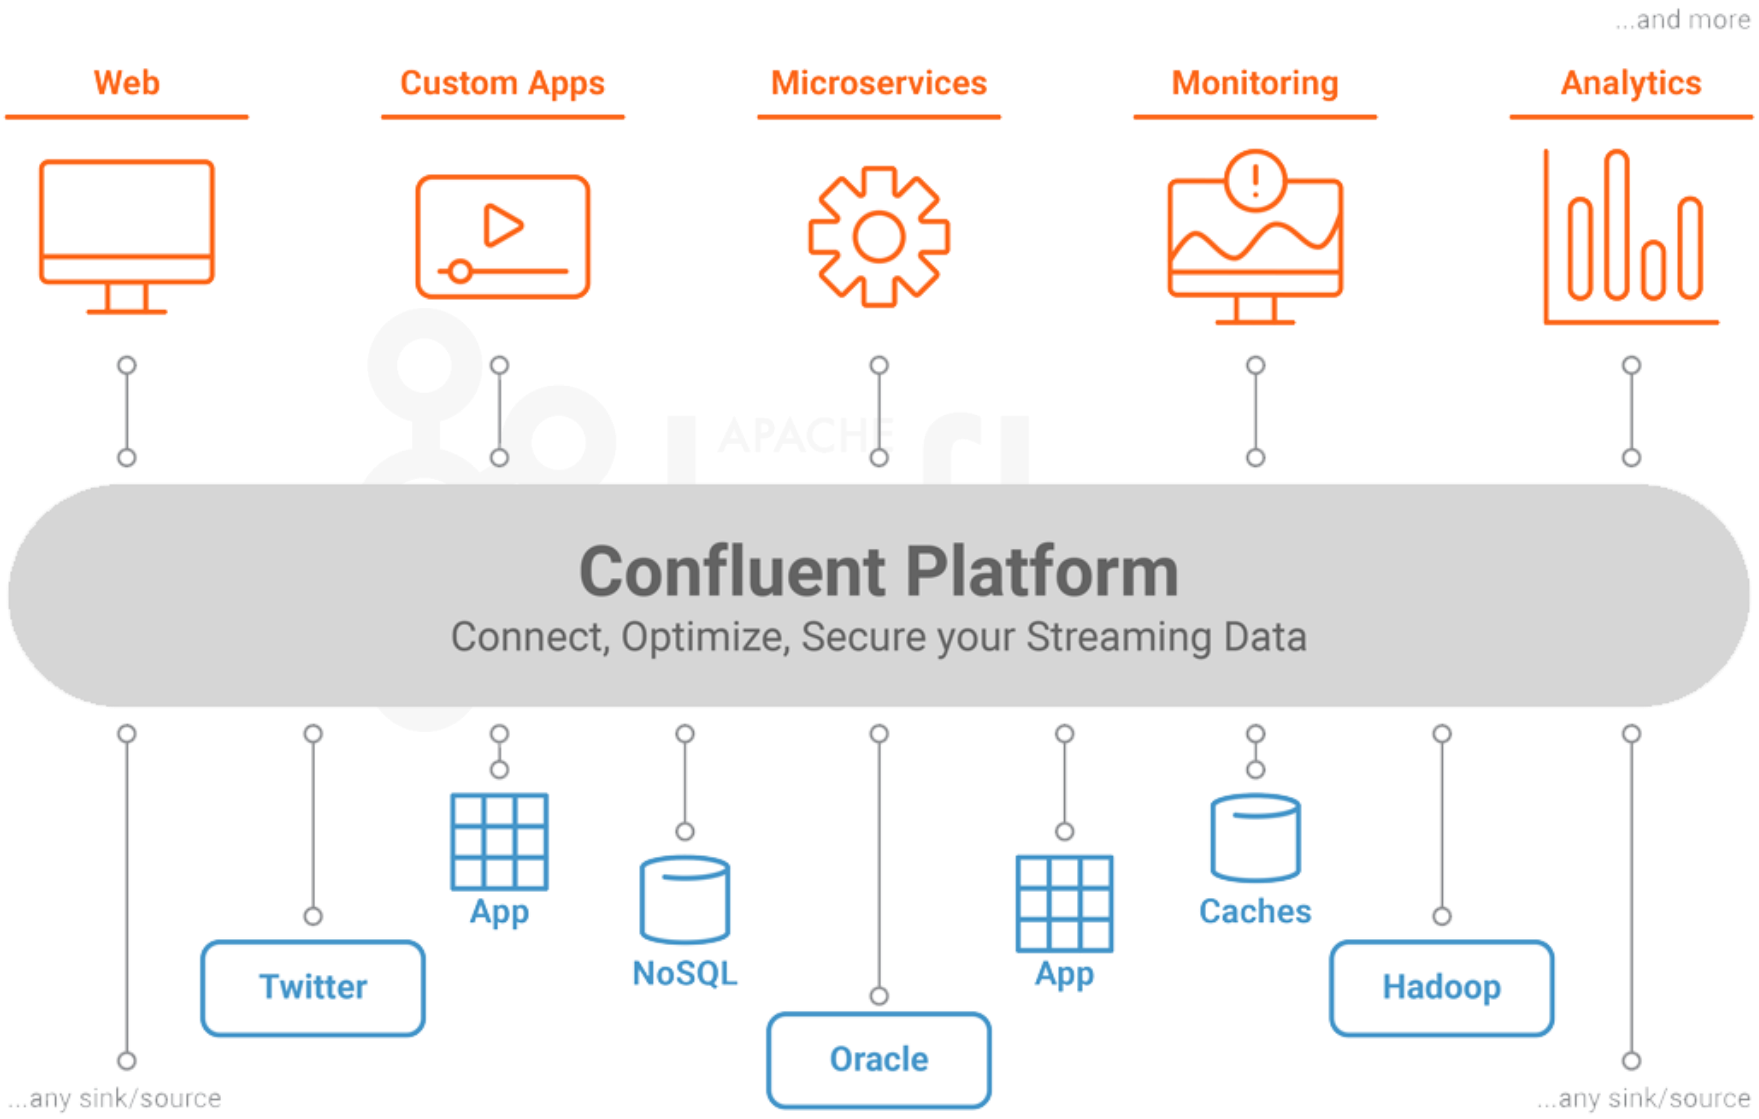


Copyright ETLForma – Tutti i diritti Riservati

# Confluent Platform

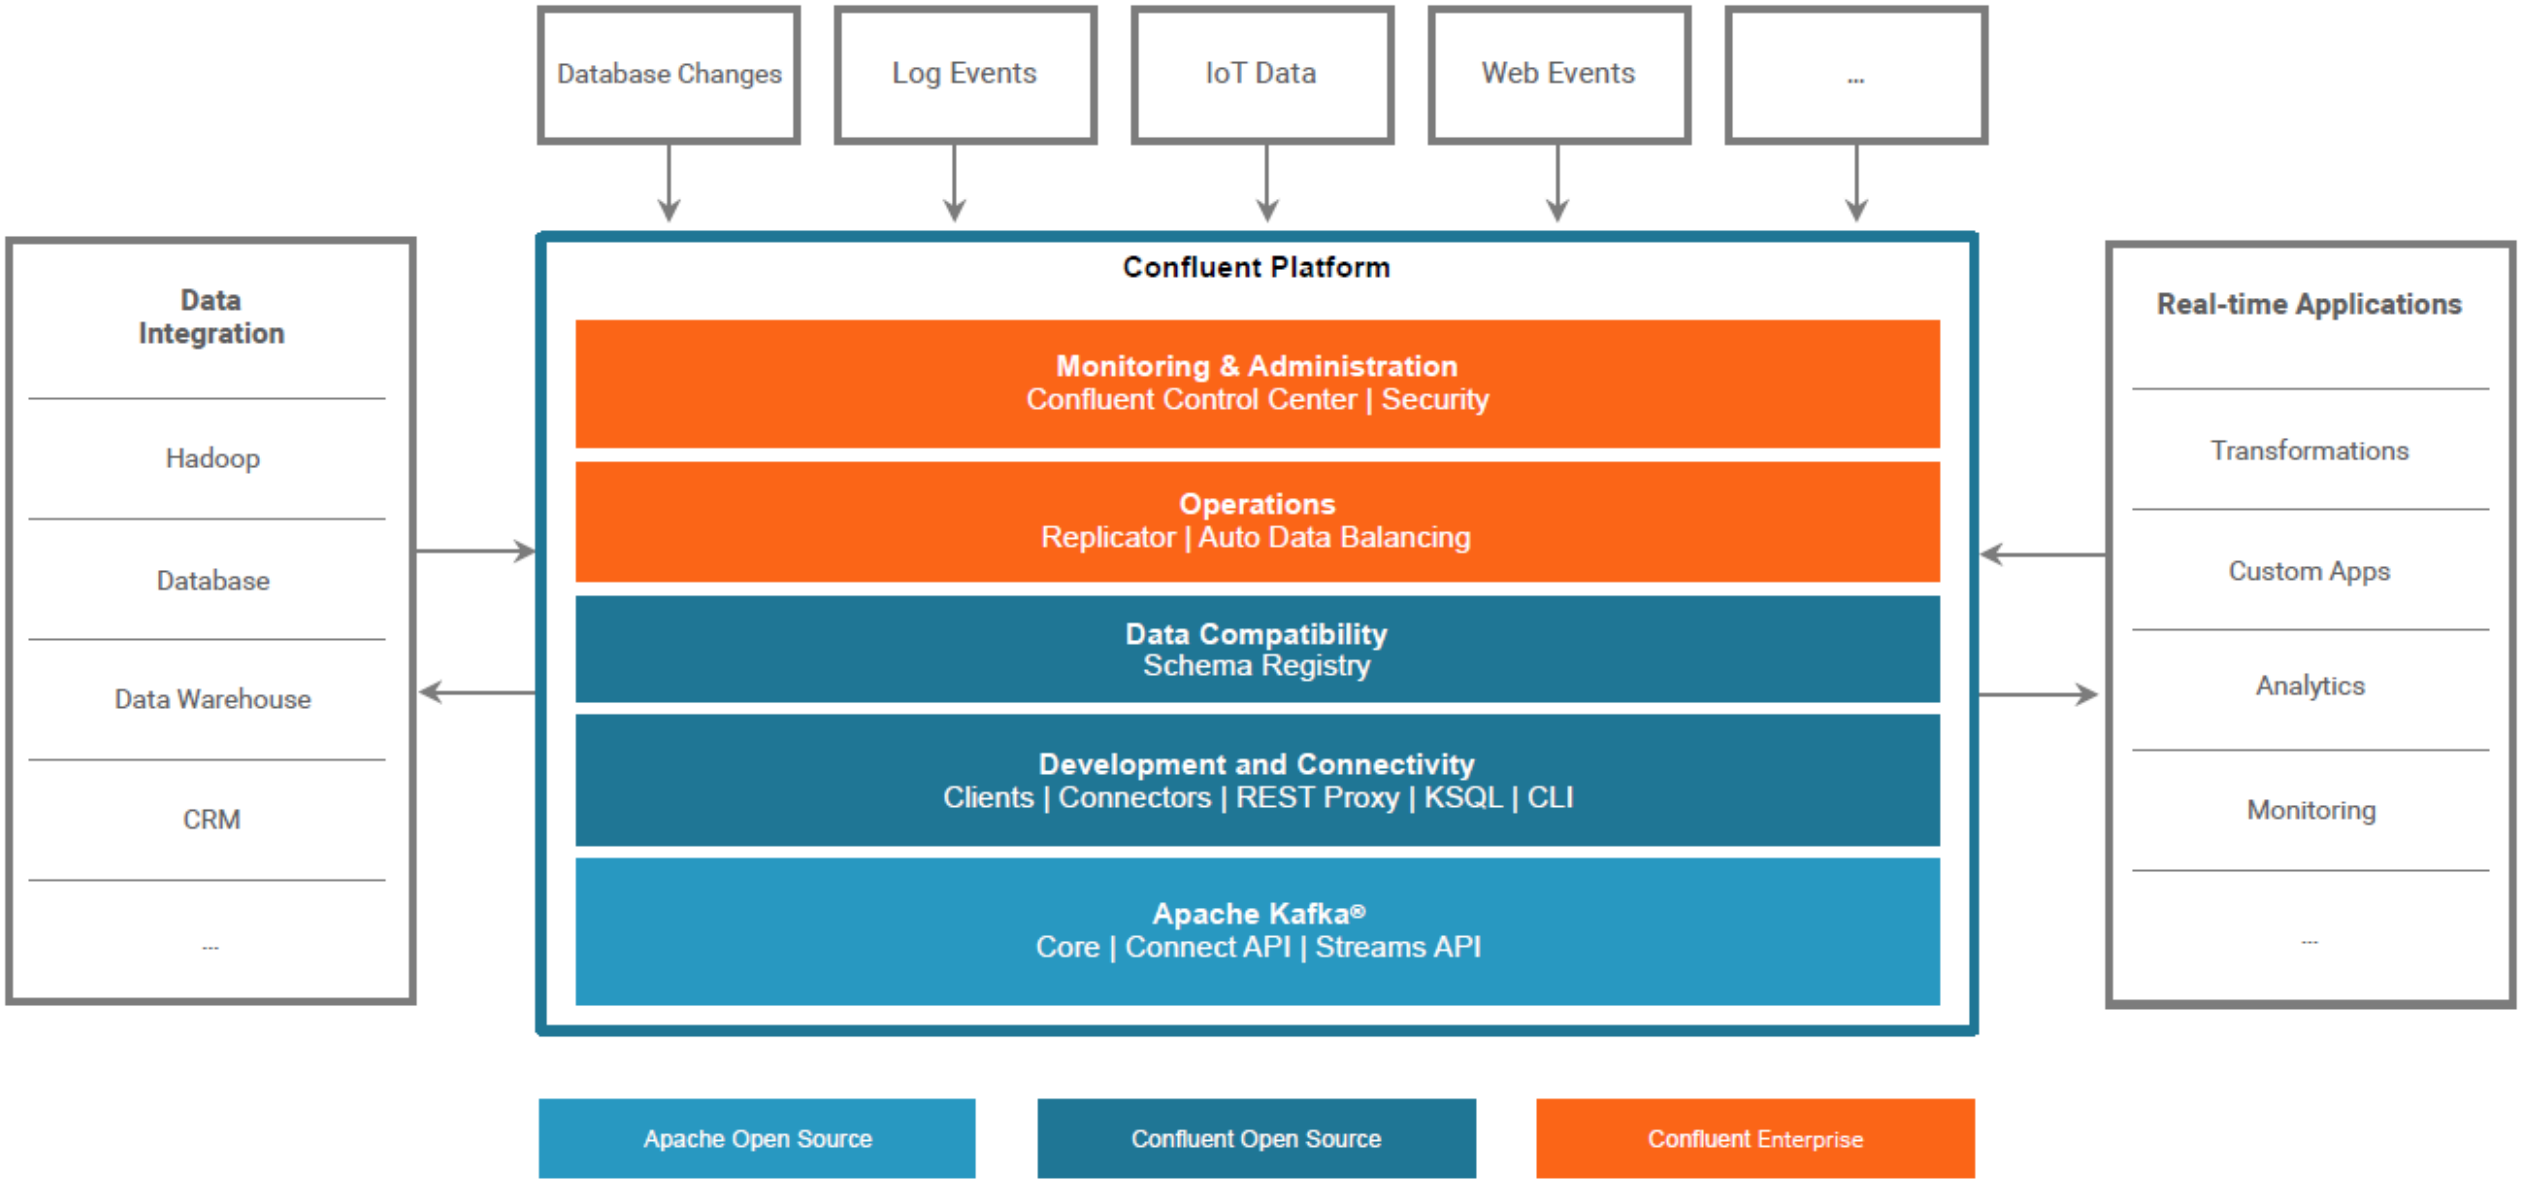


Copyright ETLForma – Tutti i diritti Riservati

# Confluent Platform

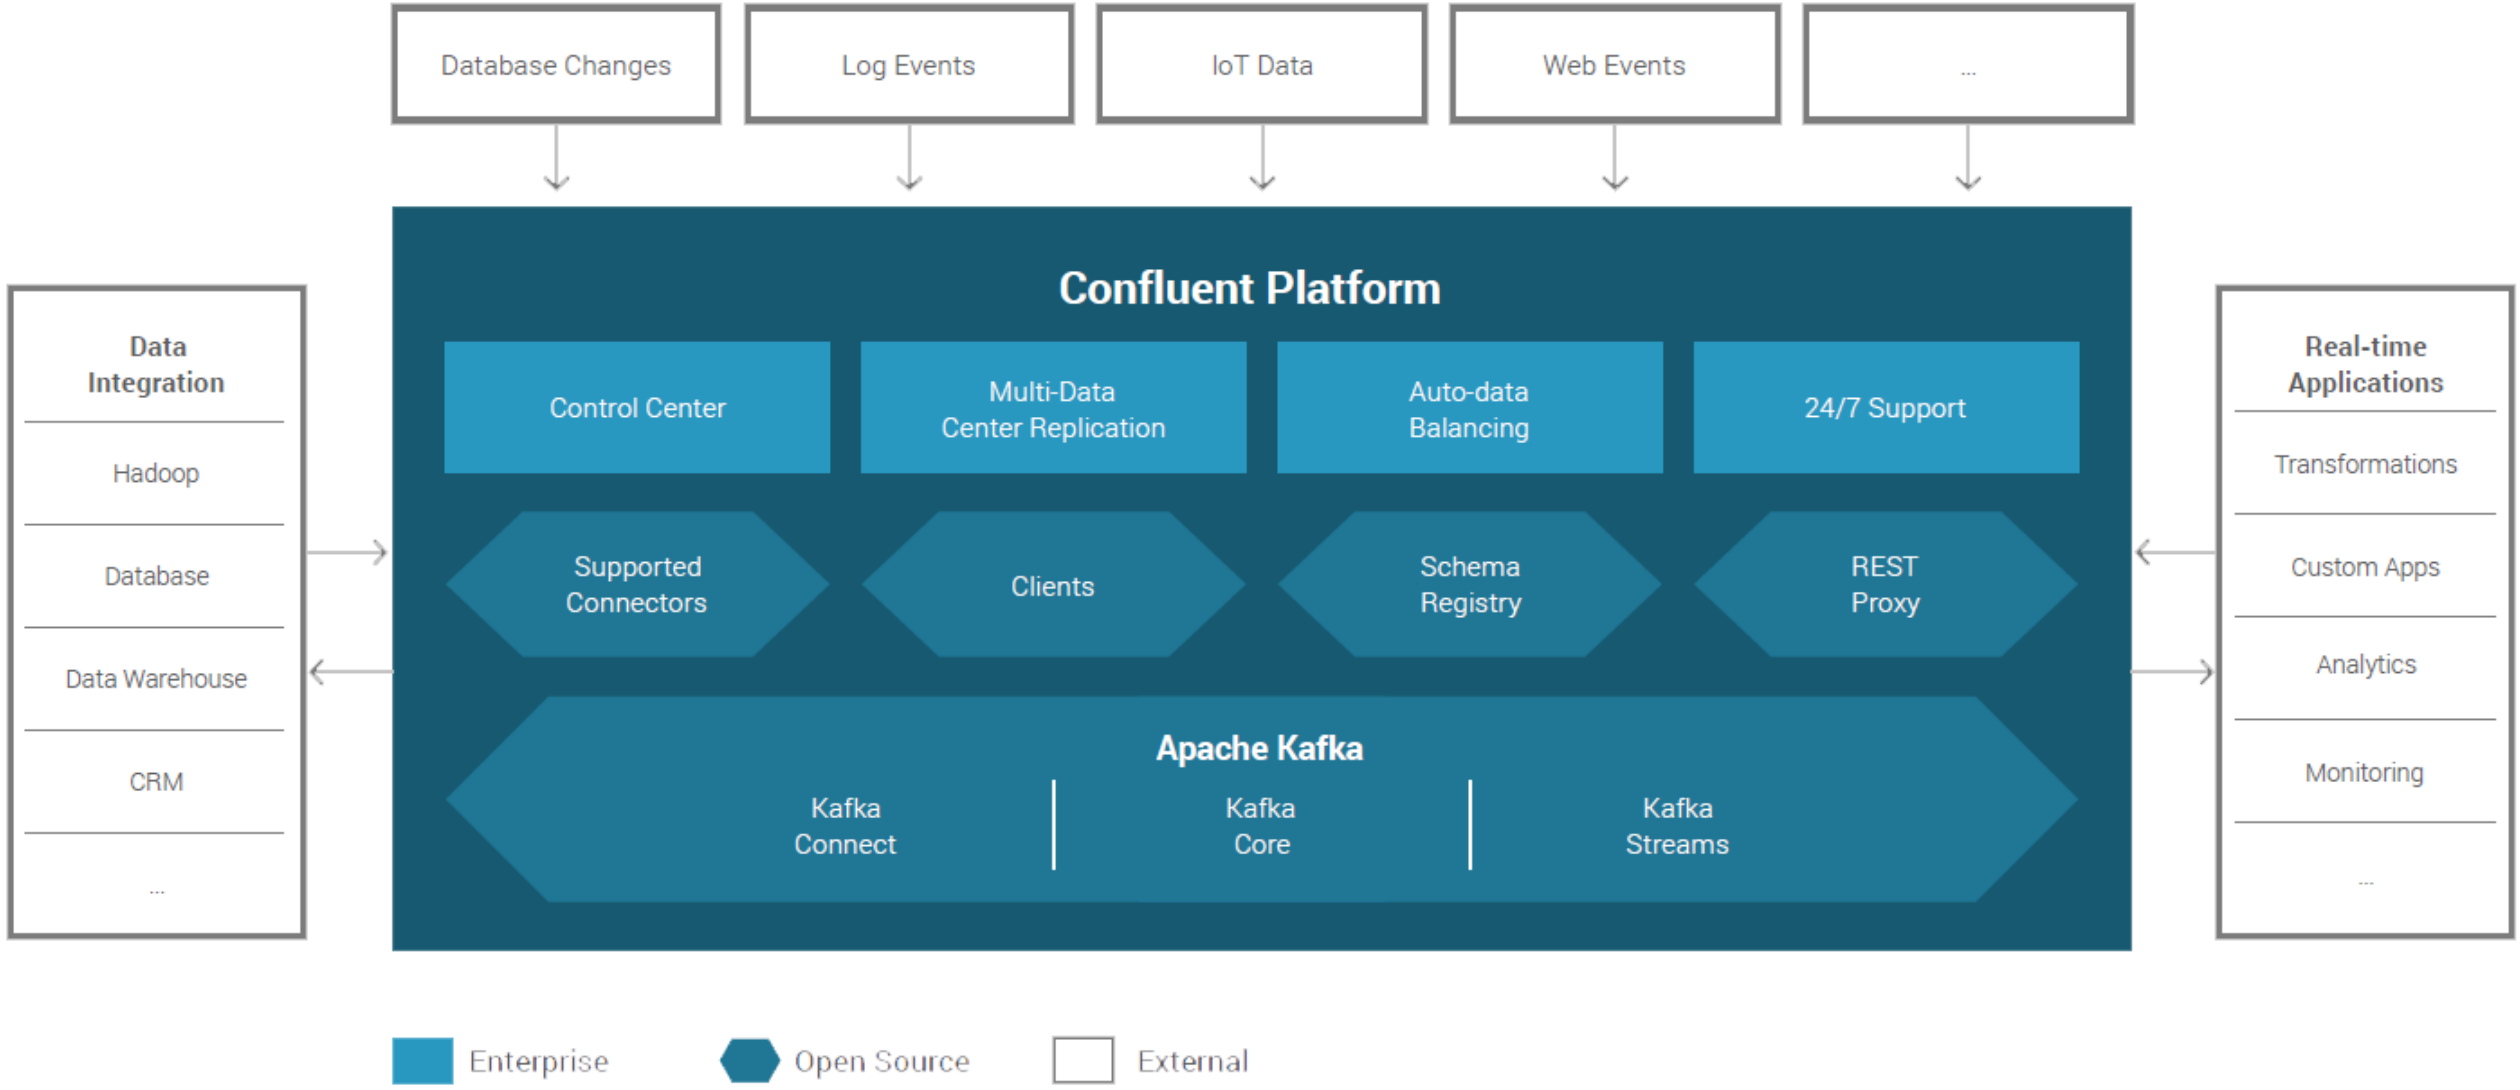


Copyright ETLForma – Tutti i diritti Riservati

# UNIT

Osservazioni

# Perché scegliere Kafka

- Kafka è una piattaforma in costante crescita, sviluppata per velocizzare e per massimizzare la sicurezza circa i flussi di dati prodotti dalla messaggistica.

- Il programma è passato dalla gestione di un miliardo di messaggi agli oltre tre trilioni di oggi, dimostrandosi sempre più gettonato dalle grandi aziende, tra cui Linkedin, Twitter, Netflix.

- Si tratta della scelta giusta per coloro che si occupano della gestione di grandi volumi di dati, per gli sviluppatori di applicazioni e per gli sviluppatori su piattaforma Hadoop.

Copyright ETLForma – Tutti i diritti Riservati

# Quando usare Apache Kafka

- Apache Kafka è integrato nei flussi di data streaming che consentono la condivisione di dati tra sistemi e/o applicazioni, ma anche nei sistemi e nelle applicazioni che usano quei dati.

- Può essere utilizzato in tutti quei casi in cui velocità e scalabilità elevate sono fondamentali.

- La sua capacità di ridurre al minimo la necessità di integrazioni point-to-point per la condivisione di dati in determinate applicazioni, riduce infatti la latenza a millisecondi.

- Gli utenti possono quindi usufruire dei dati più velocemente, aspetto utile quando i dati devono essere disponibili in tempo reale.

Copyright ETLForma – Tutti i diritti Riservati

# Quando usare Apache Kafka

- Riuscendo a gestire milioni di punti dati al secondo, Apache Kafka è la soluzione ideale alle problematiche legate ai Big Data.

- Kafka è uno strumento utile anche per le aziende che non si trovano ad affrontare difficoltà di questo tipo ovvero può essere introdotto in un normale contesto applicativo ove, ad esempio, è necessario redistribuire dati in ambienti ad alta deframmentazione del software.

- In molti esempi di utilizzo che implicano l'elaborazione di dati, come l'Internet of Things (IoT) e i social media, dove il volume di dati stessi cresce a una velocità tale da poter compromettere le applicazioni esistenti.

- In generale, quando occorre prevedere una certa scalabilità nell'elaborazione, che consenta di rispondere alla crescente proliferazione dei dati.

Copyright ETLForma – Tutti i diritti Riservati

# Riepilogo

- Kafka si occupa di elaborare grandi moli di dati in tempo reale, permettendo di creare sistemi scalabili a elevato throughput e bassa latenza.

- Gestisce la persistenza dei dati stessi sia sul server principale che sulle repliche, garantendo così la cosiddetta fault-tolerance.

- Kafka può essere usato come strumento per lo scambio di messaggi asincroni in un ecosistema di microservizi

- …e molto altro…

Copyright ETLForma – Tutti i diritti Riservati

# Prima Di Kafka

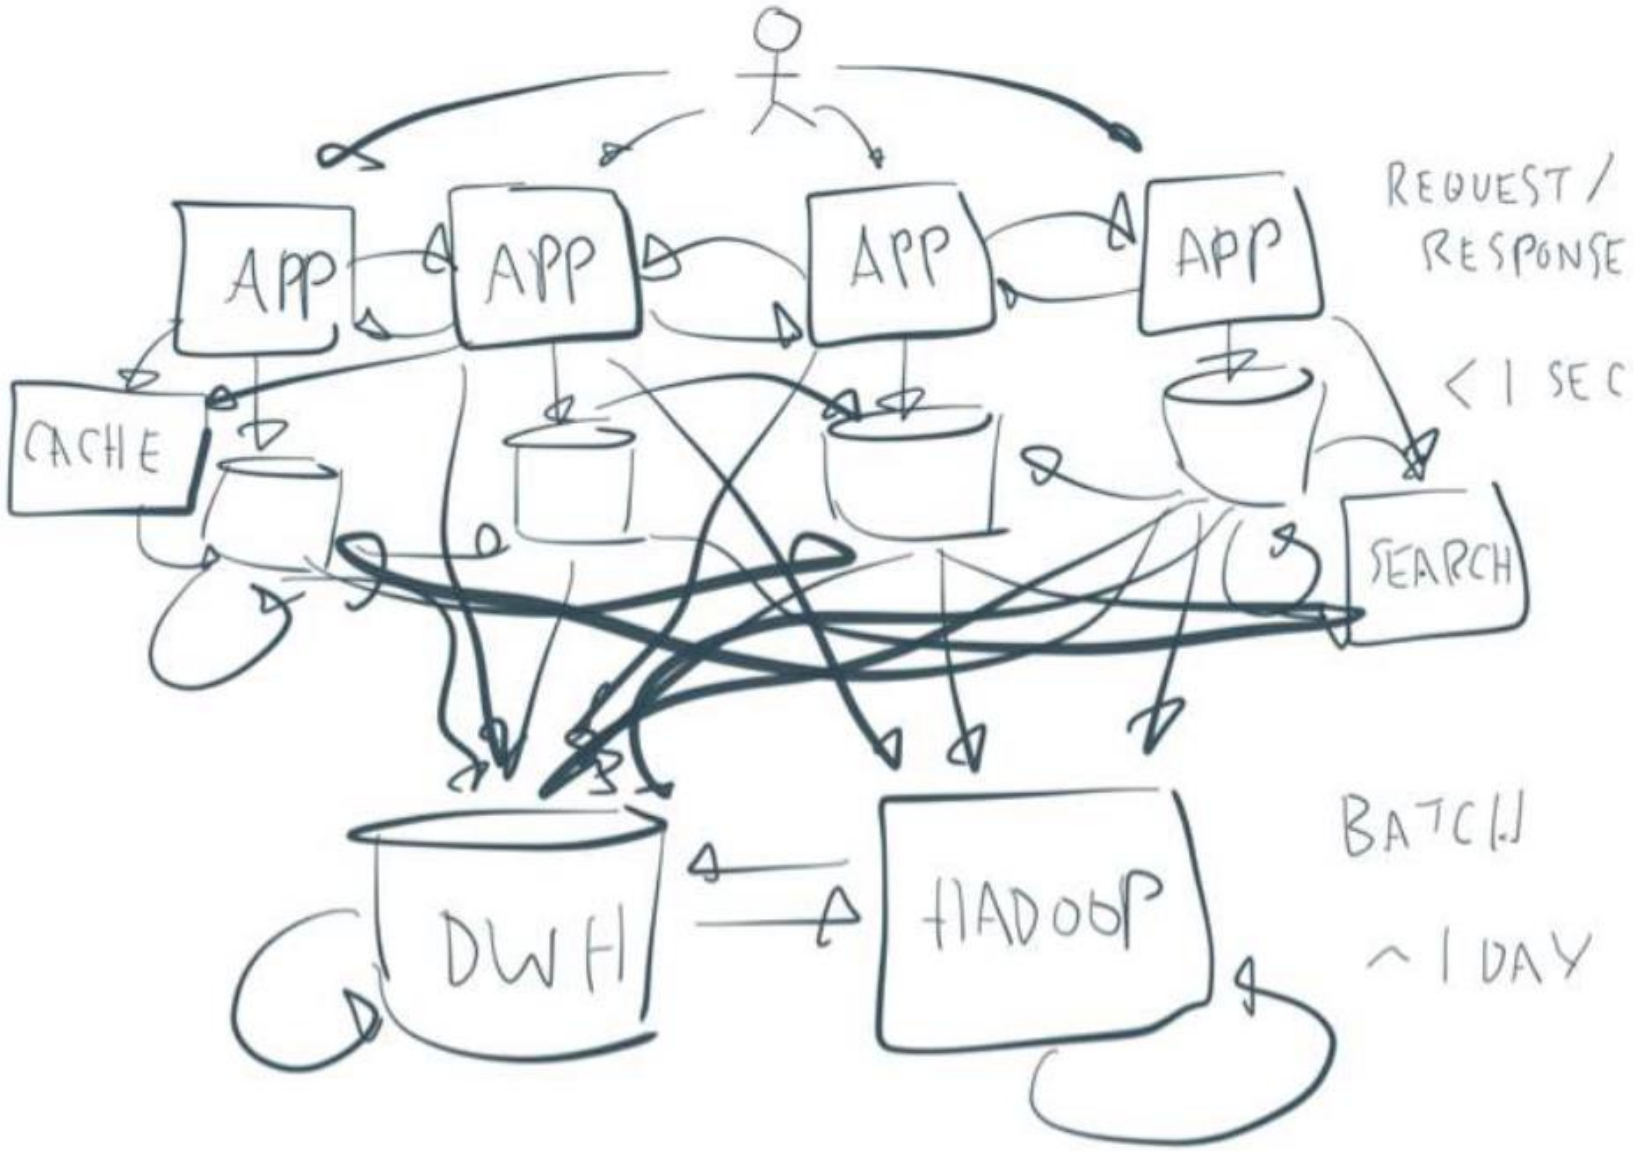


Copyright ETLForma – Tutti i diritti Riservati

# Dopo Kafka

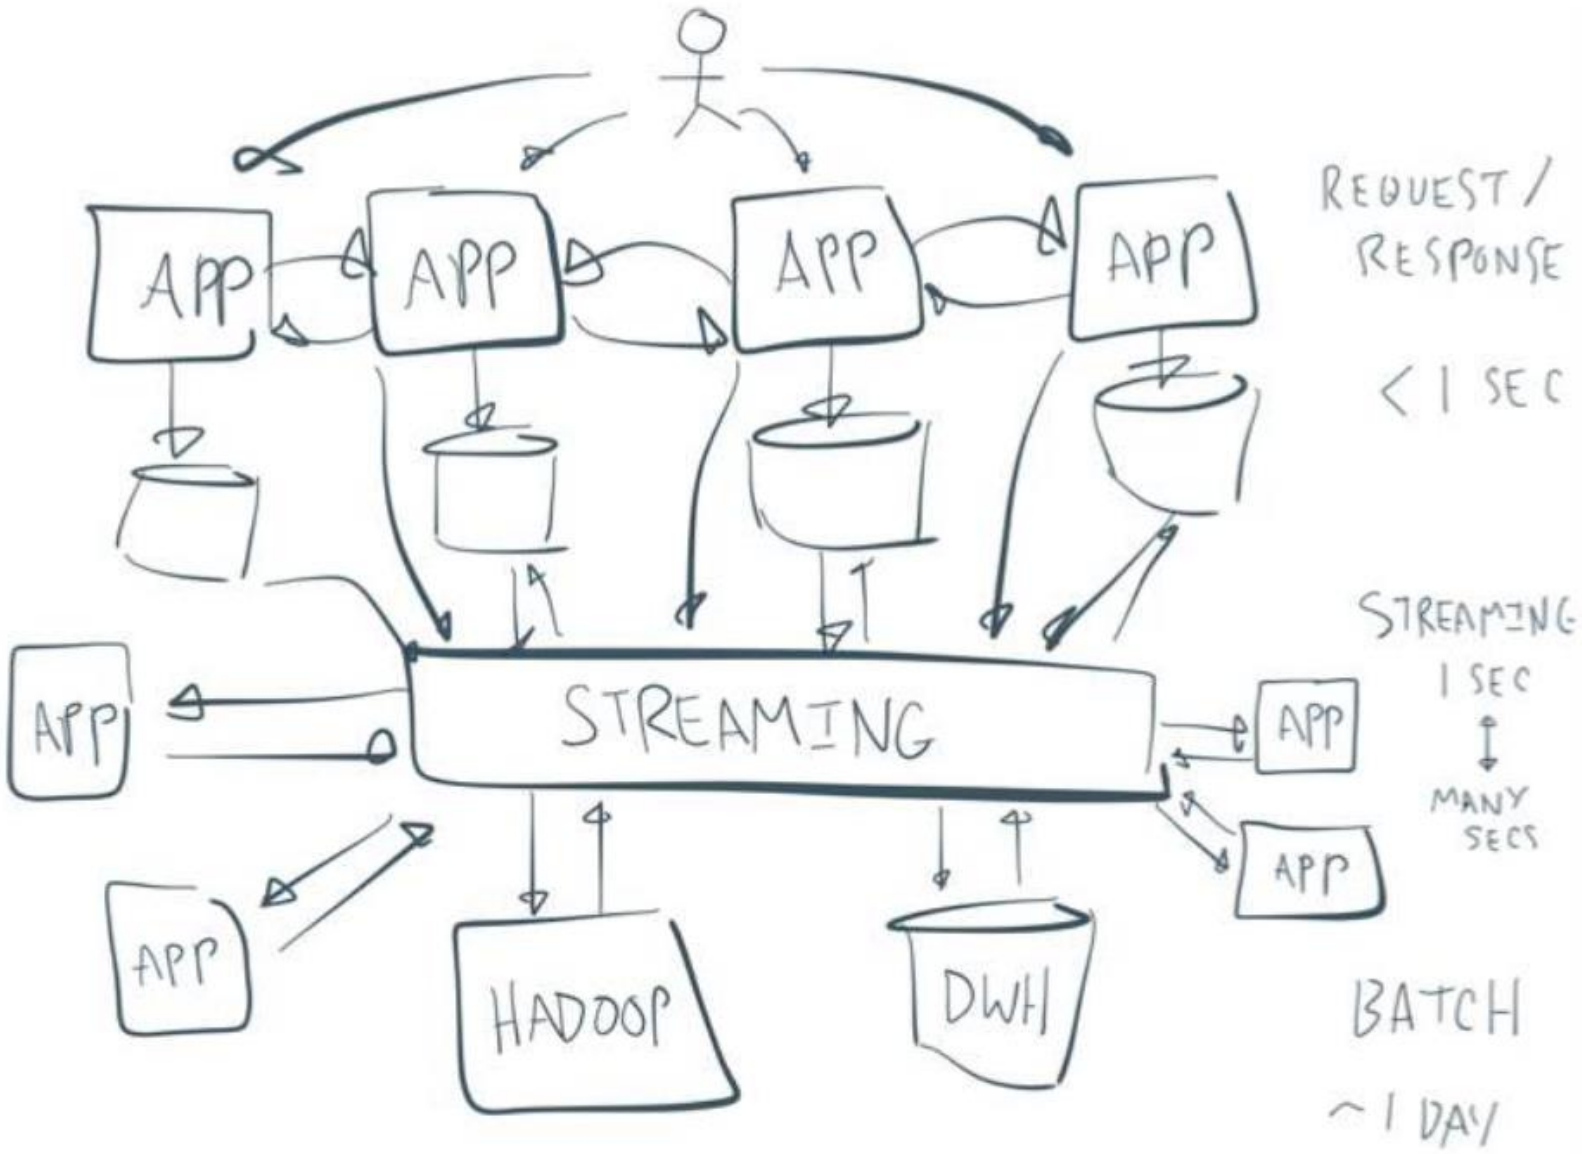


Copyright ETLForma – Tutti i diritti Riservati

# Prima Di Kafka

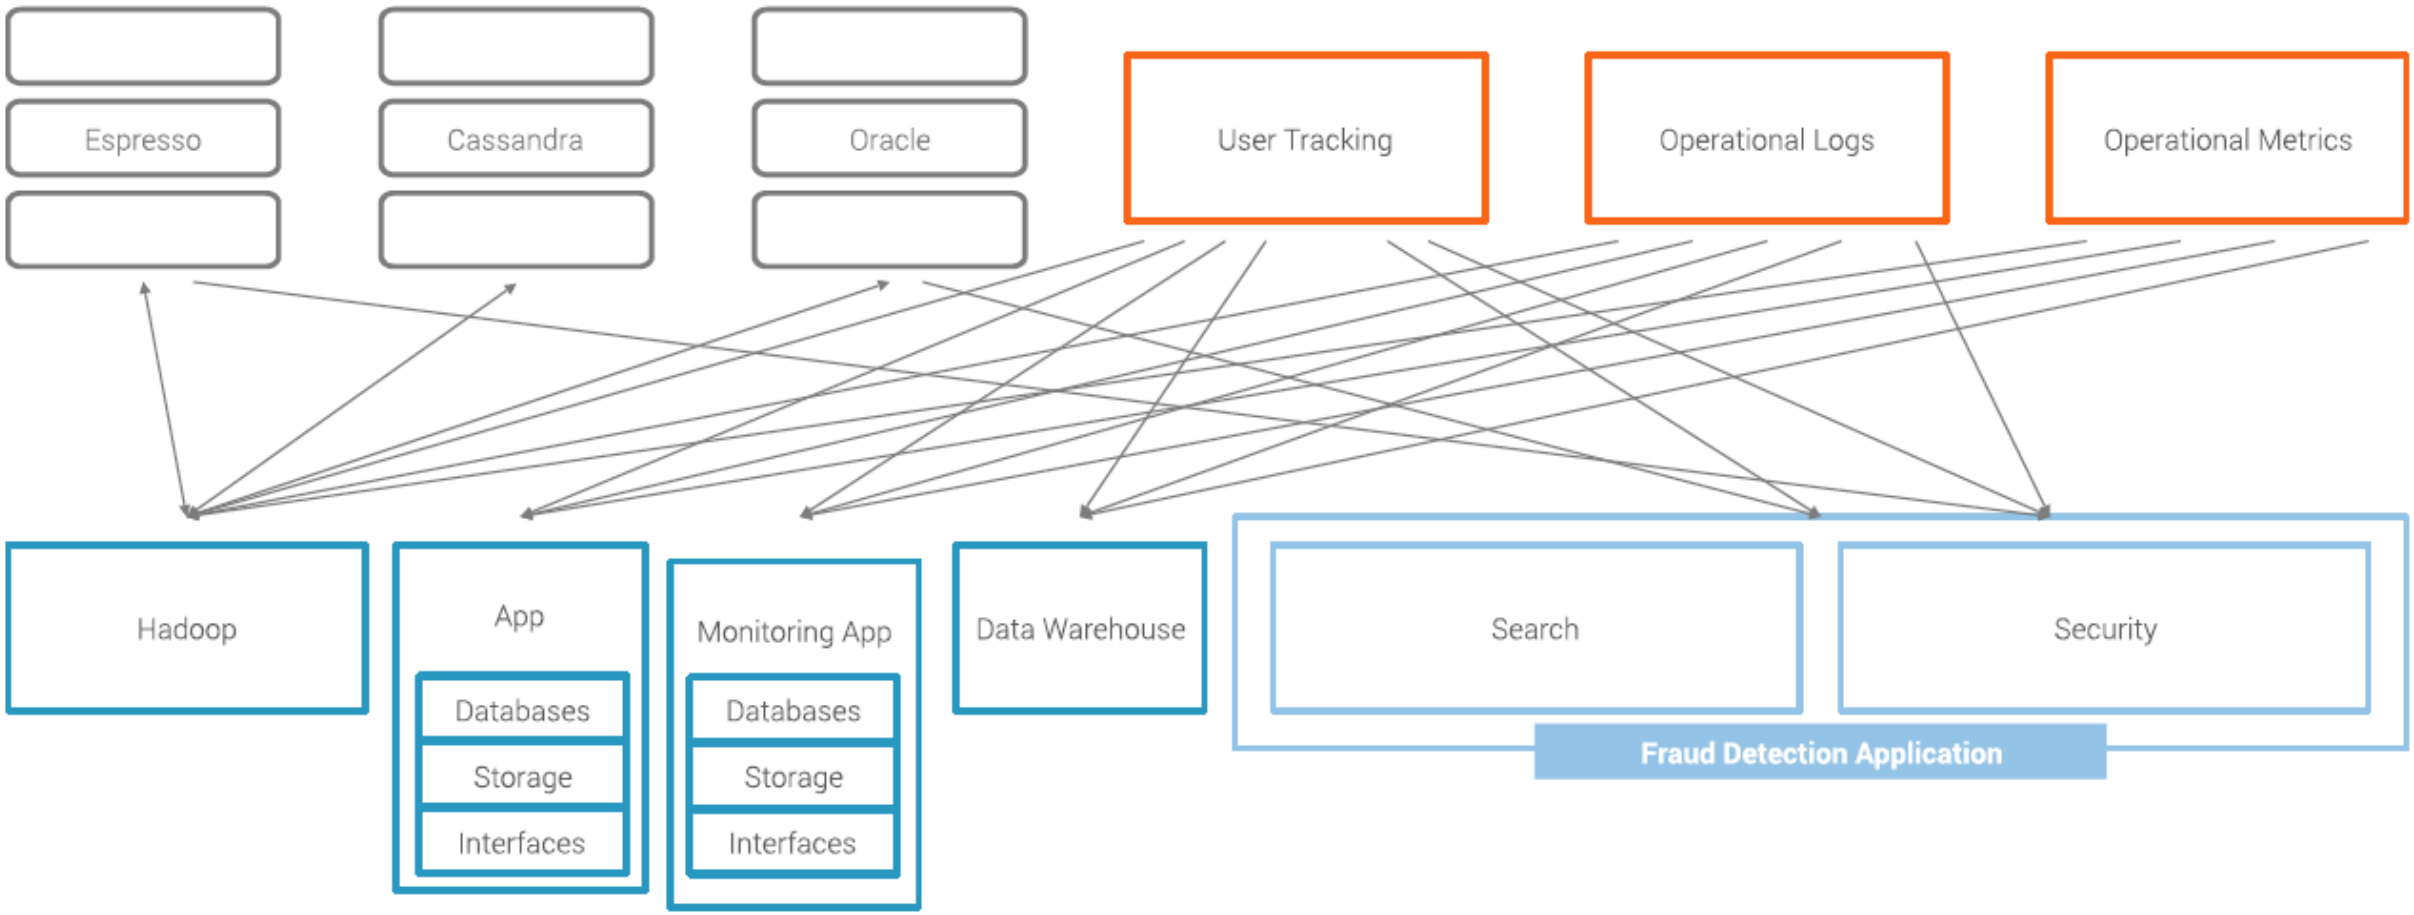


Copyright ETLForma – Tutti i diritti Riservati

# Dopo Kafka

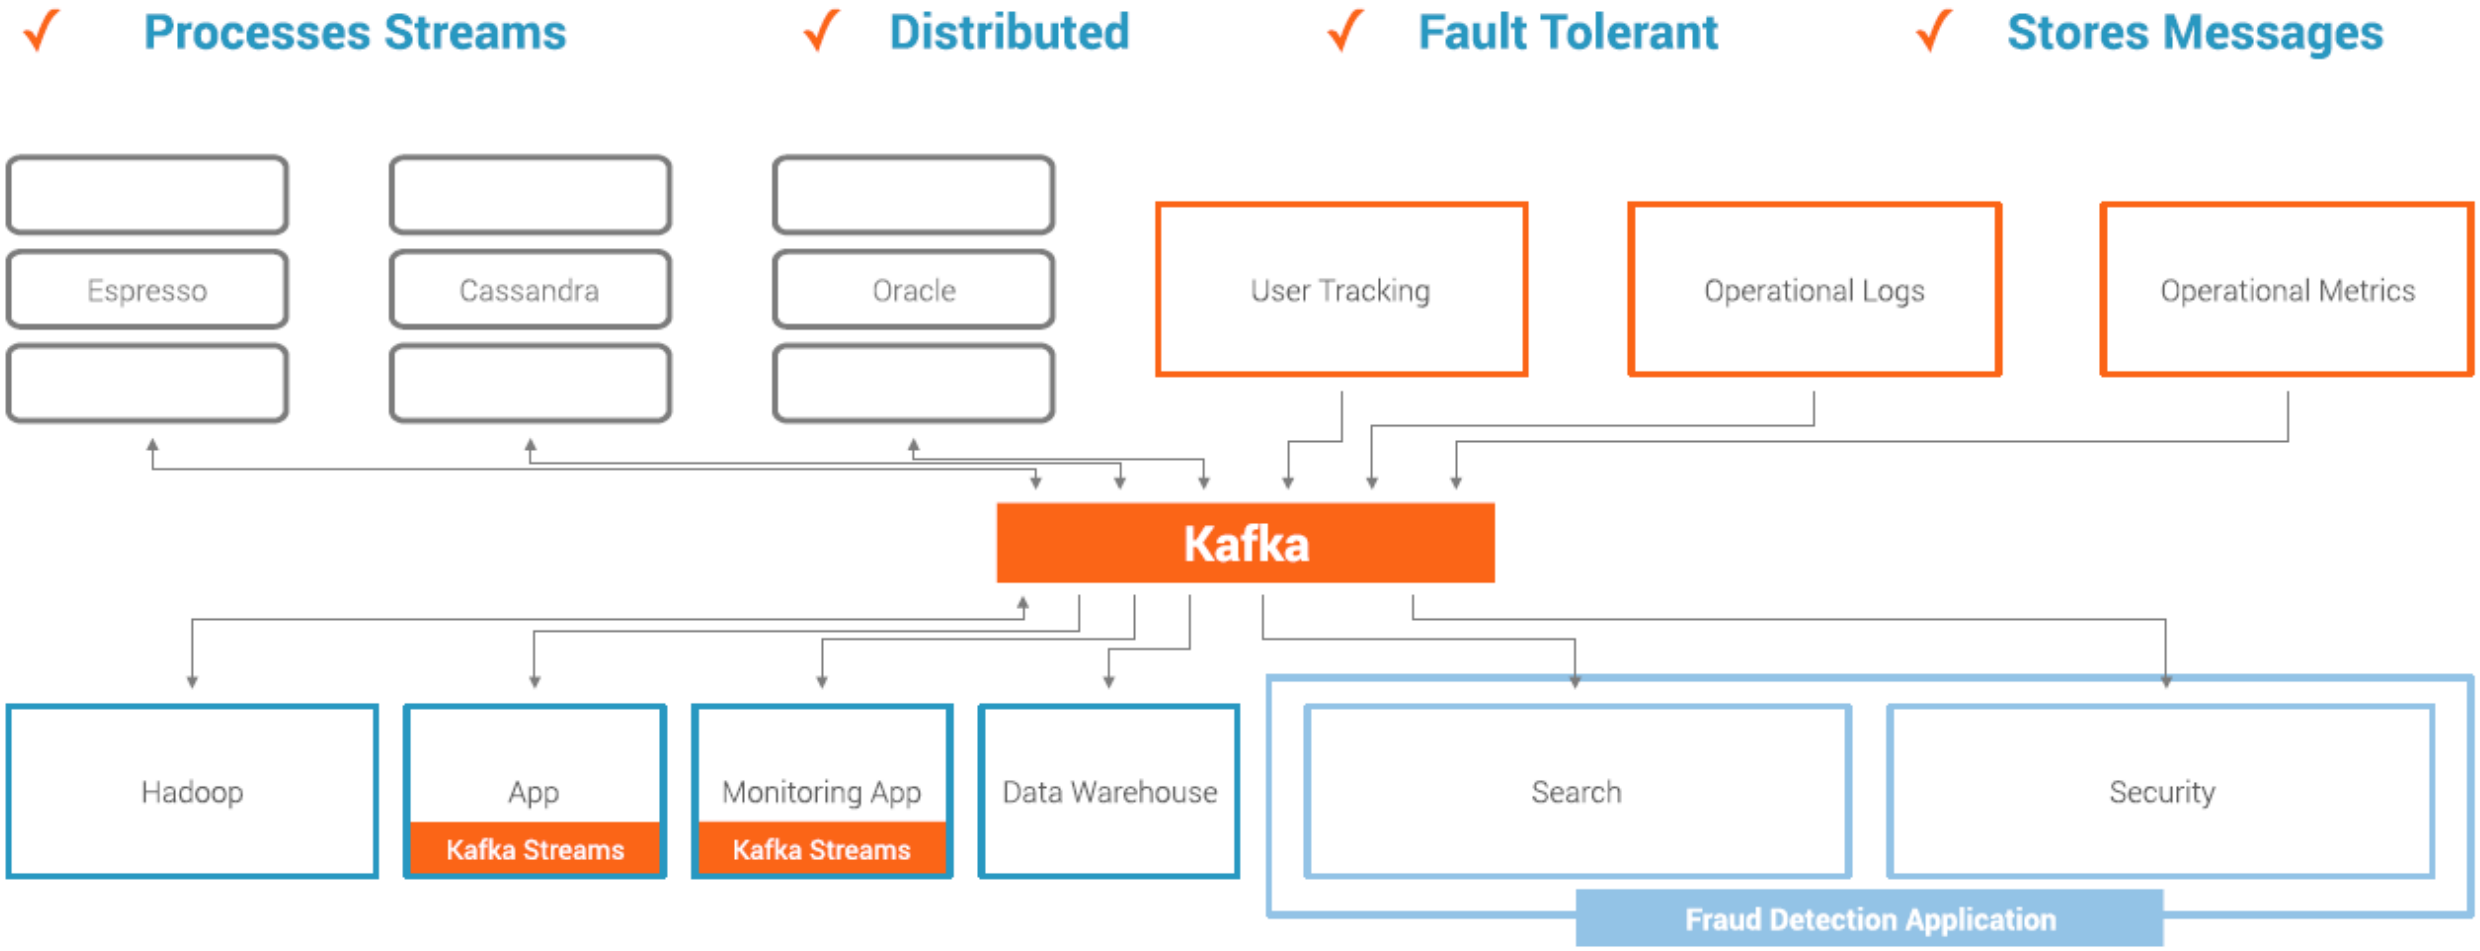


Copyright ETLForma – Tutti i diritti Riservati

# Kafka promette il passaggio «From Big Data to Fast Data»

Big data was
**The more the better**

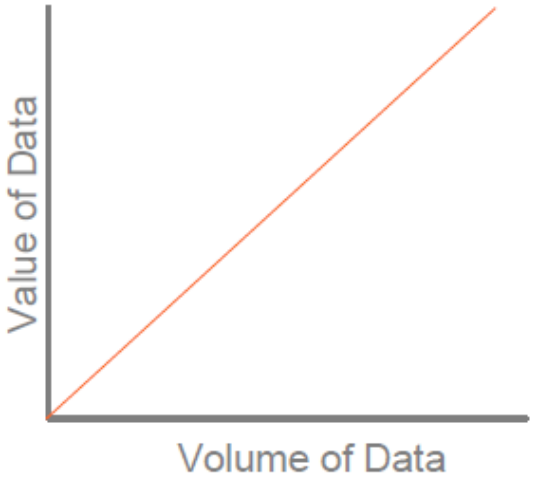


Stream data is
**The faster the better**

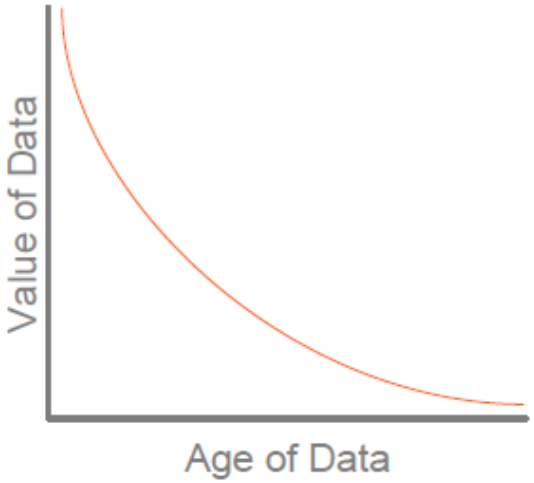


Stream data can be
**big or fast (Lambda)**

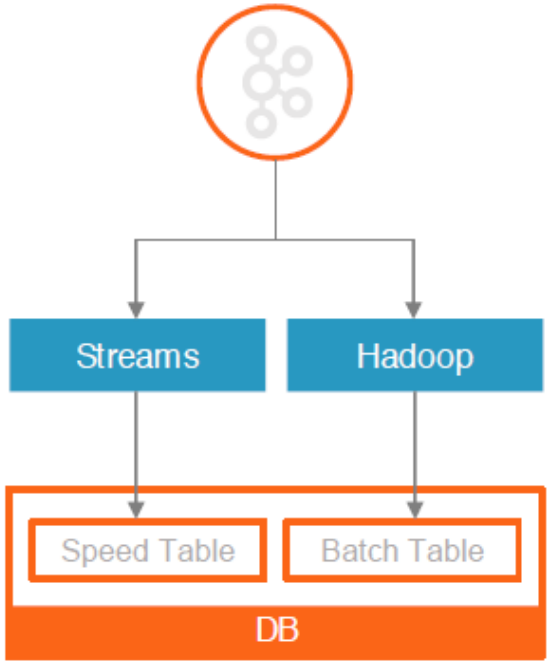


Stream data will be
**big AND fast (Kappa)**

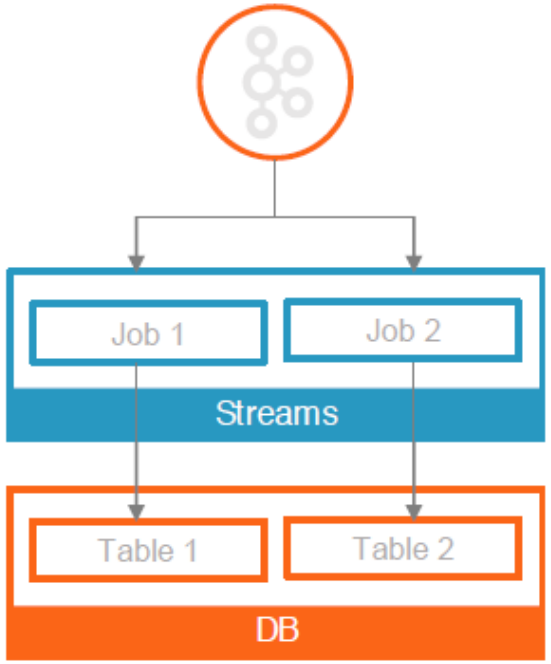


**Apache Kafka is the enabling technology of this transition**

Copyright ETLForma – Tutti i diritti Riservati

# Kafka – Streaming Platform

Copyright ETLForma – Tutti i diritti Riservati

# Kafka – Connectors

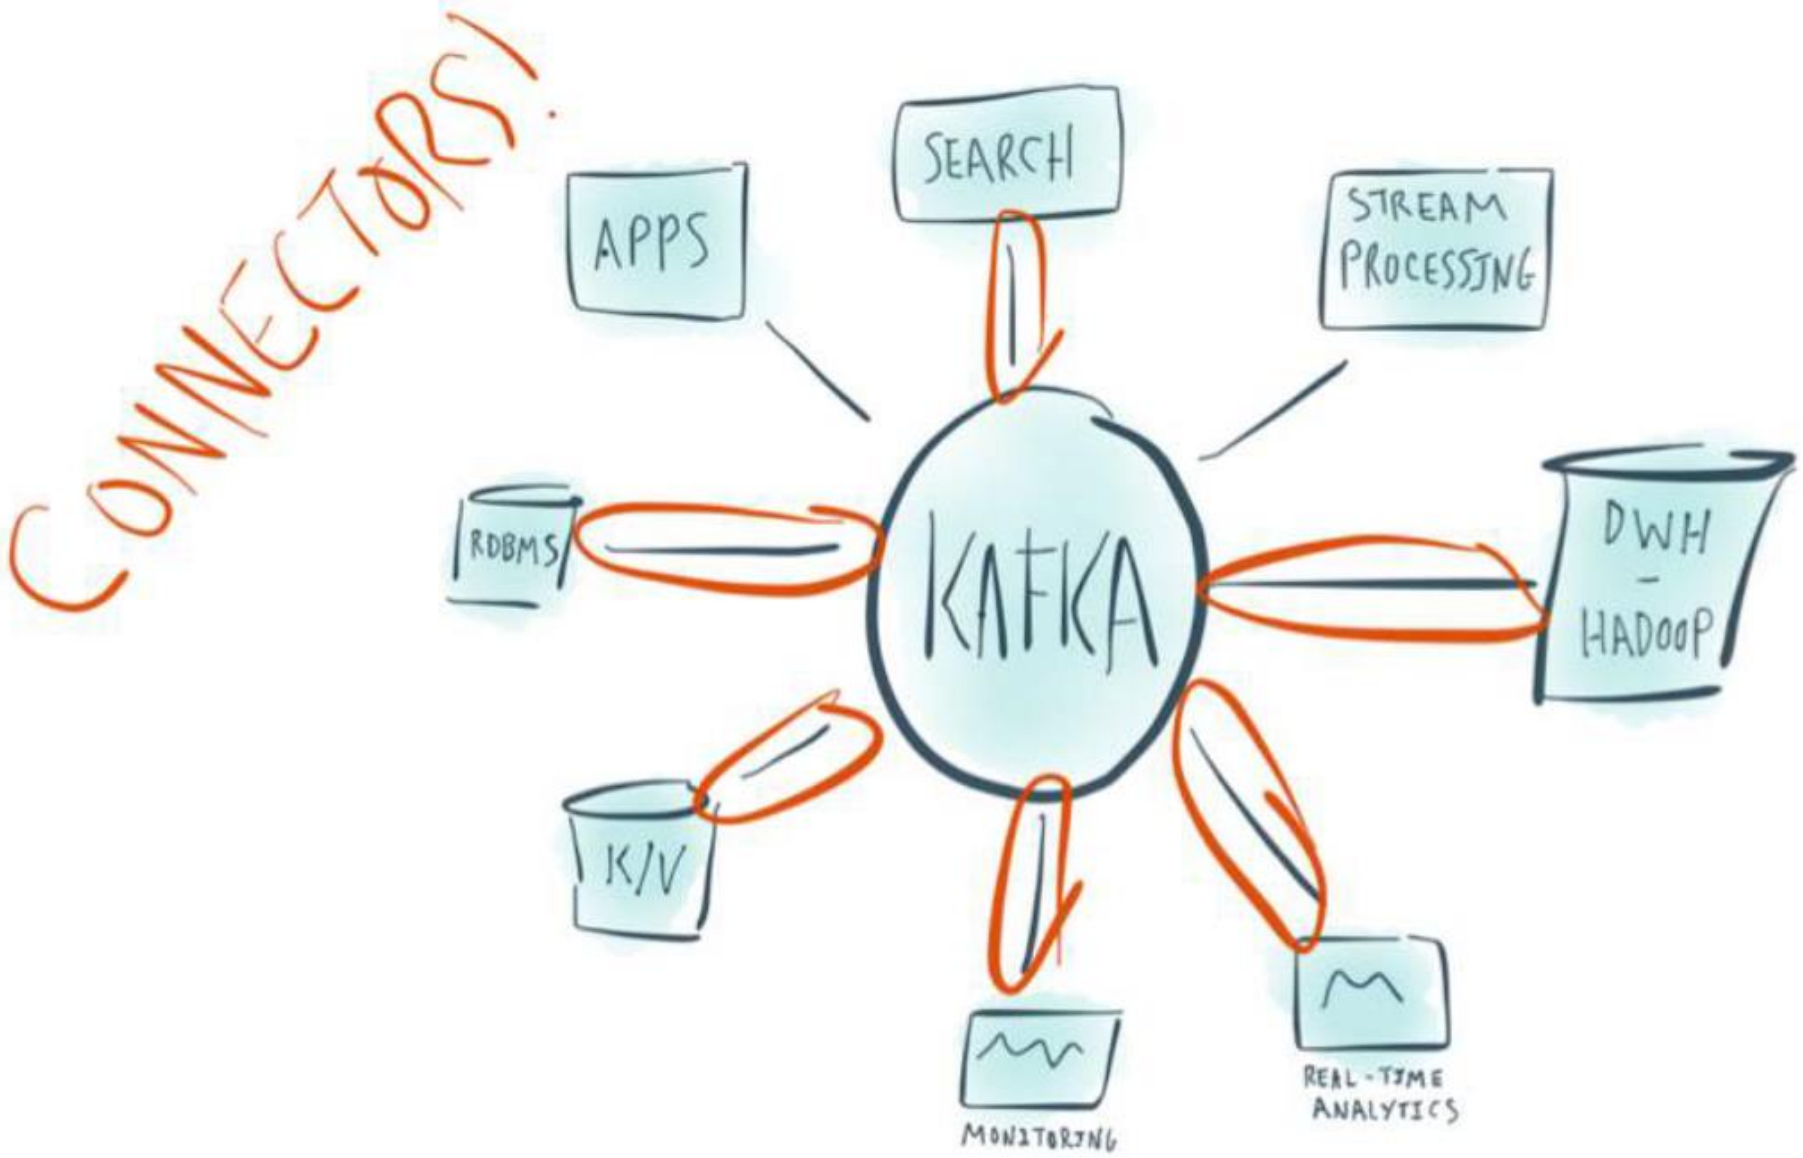


Copyright ETLForma – Tutti i diritti Riservati

# Kafka – CONNECT

Copyright ETLForma – Tutti i diritti Riservati

# Kafka – CONNECT

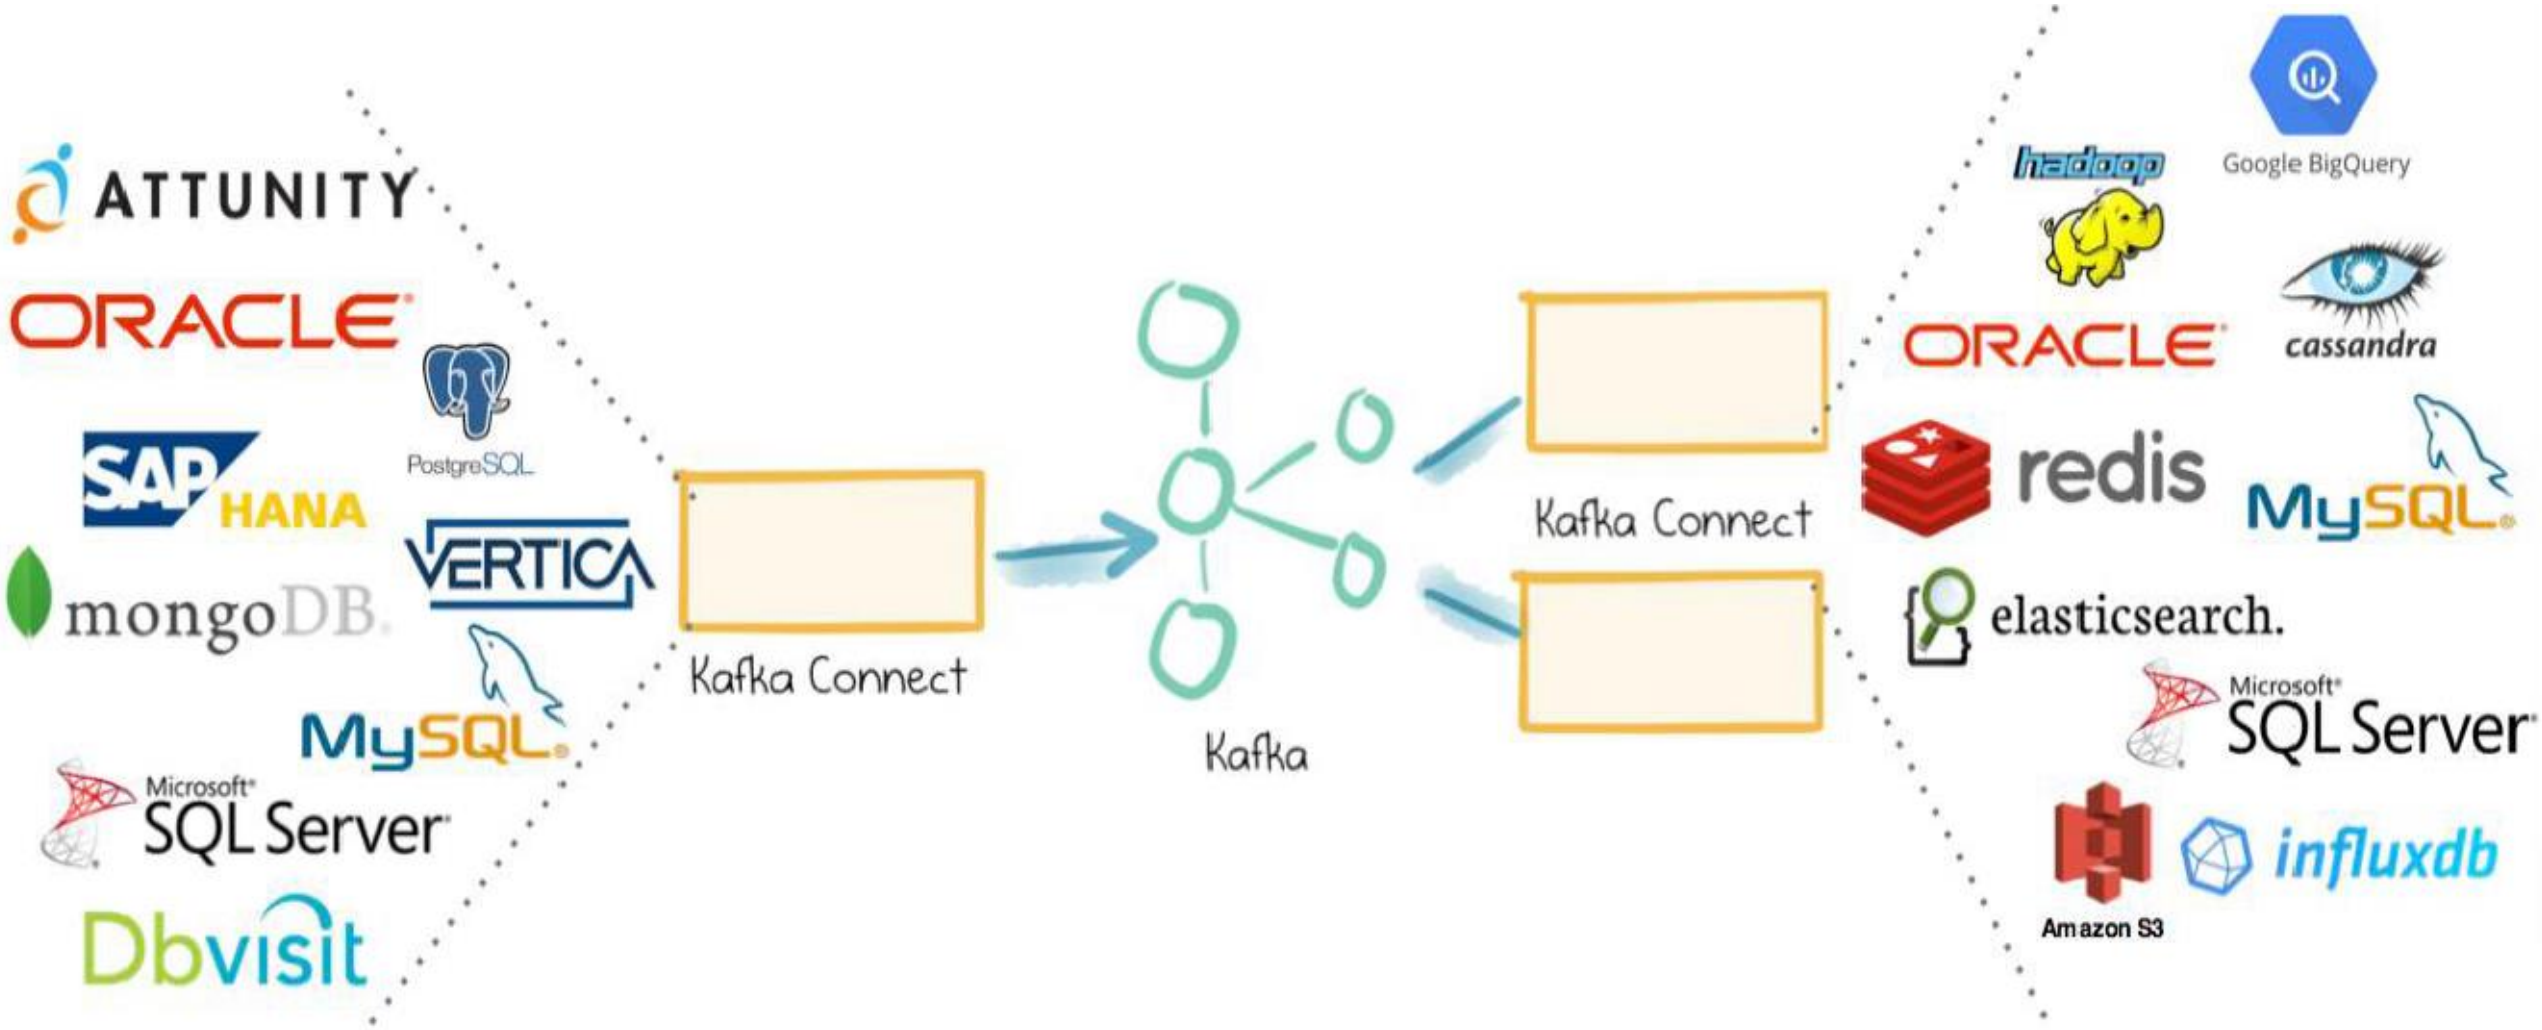


Copyright ETLForma – Tutti i diritti Riservati

# Kafka – CONNECT

## Databases

JDBC
mongoDB
Cassandra
DATASTAX
ORACLE GOLDEN GATE
Just One Data
Couchbase
amazon DynamoDB
InfluxDB
APACHE HBASE
RethinkDB
Kudu

## Datastore/File Store

hadoop
apache Ignite
FTP
amazon web services S3
syslog-ng
hazelcast

## Analytics

VERTICA An HP Company
elastic
mixpanel

## Applications / Other

#irc
GitHub
Solr
Bloomberg
syncsort
twitter
ATTUNITY
VERTICA An HP Company
striim

Copyright ETLForma – Tutti i diritti Riservati

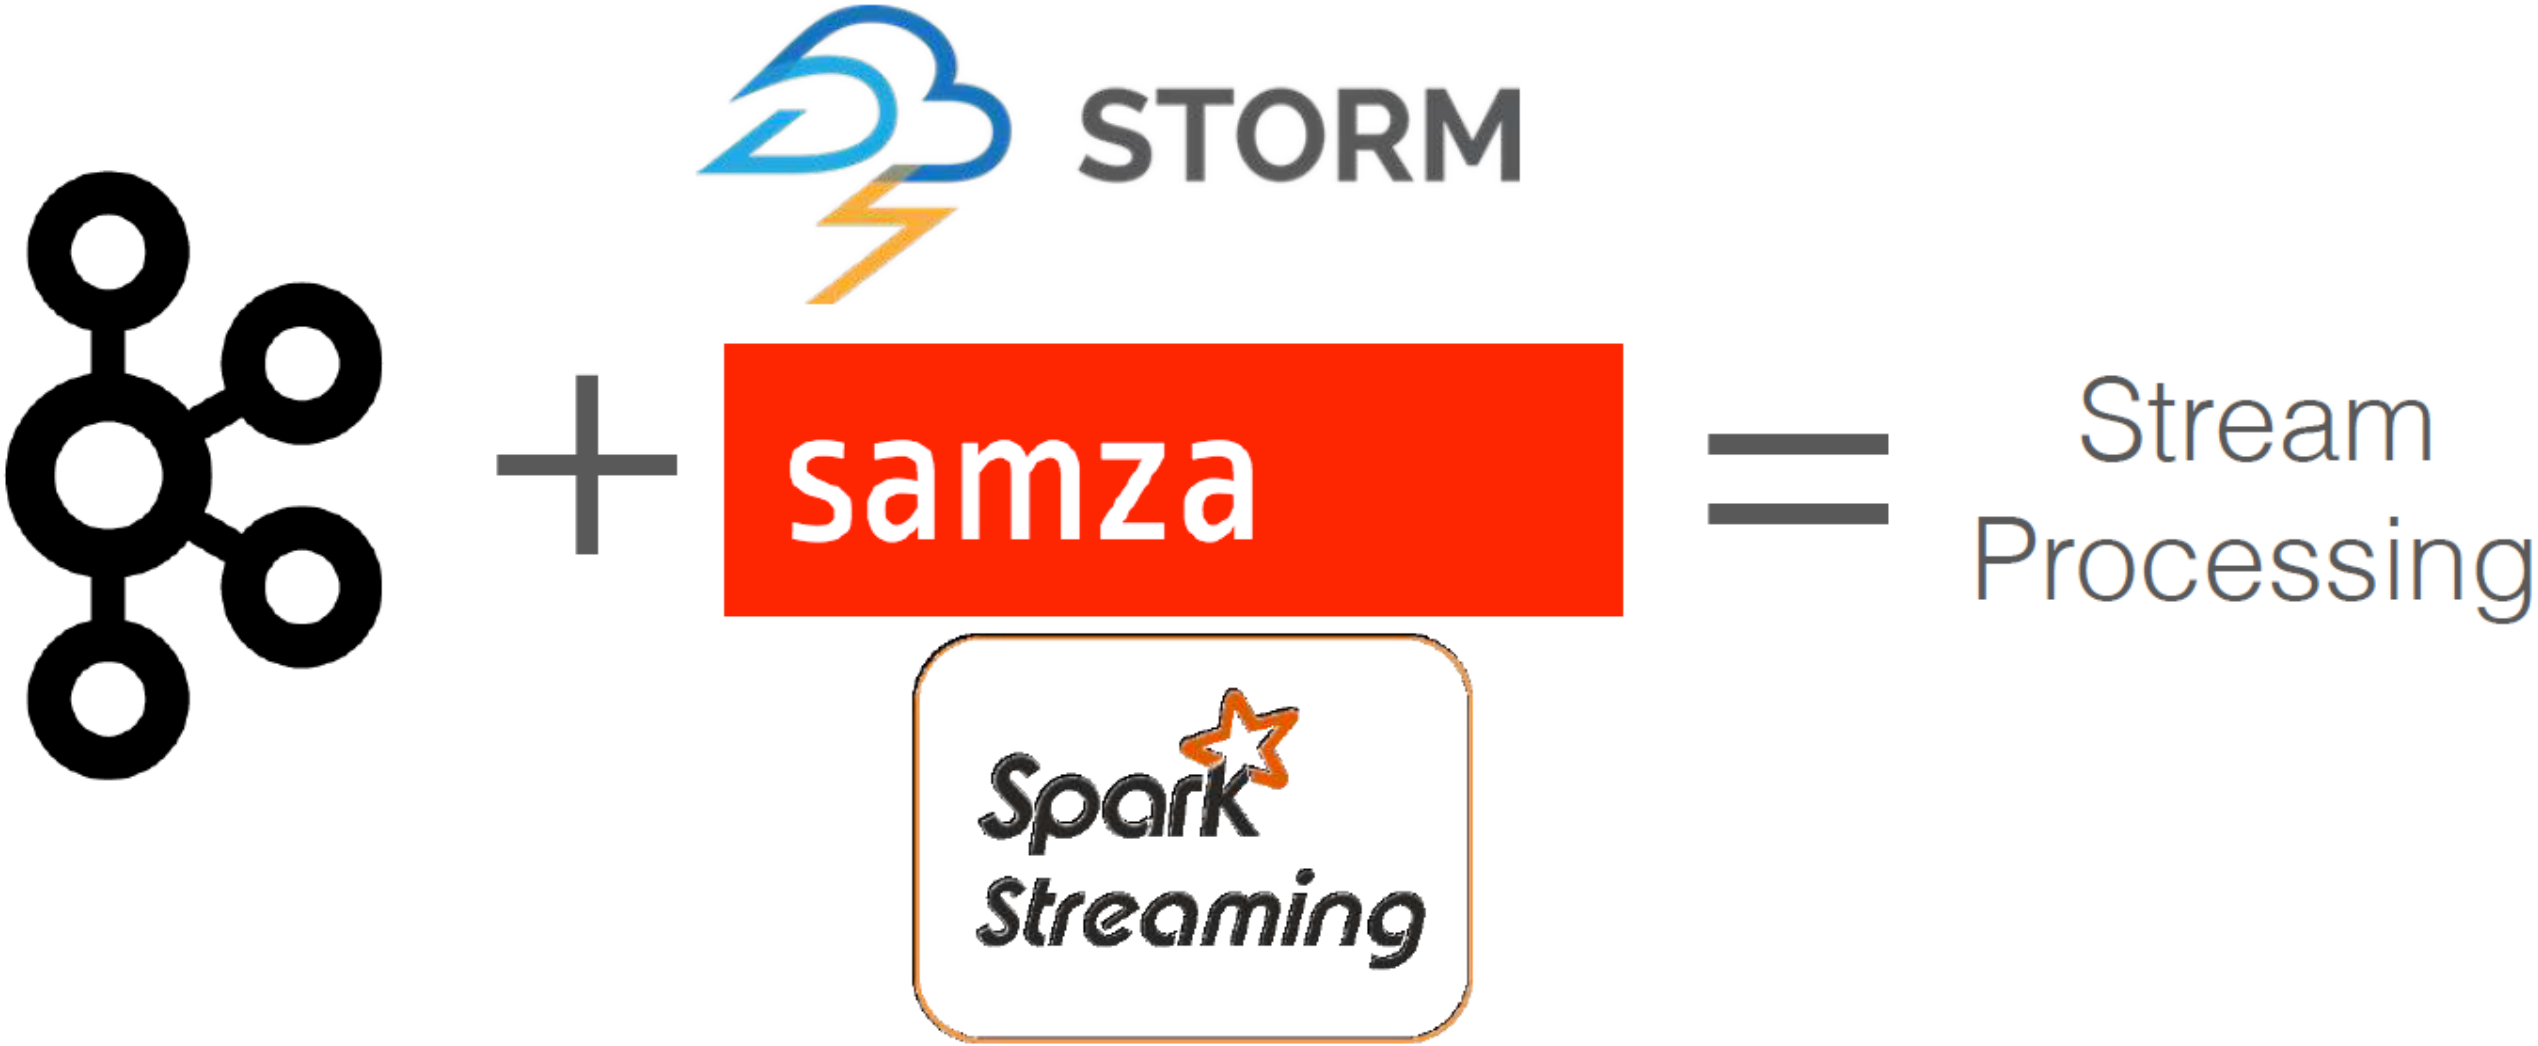


Copyright ETLForma – Tutti i diritti Riservati

# Kafka – Streams App

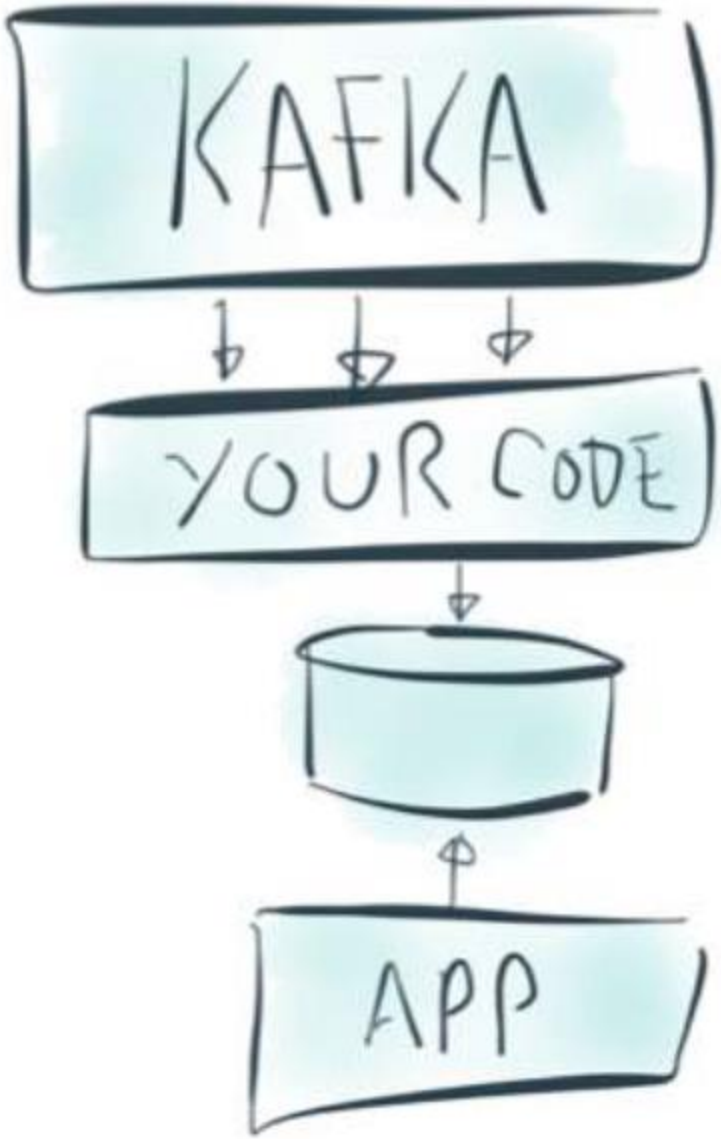


Copyright ETLForma – Tutti i diritti Riservati

# Kafka – Connect + Streams

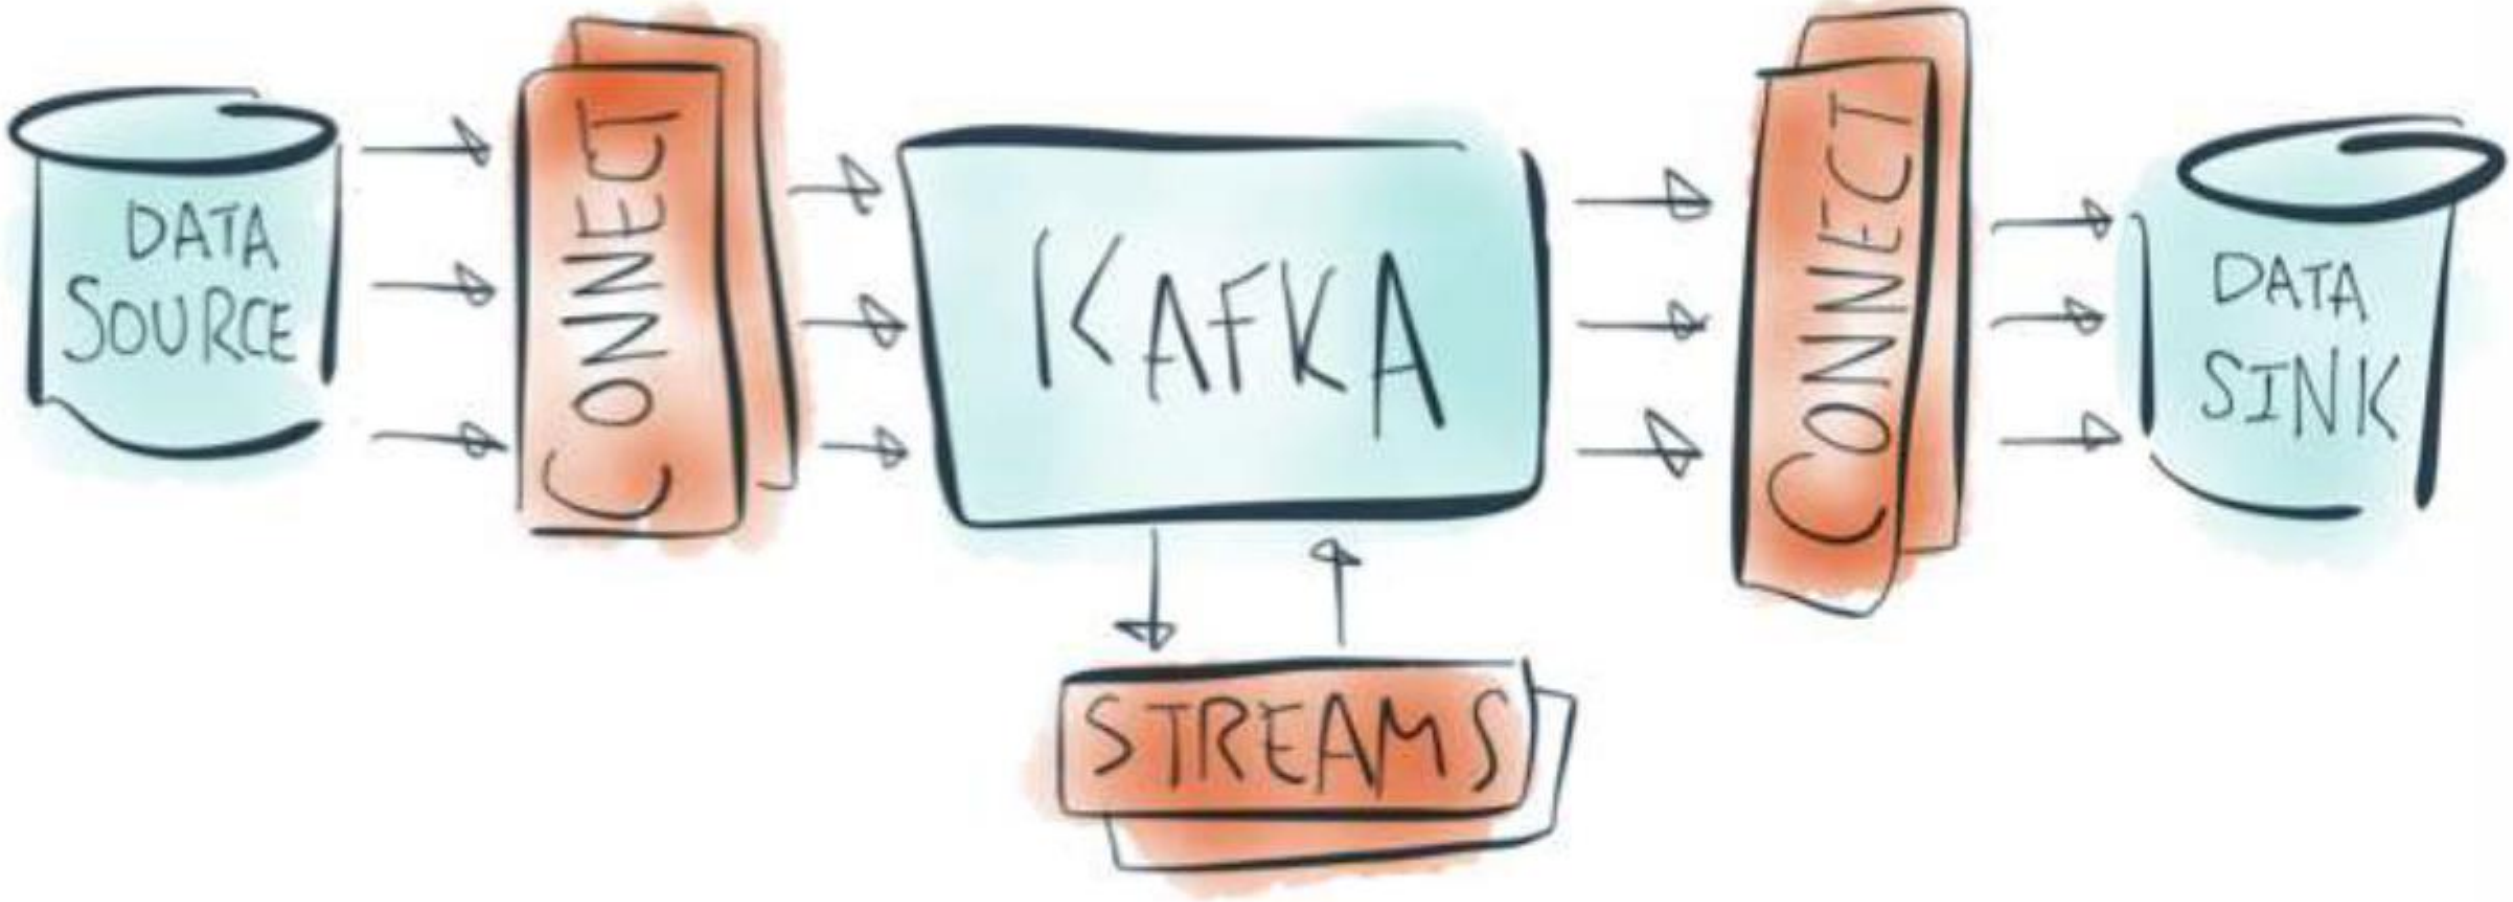


Copyright ETLForma – Tutti i diritti Riservati

# Kafka – Connect + Streams = ETL

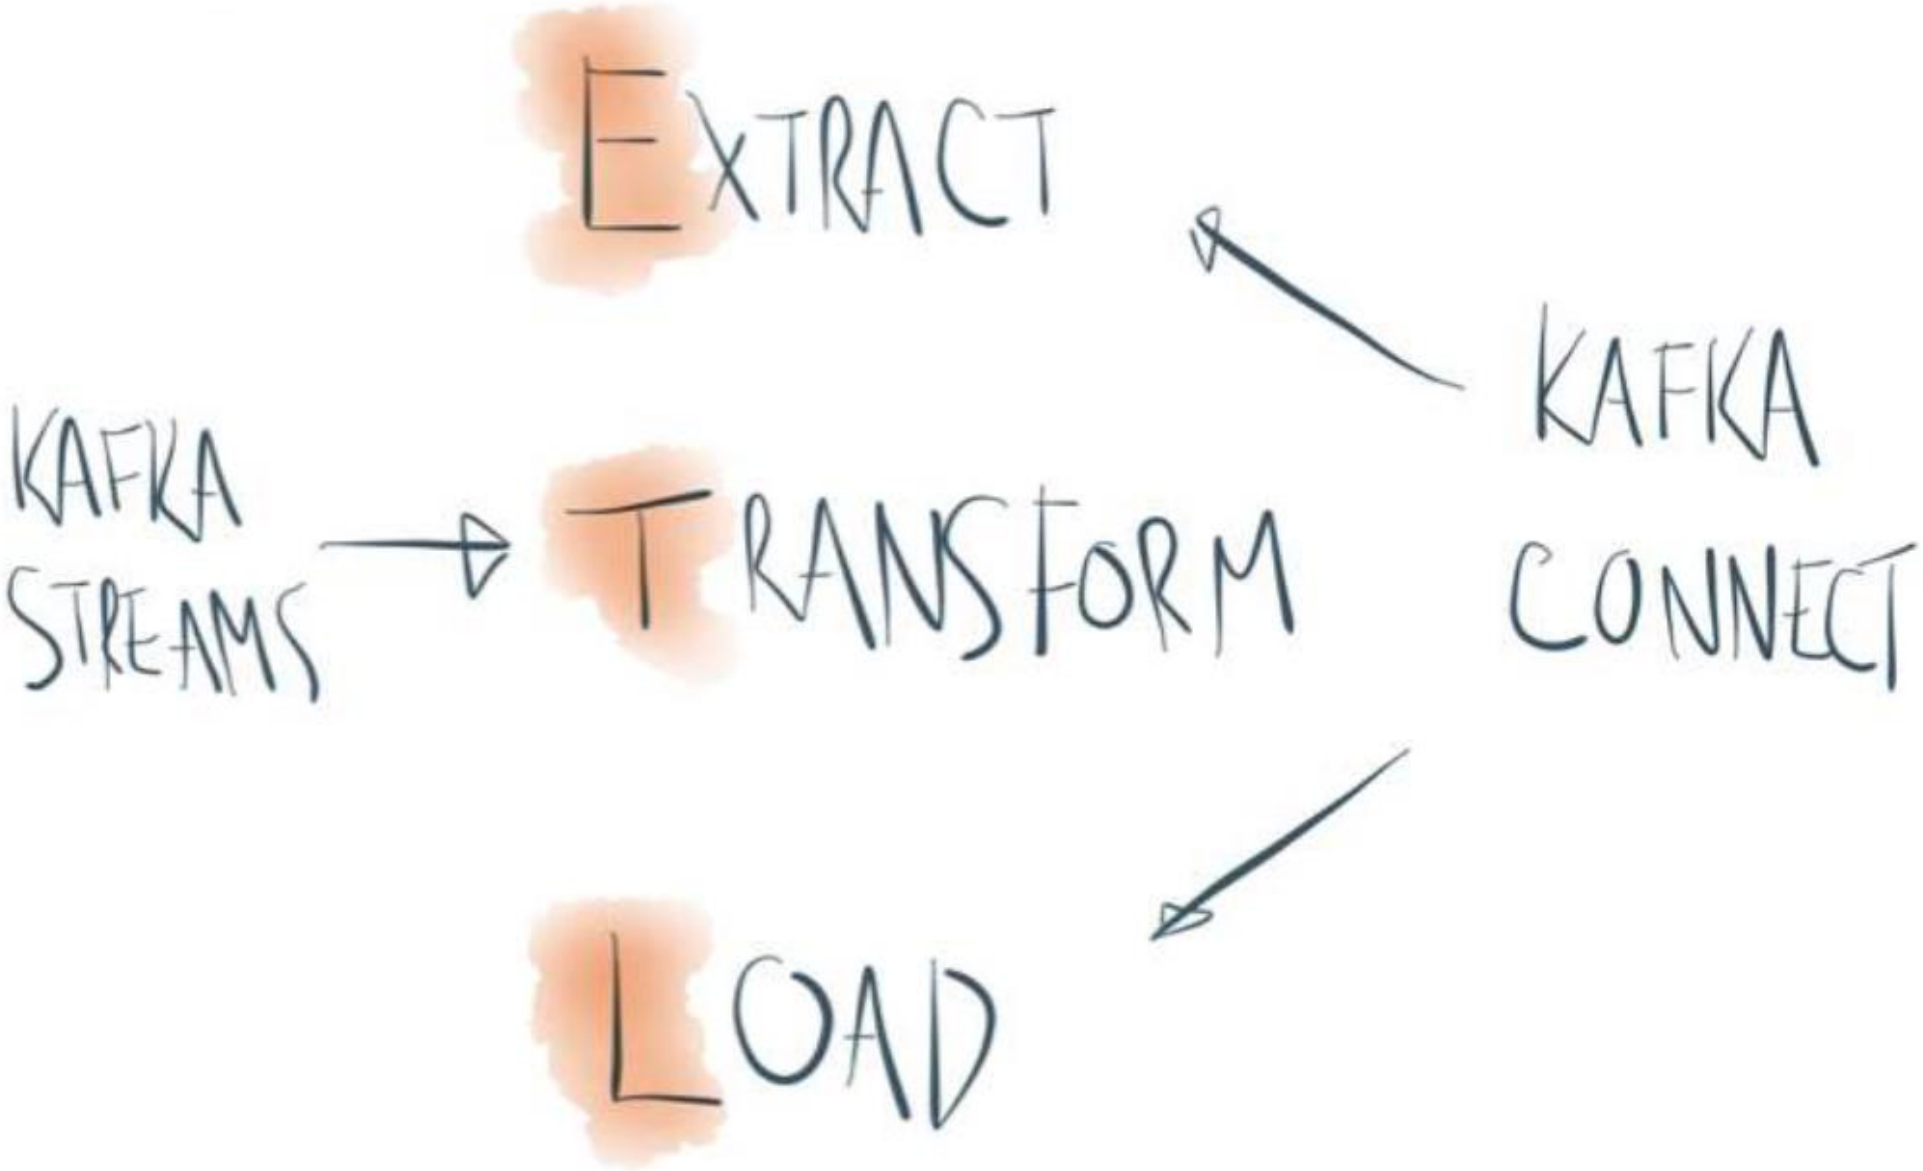


Copyright ETLForma – Tutti i diritti Riservati

# Kafka – Connect + Streams = ETL

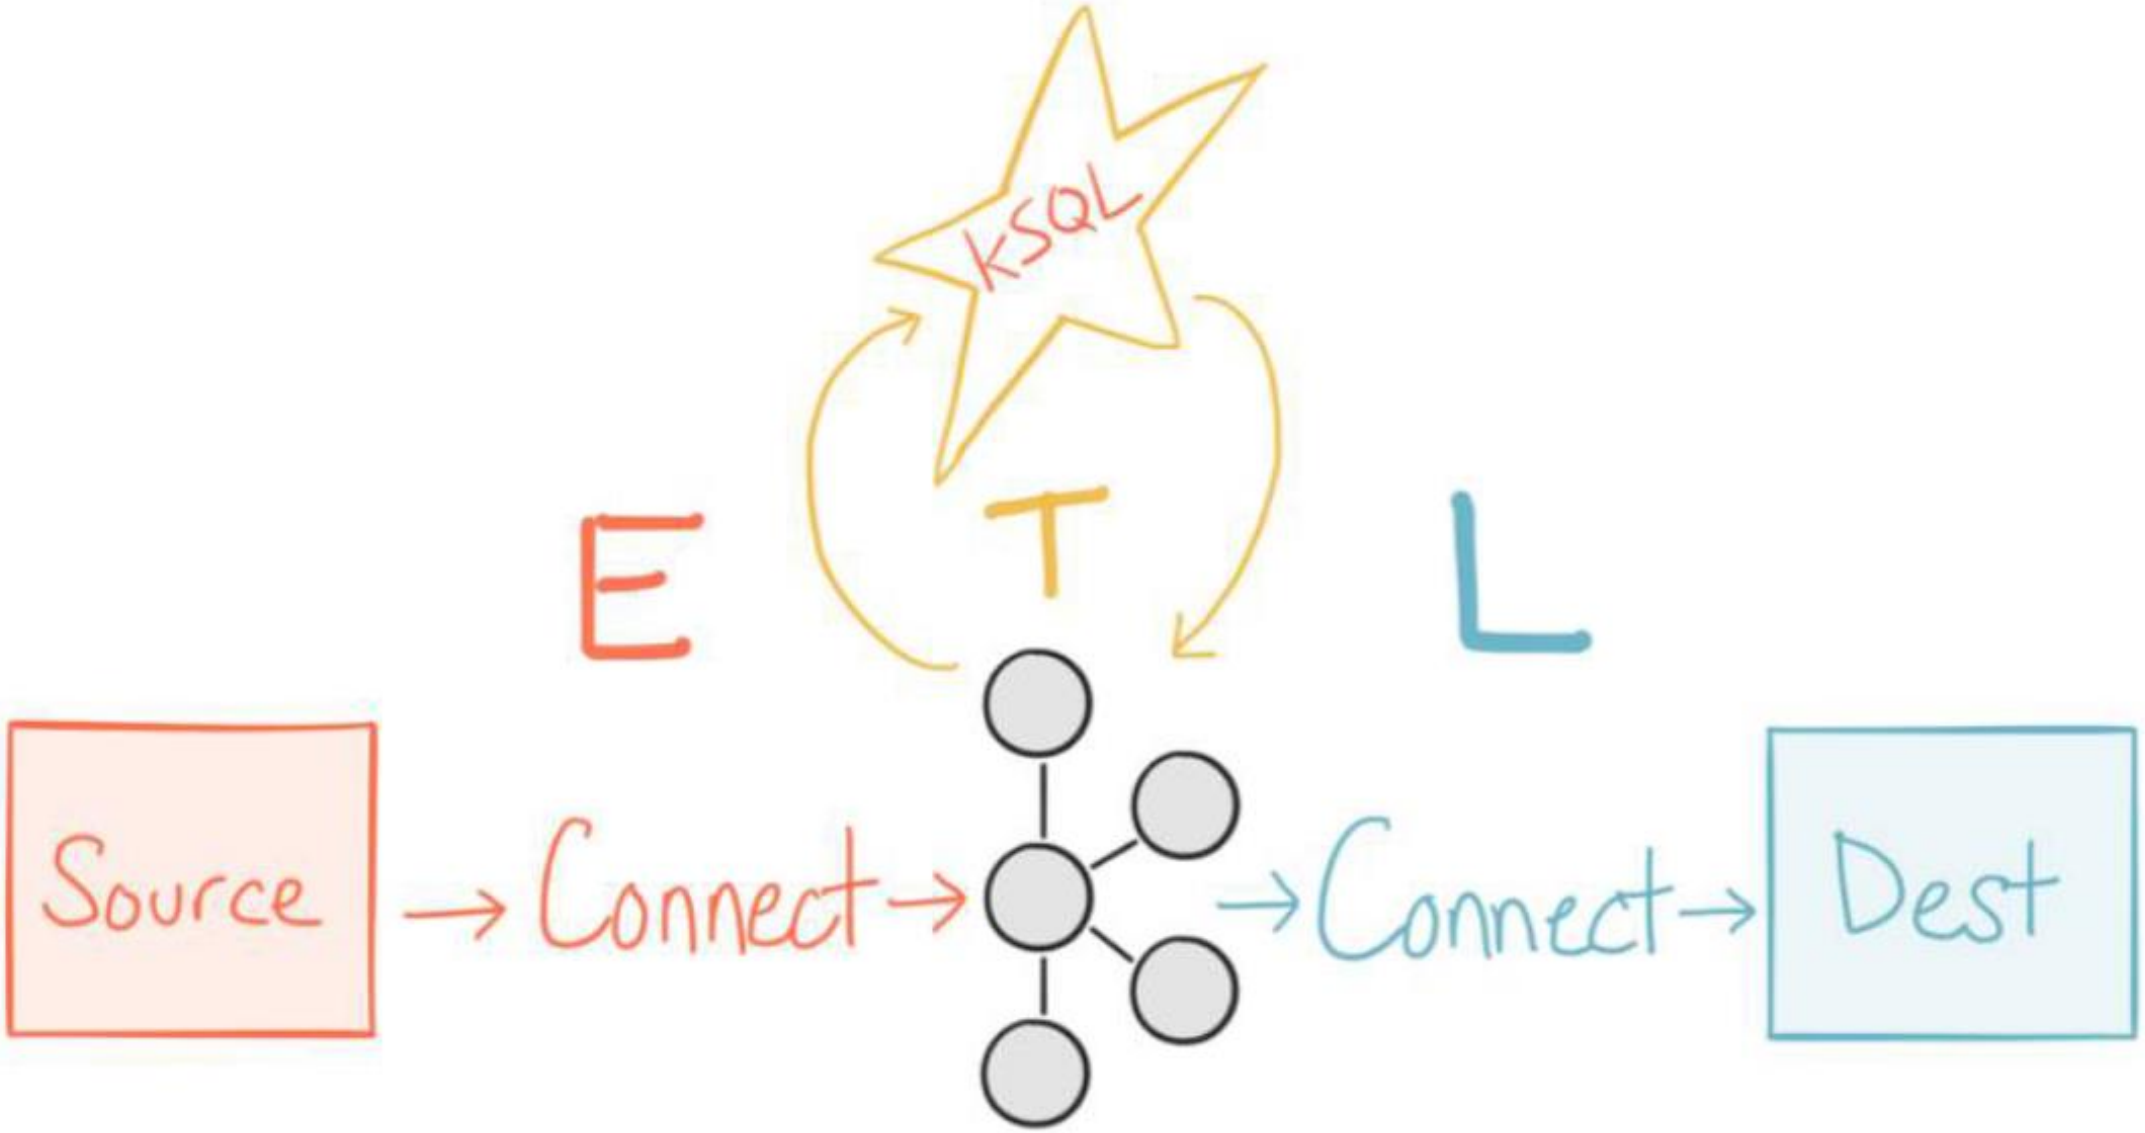


Copyright ETLForma – Tutti i diritti Riservati

# Kafka – No Code Stream Analytics

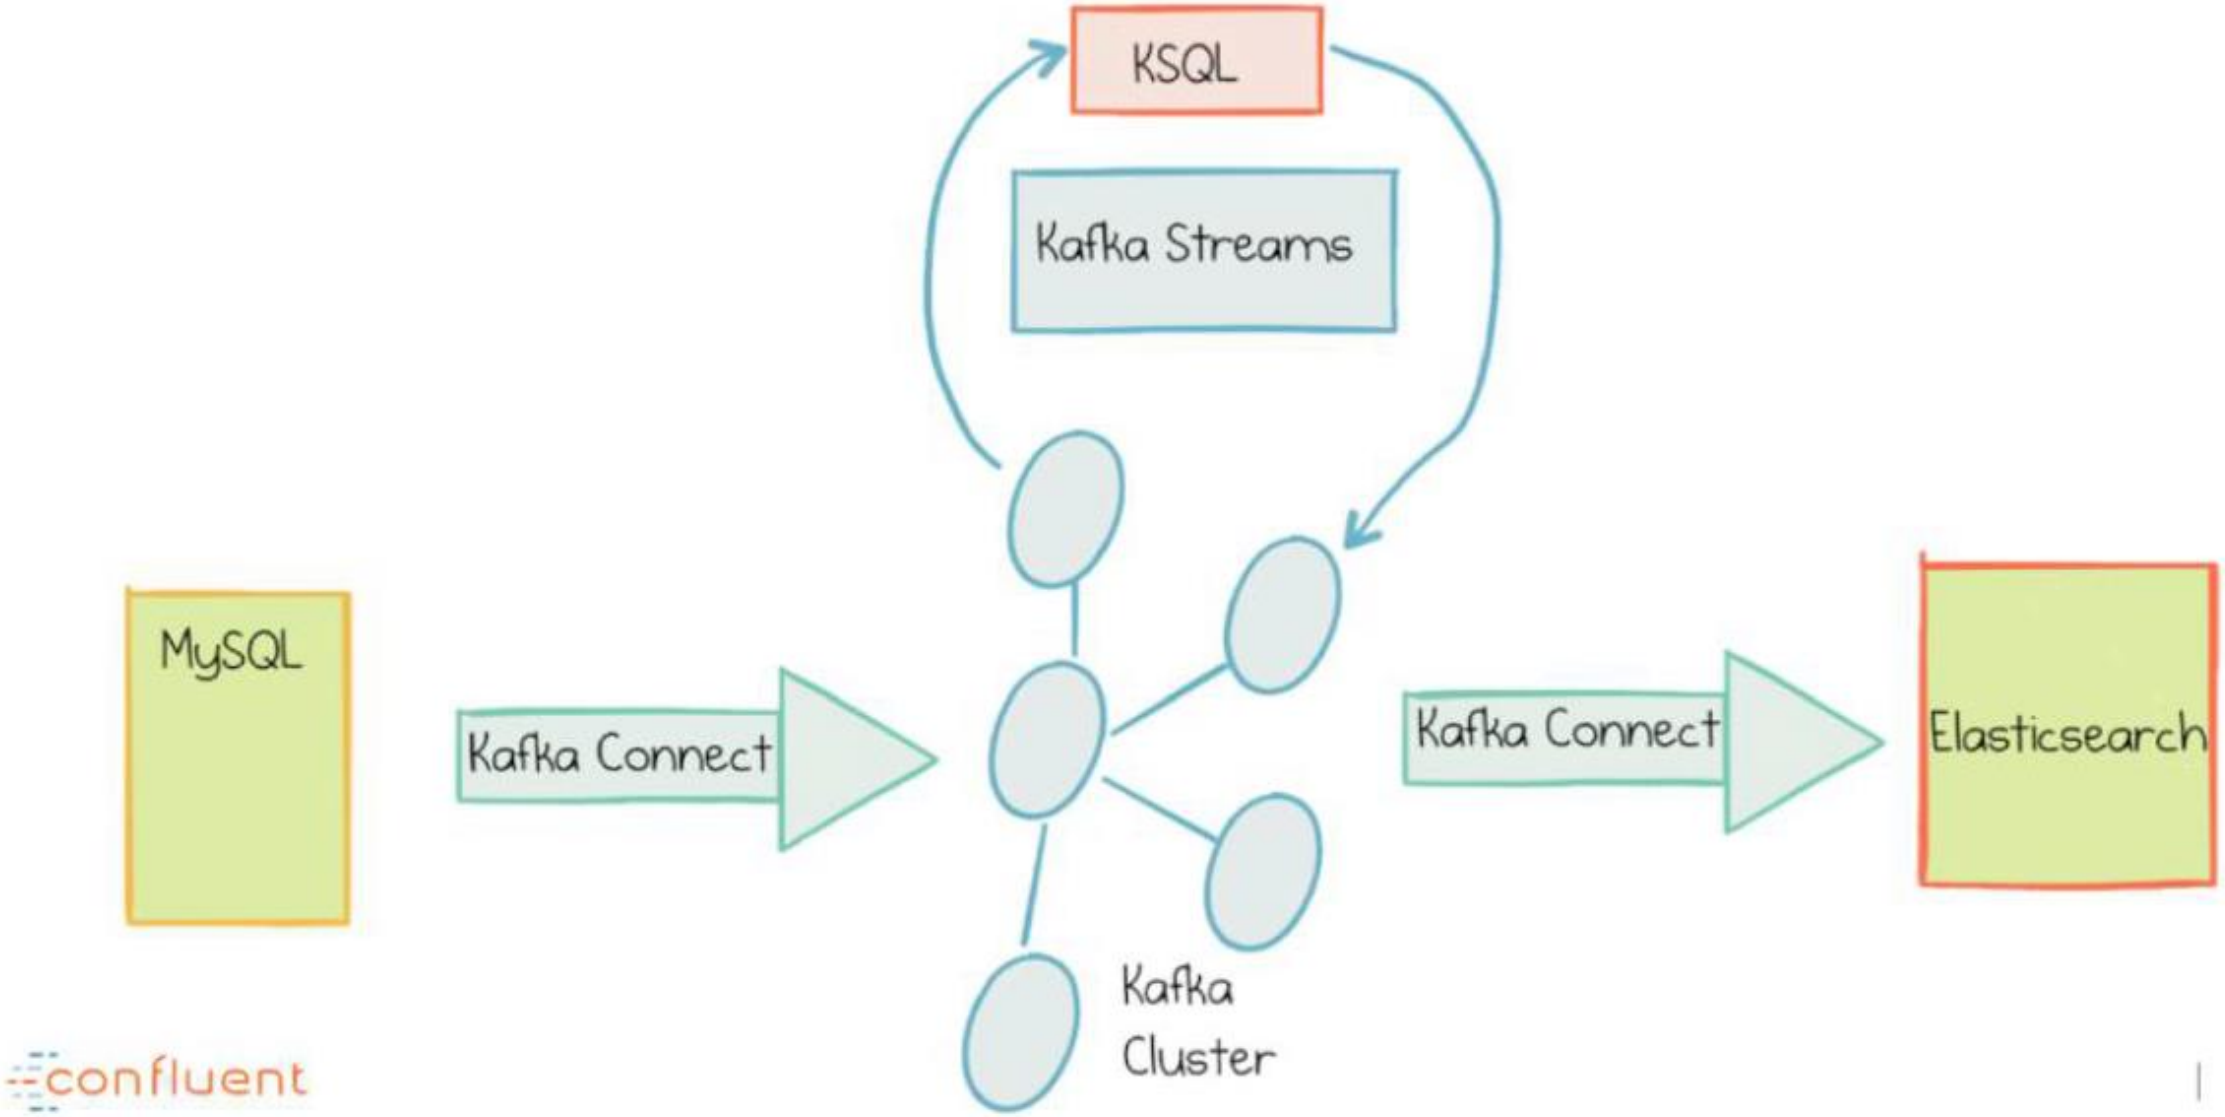


Copyright ETLForma – Tutti i diritti Riservati

# Kafka – No Code Stream Analytics

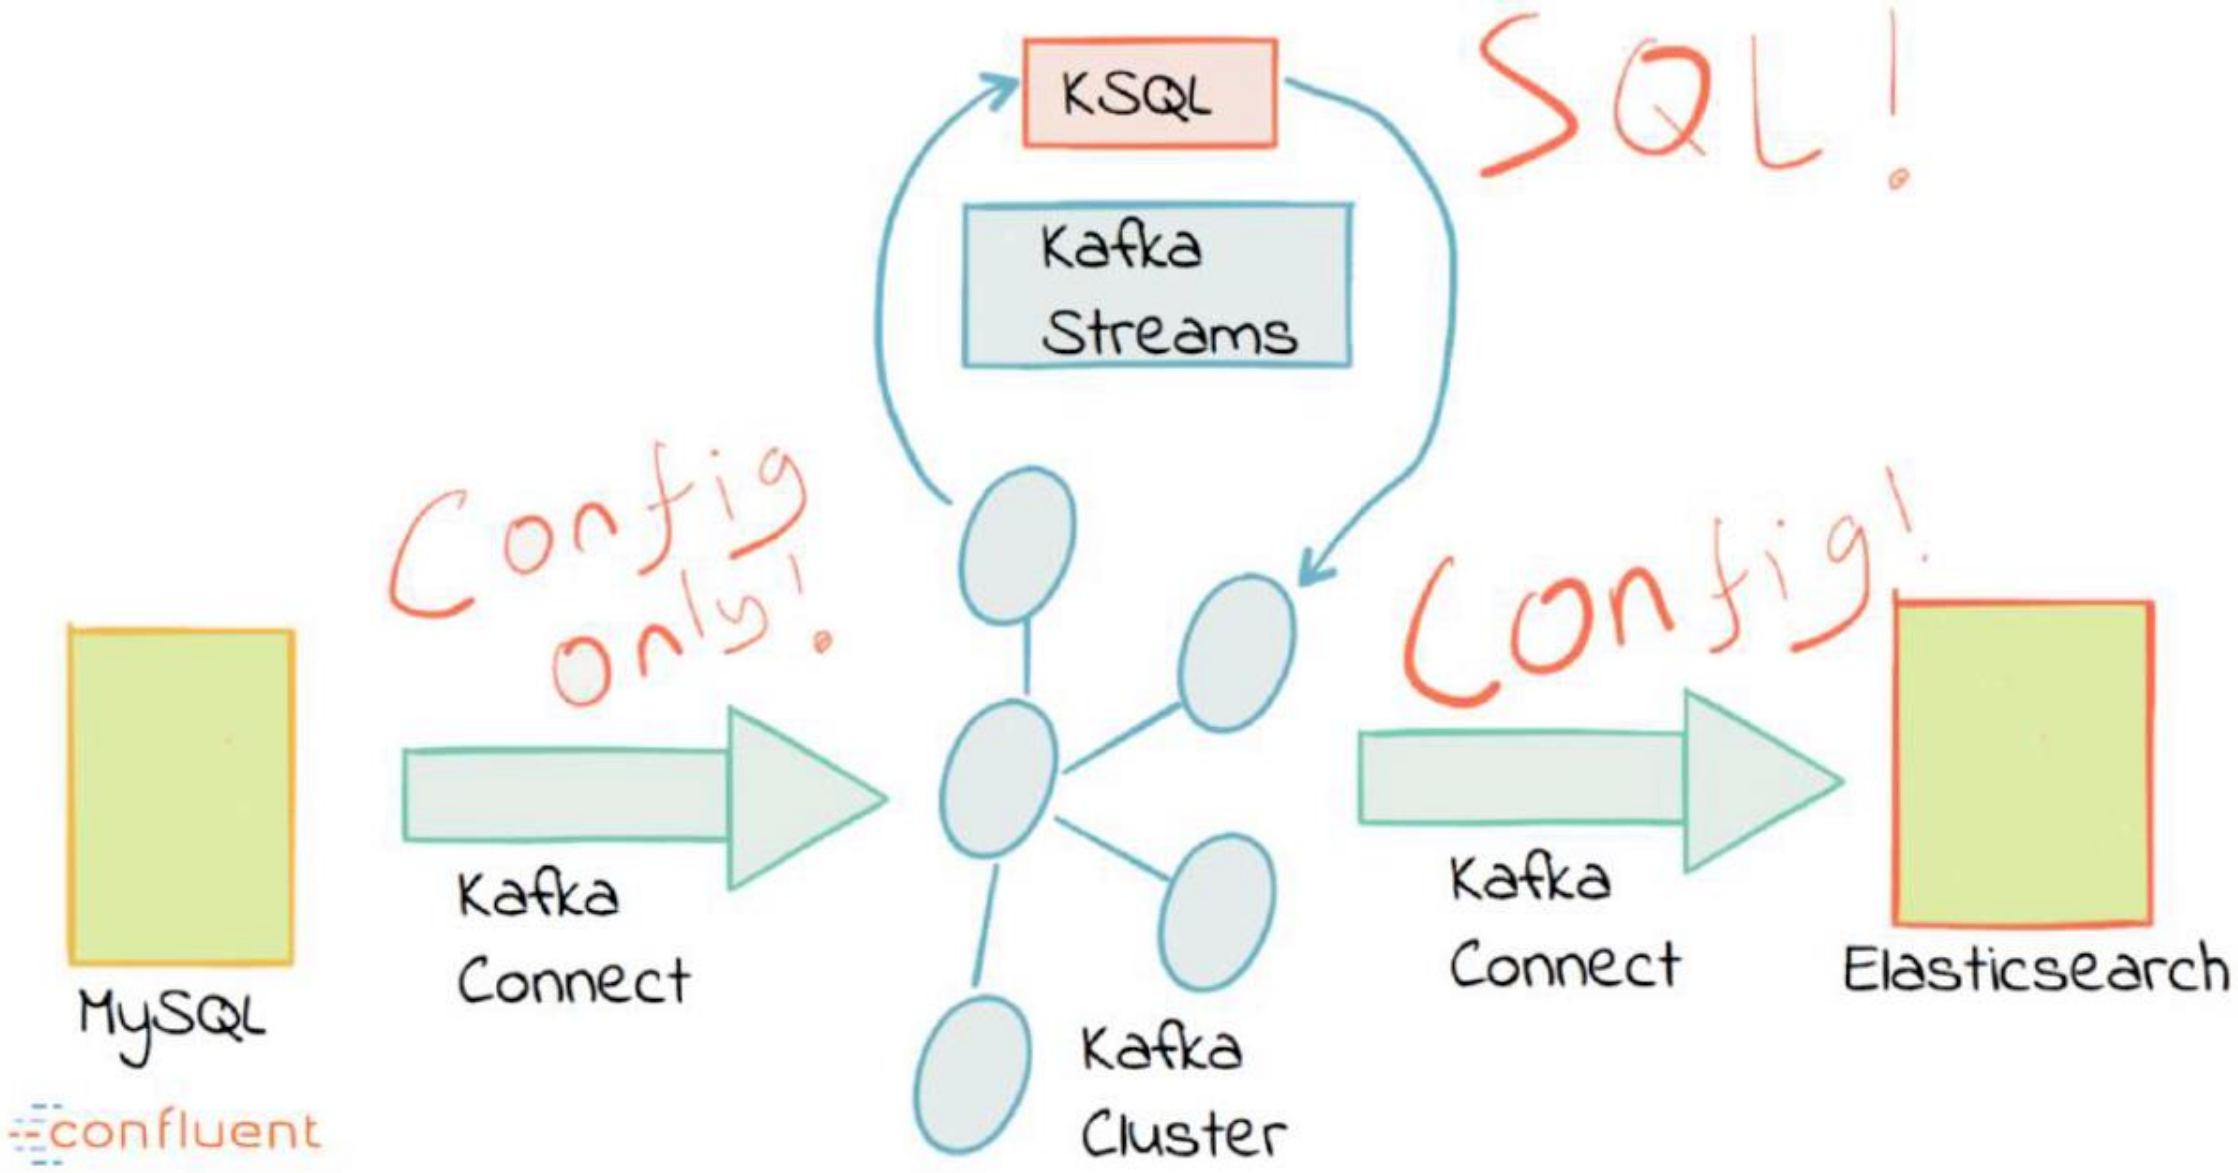


Copyright ETLForma – Tutti i diritti Riservati

# Kafka – ESEMPIO di un'architettura completa

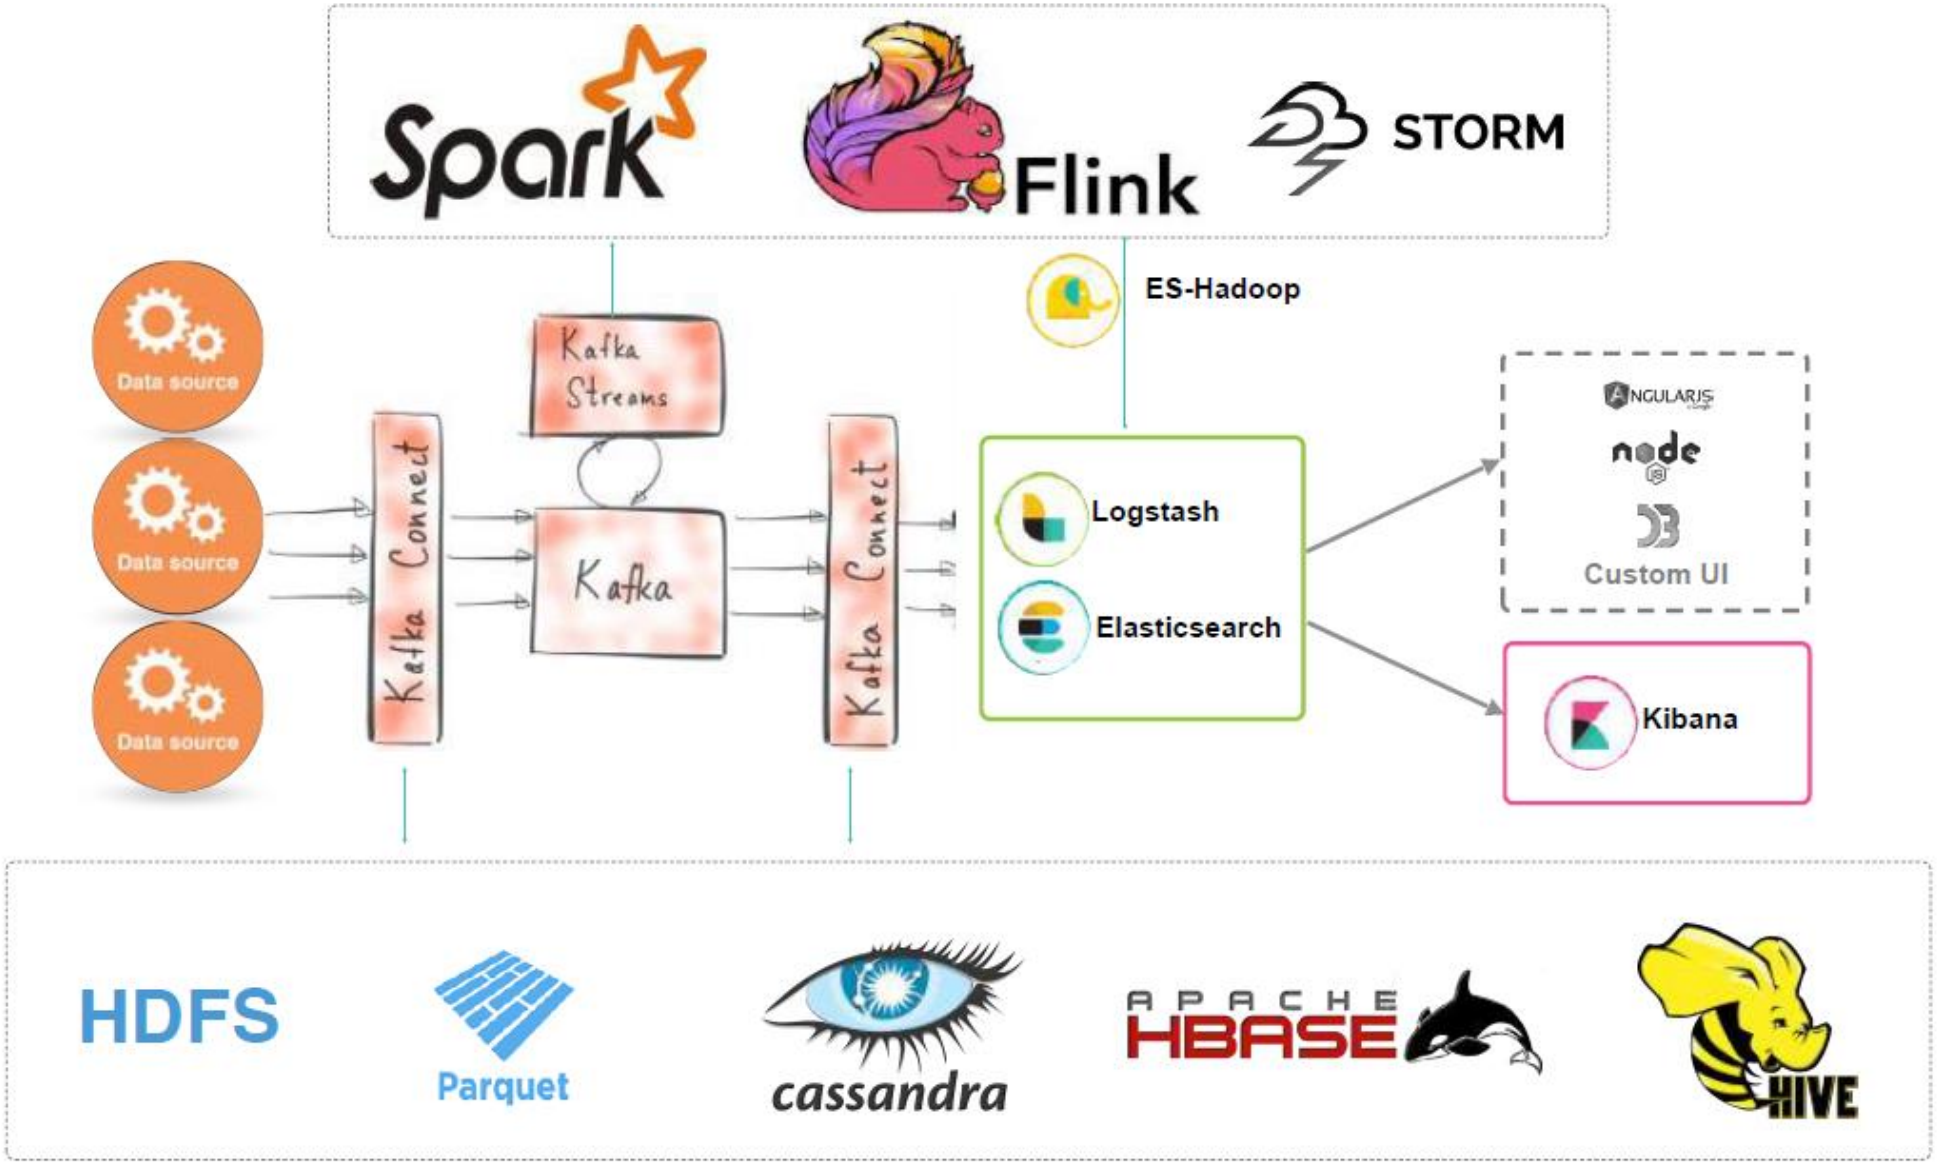


Copyright ETLForma – Tutti i diritti Riservati

# Kafka – Confluent Open Source

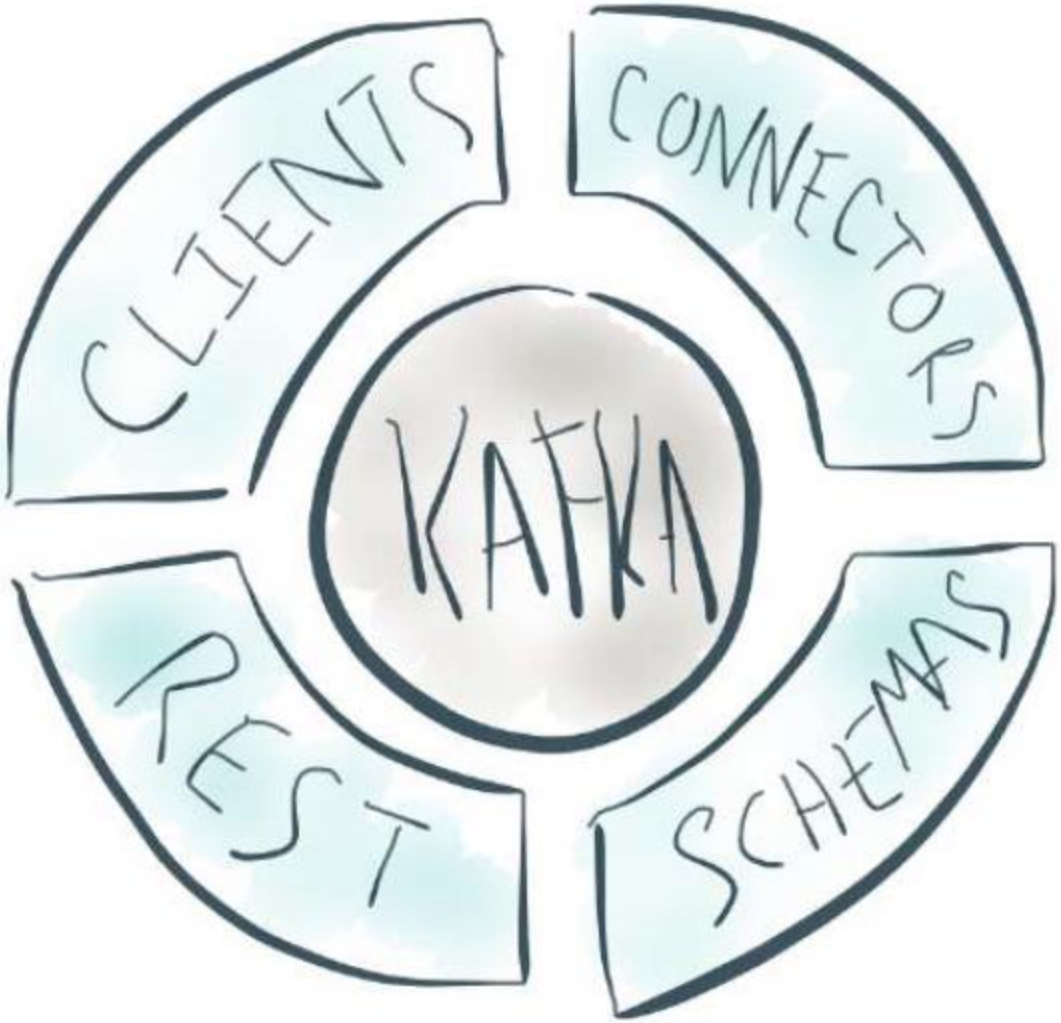


Copyright ETLForma – Tutti i diritti Riservati

# Kafka – Confluent Open Source

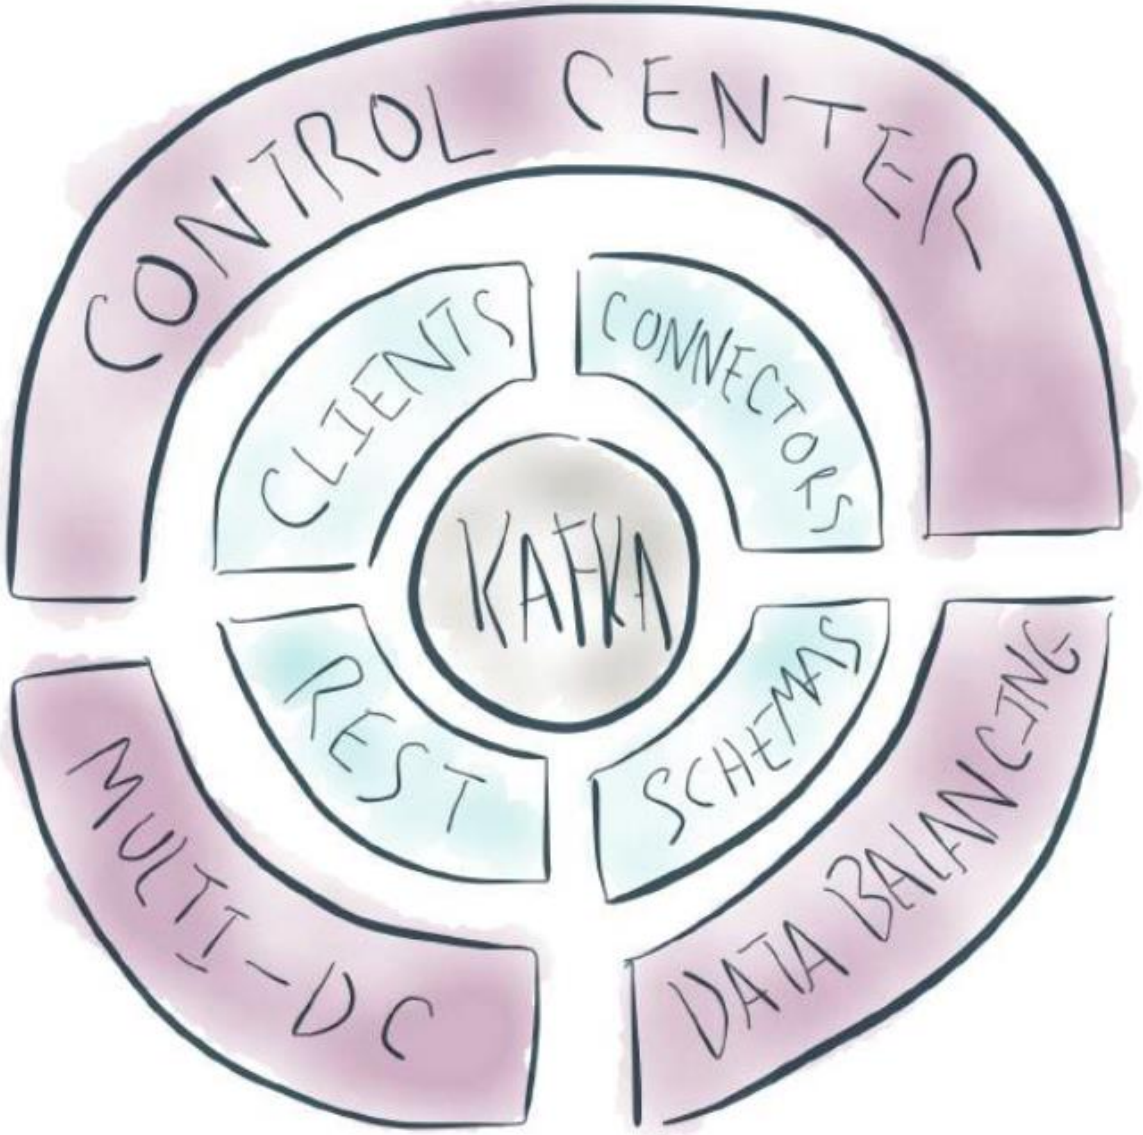


Copyright ETLForma – Tutti i diritti Riservati